



MINISTÉRIO DA CIÊNCIA E TECNOLOGIA  
**INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS**

**INPE-12137-TDI/967**

**CLASSIFICAÇÃO TEXTURAL DE IMAGENS RADARSAT-1  
PARA DISCRIMINAÇÃO DE ALVOS AGRÍCOLAS**

Silvio Pimentel Martins

Dissertação de Mestrado do Curso de Pós-graduação em Sensoriamento Remoto,  
orientada pelo Dr. Bernardo Friedrich Theodor Rudorff, aprovada em  
5 de março de 2004.

INPE  
São José dos Campos  
2005

528.711.7

MARTINS, S. P.

Classificação textural de imagens radarsat-1 para  
discriminação de alvos agrícolas / S. P. Martins. – São José  
dos Campos: INPE, 2004.

142p. – (INPE-12137-TDI/967).

1. Classificação digital. 2. Radarsat-1. 3. Soja. 4. Cana-  
de-açúcar. 5. Textura. 6. Imagens de radar. 7. Agricultura.  
I.Título.

Aprovado(a) pela Banca Examinadora,  
em cumprimento ao requisito exigido  
para a obtenção do Título de **Mestre**  
em **Sensoriamento Remoto**.

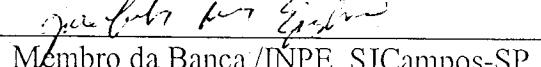
Dr. Yosio Edemir Shimabukuro

  
Presidente/INPE, SJCampos-SP

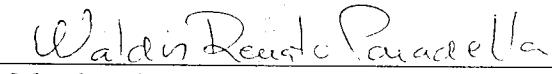
Dr. Bernardo Friederich Theodor Rudorff

  
Orientador/INPE, SJCampos-SP

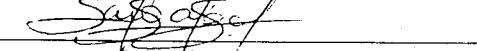
Dr. José Carlos Neves Epiphanio

  
Membro da Banca /INPE, SJCampos-SP

Dr. Waldir Renato Paradella

  
Membro da Banca/INPE, SJCampos-SP

Dr. Edson Eyji Sano

  
Membro da Banca  
Convidado/EMBRAPA/Brasília-DF

Candidato: Silvio Pimentel Martins

São José dos Campos, 05 de março de 2004.



*“O que o mundo mais precisa hoje, acima de qualquer outra coisa é uma fé inabalável em Deus, nosso Pai, e em Jesus Cristo, Seu Filho, o redentor do mundo”.* (Heber J. Grant).

*“Não conheço nenhuma fórmula fácil para o sucesso. Persistam, persistam, PERSISTAM; trabalhem, trabalhem, TRABALHEM – é o que conta na batalha da vida”.* (Heber J. Grant).

*“E se os homens vierem a mim, mostrar-lhes-ei sua fraqueza. E dou a fraqueza aos homens a fim de que sejam humildes; e minha graça basta a todos os que se humilham perante mim; porque caso se humilhem perante mim e tenham fé em mim, então farei com que as coisas fracas se tornem fortes para eles”.* (Éter 12:27-Livro de Mórmon, A Igreja de Jesus Cristo dos Santos dos Últimos Dias).

*“Em tudo somos atribulados, mas não angustiados; perplexos, mas não desanimados”*  
(II Coríntios 4:8).



*A meus pais e irmãos,  
Milton Martins,  
Ana Rosa Pimentel Martins, Milton, Otavio, Gisele e Eduardo.*



## **A GRADECIMENTOS**

Agradeço à Fundação de Aperfeiçoamento de Pessoal de Nível Superior – CAPES, pela ajuda financeira.

Ao Instituto Nacional de Pesquisas Espaciais – INPE, à Coordenação Acadêmica em Sensoriamento Remoto e à Secretaria da Pós-Graduação pela ajuda, oportunidade de estudos e utilização de suas instalações.

Ao meu orientador Prof. Dr. Bernardo Friedrich Rudorff, pela amizade, conhecimento passado e, pela orientação e apoio na realização deste trabalho.

Aos professores do INPE pelo conhecimento compartilhado especialmente aos professores Dr. Antonio Roberto Formaggio e Dr. José Carlos Neves Epiphanio pela oportunidade concedida de trabalhar como bolsista no INPE.

Aos amigos e professores Cleber Gonzalez de Oliveira, Dr. Waldir Renato Paradella, Dra. Corina da Costa Freitas, Dr. Camilo Daleles Rennó, Lélio Junior e Sidnei Sant'Anna pelas colaborações fundamentais para a realização deste trabalho.

Aos alunos 2002, Brummer, Cleber, Enzo, Eddy, Fernanda, Felix, Capitão Gelelete, Ieda, Liana Andersen, Luciana, Paula (*in memorian*), Pierre e Willian por toda a ajuda e apoio durante o período das disciplinas e amizade durante todo o mestrado.

Ao Major Paulo Souza por ter feito o modelo que gerou esse documento, pelas “macros” no excel, curso de lógica de programação e ajuda no ENVI e linguagem IDL.

Ao Brenner Gomes Silva, pelos momentos de discussão e conhecimentos compartilhados no LTID, ajuda com as “macros” do Excel e pela disposição de sempre ajudar.

À Salete Gurtler pela ajuda geral, principalmente no fluxograma.

À Maria José dos Santos (Mary) pela ajuda, amizade e principalmente pelo suporte doméstico (roupas, almoços, organização da bagunça, etc.).

A meus pais Milton Martins e Ana Rosa Pimentel Martins por sempre acreditarem na importância do estudo e pela ajuda financeira.

A meu irmão Otavio e família pelos almoços dominicais e apoio nos momentos mais difíceis.



## RESUMO

As imagens de sensoriamento remoto da faixa do visível e infravermelho do espectro eletromagnético apresentam grande potencial na identificação e discriminação de áreas agrícolas para fins de estimativa de safra. Contudo, a presença de nuvens impede a aquisição deste tipo de imagens. Já as imagens obtidas na faixa espectral de microondas por radares imageadores de abertura sintética independem de condições meteorológicas. Neste contexto, este trabalho tem por objetivo verificar o potencial de imagens de radar na identificação das culturas de soja e cana-de-açúcar na região de Assis-SP, através de classificação textural. As imagens utilizadas foram do RADARSAT-1/SAR C-HH nos seguintes modos de aquisição: *Fine-5*/descendente (F5D) de 30 de janeiro de 2003; *Fine-5*/ascendente (F5A) de 14 de fevereiro de 2003; e *Standard-7*/descendente (S7D) de 23 de fevereiro de 2003. Adicionalmente foram utilizadas duas imagens do sistema Landsat-7 ETM+ adquiridas em 23 de fevereiro e 27 de março de 2003 para servirem como referência na identificação dos alvos de interesse na área de estudo. Os métodos para identificação das culturas foram baseados em análises visuais e classificações digitais utilizando medidas de textura dentro das seguintes etapas: a) definição das classes de uso do solo; b) coleta das amostras de treinamento e teste; c) geração das bandas de textura; d) classificação supervisionada; e) avaliação das classificações através da matriz de confusão e do coeficiente *kappa*. As classificações digitais foram realizadas sobre as imagens originais, filtradas e de textura através do classificador pontual/contextual (MAXVER/ICM). Os resultados indicaram que as classificações realizadas sobre as imagens filtradas e de textura foram, em geral, satisfatórios indicando que as medidas texturais podem ser ferramentas úteis para maximizar a discriminação de classes de interesse em regiões agrícolas.



## **AGRICULTURAL TARGETS DISCRIMINATION BY TEXTURAL CLASSIFICATION OF RADARSAT-1 IMAGERY**

### **ABSTRACT**

Remote sensing images from the visible and infrared regions of the electromagnetic spectrum have demonstrated a great potential to identify and discriminate agricultural areas for crops estimation. However, cloud cover is an obstruction for this type of image acquisition. On the other hand, Synthetic Aperture Radar (SAR) images acquired in the microwave region of the electromagnetic spectrum are independent of weather conditions. In this context, this work has the objective to verify the capability of radar images to identify soybean and sugarcane crops in the region of Assis, São Paulo State using textural classification. Images from RADARSAT-1/SAR C-HH were acquired in the following modes: Fine-5/descending (F5D) from 31 January 2003; Fine-5/ascending (F5A) from 14 February 2003; and Standard-7/descending (S7D) from 23 February 2003. Additionally, two cloud free Landsat-7 images from 23 February and 27 March 2003 were used to identify targets of interest in the study area. The methods for crops type identification were based on visual and digital classification analysis by using texture measures in the following steps: a) definition of land use classes; b) extraction of training and test samples; c) generation of texture bands; d) supervised classification; and e) classification evaluations using confusion matrix and kappa coefficient. Digital classifications using MAXVER/ICM were carried out for: original, filtered and texture images. The results indicated a good classification performance for both filtered and texture images showing that the textural measures can be a useful tool to maximize crop type discrimination.



# SUMÁRIO

Pág.

## LISTA DE FIGURAS

## LISTA DE TABELAS

## LISTA DE SIGLAS E ABREVIATURAS

<b>CAPÍTULO 1 - INTRODUÇÃO .....</b>	<b>23</b>
<b>CAPÍTULO 2 - FUNDAMENTAÇÃO TEÓRICA .....</b>	<b>27</b>
2.1 Sensoriamento remoto na faixa de microondas .....	27
2.1.1 Interpretação de imagens de radar .....	32
2.1.2 Interação das microondas com alvos agrícolas .....	34
2.1.2.1 Parâmetros do sistema sensor .....	34
2.1.2.2 Parâmetros do alvo .....	36
2.2 Descrição do RADARSAT-1 .....	37
2.3 Utilização de imagens RADARSAT-1 em aplicações agrícolas .....	40
2.4 Classificação de imagens orbitais .....	47
2.4.1 Classificação supervisionada .....	48
2.4.1.1 O Classificador MAXVER-ICM .....	49
2.5 Análise de textura .....	50
<b>CAPÍTULO 3 - ÁREA DE ESTUDO .....</b>	<b>61</b>
3.1 Área de estudo .....	61
3.1.1 Uso do solo .....	64
3.1.2 A cultura de soja .....	65
3.1.3 A cultura de cana-de-açúcar .....	68
<b>CAPÍTULO 4 - MATERIAIS E MÉTODOS .....</b>	<b>71</b>
4.1 Materiais .....	71
4.1.1 Imagens .....	71
4.1.2 Softwares .....	71
4.2 Metodologia .....	72
4.2.1 Correção geométrica das imagens .....	74
4.2.1.1 Ortorretificação .....	74
4.2.2 Trabalho de campo .....	77
4.2.3 Análise de textura nas imagens RADARSAT-1 .....	78
4.2.3.1 Definição das classes de estudo .....	79
4.2.3.2 Extração de amostras de treinamento e teste .....	81
4.2.3.3 Análise das medidas e geração das bandas de textura .....	83
4.2.3.4 Classificação das imagens .....	87
<b>CAPÍTULO 5 - RESULTADOS E DISCUSSÃO .....</b>	<b>91</b>
5.1 Seleção das classes de estudo e análise visual .....	91
5.2 Seleção das amostras de treinamento e teste .....	96
5.3 Seleção das medidas e bandas de textura .....	98

5.3.1 Imagem F5D .....	99
5.3.2 Imagem F5A .....	102
5.3.3 Imagem S7D .....	105
5.4 Classificação das imagens .....	108
5.4.1 Classificação da imagem F5D .....	109
5.4.2 Classificação da imagem F5A .....	115
5.4.3 Classificação da imagem S7D .....	120
<b>CAPÍTULO 6 - CONCLUSÕES E RECOMENDAÇÕES .....</b>	<b>127</b>
<b>REFERÊNCIAS BIBLIOGRÁFICAS .....</b>	<b>131</b>
<b>APÊNDICE A .....</b>	<b>137</b>

## LISTA DE FIGURAS

2.1 - Espectro eletromagnético e as bandas utilizadas na região de microondas .....	28
2.2 - Janelas de transmissão atmosférica na região de microondas.....	29
2.3 - Contribuições do retroespalhamento de um dossel agrícola. ....	35
2.4 - Módulos de imageamento do RADARSAT-1. ....	38
2.5 - Órbitas ascendente e descendente do RADARSAT-1. ....	39
2.6 - Variação do retroespalhamento em função do ângulo de incidência. ....	41
2.7 - Valores de retroespalhamento para cada área em março. As letras indicam o uso: sn (solo exposto), mi (milho), a (algodão), po (pousio), ca (cana-de-açúcar), t (tomate) e sp (solo preparado). ....	43
2.8 - Retroespalhamento médio de culturas agrícolas para pares de imagens RADARSAT-1 ascendente e descendente. A variação do retroespalhamento em cada cultura é indicada pela barra de erro. ....	44
2.9 - Variação do retroespalhamento em função da fase de crescimento de culturas de grãos e canola. Estes valores médios de retroespalhamento foram derivados da imagem RADARSAT-1 modo <i>Fine</i> adquirida em 22 de julho de 1997. ....	46
2.10 - Janela 3 x 3 de uma imagem com <i>pixel</i> central (*) e 8 vizinhos.....	53
2.11 - Imagem 4 x 4 com níveis de cinza entre 0 e 3 (a). As matrizes de co-ocorrência com ângulos de 0°, 45°, 90° e 135° são apresentadas em (b), (c), (d) e (e), respectivamente. ....	55
2.12 - Matriz de co-ocorrência de níveis de cinza.....	56
3.1 - Representação da área de estudo. ....	61
3.2 - As partes do sistema vegetativo da soja. ....	66
3.3 - Fotografias de diferentes talhões de soja da área de estudo em 24 e 25/Fev/2003.	68
4.1 - Fluxograma em modelagem OMT-G (Object Modeling Techniques para aplicações geográficas). ....	733
4.2 - Representação do DEM e das imagens ortorretificadas. (a) DEM, (b) S7D, (c) F5D; (d) F5A; (e) ETM+ 23/02/2003; (f) ETM+ 27/03/2003.....	777
4.3 - Ilustração das áreas visitadas no campo (a) Imagem Landsat-7/ETM+ R(4)G(5)B(3) de 07/02/2002 (b) Imagem Landsat-7/ETM+ R(4)G(5)B(3) de 06/02/2003. ....	788
4.4 - Exemplo de variação tonal. (a) ETM+ R(4)G(5)B(3) de 23/02/2003, (b) S7D de 23/02/2003, (c) F5D de 31/01/2003, (d) F5A de 14/02/2003.....	80
4.5 - Ilustração do procedimento utilizado para extração de amostras de treinamento e teste. (a) ETM+ ortorretificada, (b) F5D ortorretificada, (c) F5D original. ....	822
4.6 - Recortes representativos das áreas comuns. (a) Fine5D, (b) F5A, (c) ETM+ R(4)G(5)B(3) e, (d) S7D. ....	833
4.7 - Representação do ajuste do histograma. (a) Imagem de entrada; (b) Imagem de saída. ....	877
5.1 - Exemplo de tonalidade escura para um talhão de cana-de-açúcar. (a) ETM+ R(4)G(5)B(3), (b) F5D, (c) S7D, (d) F5A, (e) fotografia da cultura de cana-de- açúcar adulta de 25/fev/2003.....	933

5.2 - Exemplo de tonalidade média para um talhão de cana-de-açúcar. (a) ETM+ R(4)G(5)B(3), (b) F5D, (c) S7D, (d) F5A, (e) fotografia da cana-de-açúcar adulta de 25/fev/2003.....	944
5.3 - Exemplo de tonalidade média para um talhão de soja. (a) ETM+ R(4)G(5)B(3), (b) F5D, (c) F5A, (d) S7D.....	955
5.4 - Ilustração de gráficos de distribuição de classes em relação à medidas de textura para a imagem F5D.....	101
5.4 - (conclusão).....	1022
5.5 - Ilustração de distribuição de classes em relação às medidas de textura para a imagem F5A.....	1044
5.5 - (conclusão).....	1055
5.6 - Ilustração de distribuição de classes relacionados às medidas de textura para a imagem S7D.....	1077
5.6 - (conclusão).....	1088
5.7 - Classificação da imagem F5D original.....	1099
5.8 - Classificação da imagem F5D com filtro de Frost5x5.....	111
5.9 - Classificação da imagem de textura média do vetor diferença.....	1144
5.10 - Classificação da imagem F5A original.....	1166
5.11 - Classificação da imagem F5A filtrada de Gamma5x5.....	1177
5.12 - Classificação da imagem S7D original.....	20
5.13 - Classificação da imagem S7D filtrada de Gamma5x5.....	1222
A.1 - Imagens de textura da imagem F5D. (a) <i>Cluster prominence</i> , (b) Contraste do vetor diferença, (c) Contraste do vetor diferença (Frost 5x5), (d) Energia do vetor diferença.....	1377
(continua).....	1377
A.1 - Imagens de textura da imagem F5D (conclusão). (e) Variância do vetor diferença, (f) Média (Frost 5x5), (g) Média do vetor soma, (h) Média do vetor soma (Frost 5x5).....	1388
A.2 - Imagens de textura F5A. (a) Média (Frost5x5), (b) Média (Lee 5x5), (c) Qui-quadrado, (d) <i>Cluster prominence</i> , (e) Contraste do vetor diferença, (f) Energia do vetor diferença.....	1399
A.2 - Imagens de textura F5A (conclusão). (g) Entropia do vetor diferença, (h) Variância do vetor diferença, (i) Entropia, (j) Entropia (Frost5x5).....	140
A.3 - Imagens de textura S7D. (a) Qui-quadrado, (b) Contraste, (c) Energia do vetor diferença, (d) Média do vetor diferença, (e) Variância do vetor diferença, (f) Energia.....	14141
A.3 - Imagens de textura S7D (conclusão). (g) homogeneidade, (h) Desvio médio absoluto, (i) Média, (j) Média (Frost5x5), (k) Média (Gamma5x5), (l) Média do vetor soma.....	142

## LISTA DE TABELAS

2.1 - Modos de imageamento do RADARSAT-1 .....	38
2.2 - Parâmetros de imageamento do RADARSAT-1.....	39
3.1 - Áreas agrícolas ( $\text{km}^2$ ) dos municípios pertencentes à região de Assis-SP .....	62
3.2 - Dados Pluviométricos nos dias de imageamento.....	63
3.3 - Uso do solo dos municípios que abrangem a área de estudo .....	64
3.4 - Total de área cultivada (em hectares) por tipo de cultura dos municípios pertencentes à região de Assis-SP .....	65
3.5 - Fases fenológicas da cultura de soja e respectivas simbologias.....	67
4.1 - Características das imagens utilizadas no trabalho .....	711
4.2 - Comparação das características dos métodos polinomial e fotogramétrico.....	755
4.3 - Principais características das cartas topográficas utilizadas. ....	755
4.4 - Procedimentos adotados para correção de cartas topográficas. ....	766
4.5 - Procedimentos adotados para a ortorretificação.....	766
4.6 - Medidas de textura selecionadas.....	844
4.7 - Conceitos de eficiência para o <i>Kappa</i> . ....	899
5.1 - Número de amostras por classe de uso para a imagem F5D.....	966
5.2 - Número de amostras por classe de uso para a imagem F5A.....	966
5.3 - Número de amostras por classe de uso para a imagem S7D.....	977
5.4 - Valores de Média e Desvio Padrão dos níveis de cinza de amostras de treinamento/teste.....	977
5.5 - Medidas selecionadas pelo fator discriminante $F_d$ para a imagem F5D. ....	999
5.6 - Medidas selecionadas pelo fator discriminante $F_d$ para a imagem F5A. ....	1033
5.7 - Medidas selecionadas pelo fator discriminante $F_d$ para a imagem S7D. ....	1066
5.8 - Matriz de confusão da classificação da imagem F5D original.....	110
5.9 - Matriz de confusão da imagem F5D filtrada (Frost5x5). ....	1122
5.10 - Resultado das classificações de imagens de textura F5D em %. ....	1133
5.11 - Matriz de confusão da imagem de textura média do vetor diferença.....	1155
5.12 - Matriz de confusão da classificação da imagem F5A original.....	1166
5.13 - Matriz de confusão da imagem F5A filtrada de Gamma5x5. ....	1188
5.14 - Resultado das classificações de imagens de textura F5A em %. ....	119
5.15 - Matriz de confusão da imagem S7D original.....	121
5.16 - Matriz de confusão da imagem S7D filtrada de Gamma5x5. ....	1233
5.17 - Resultado das classificações de imagens de textura S7D em %. ....	1244



## **LISTA DE SIGLAS E ABREVIATURAS**

CCRS	- Canada Centre for Remote Sensing
CEOS	- Committee on Earth Observation Satellites
DEM	-Digital Elevation Model
ETM+	- Enhanced Thematic Mapper Plus
GCP	- Ground Control Points
GLCM	- Gray Level Co-occurrence Matrix
GPS	- Global Positioning System
IAC	- Instituto Agronômico de Campinas
IAF	- Índice de Área Foliar
IBGE	- Instituto Brasileiro de Geografia e Estatística
ICM	- Interated Conditional Modes
INPE	- Instituto Nacional de Pesquisas Espaciais
MAXVER	- Máxima Verossimilhança
PAM	- Produção Agrícola Municipal
RADAR	- Radio Detection and Ranging
RAR	- Real Aperture Radar
RMSE	- Root Mean Square Error
SAD	- South America Datum
SAR	- Synthetic Aperture Radar
SLAR	- Side-Looking Airborne Radar
SIG	- Sistema de Informação Geográfica
UTM	- Universal Transversa de Mercator



## CAPÍTULO 1

### INTRODUÇÃO

As imagens de sensoriamento remoto aliadas às técnicas de processamento digital de imagens e de outras tecnologias, como os Sistemas de Informação Geográfica (SIG) e o Sistema de Posicionamento Global (GPS), apresentam potencial na discriminação e mapeamento rápido e confiável de culturas agrícolas para fins de estimativa de área e produtividade. Considerando a grande dimensão do território brasileiro e a intensa atividade agrícola em grande parte do país, o uso de imagens de sensoriamento remoto pode ser uma opção viável para a obtenção de informações agrícolas devido à visão sinóptica dos sensores e repetição proporcionada pelos sistemas de imageamento a bordo de satélites.

Porém, as imagens de sensoriamento remoto óptico adquiridas nas faixas espectrais do visível e infravermelho do espectro eletromagnético apresentam limitações, em especial na agricultura, por causa da intensa cobertura de nuvens por ocasião do crescimento e desenvolvimento das culturas agrícolas, dificultando a obtenção de imagens nesta faixa do espectro eletromagnético (Brisco e Brown, 1995; Ippoliti-Ramilo et al., 1999).

Já os sensores que operam na faixa espectral de microondas, os radares imageadores de abertura sintética (*Synthetic Aperture Radar – SAR*) adquirem imagens praticamente sem interferência das condições meteorológicas devido ao tamanho das partículas serem menores do que o comprimento de onda nessa faixa espectral, o que é uma vantagem sobre sensores ópticos (Smith et al., 1995). Além disso, por se tratar de um sistema ativo, que tem sua própria fonte de radiação, os radares independem da radiação solar para o imageamento podendo ser empregado tanto no período diurno quanto no noturno.

Enquanto as imagens de sensores ópticos estão relacionadas às características físico-químicas dos alvos, as imagens de sensores de microondas estão relacionada às

propriedades dielétricas e geométricas dos alvos, trazendo, portanto, perspectivas promissoras em várias aplicações agrícolas (Brisco e Brown, 1997).

Um dos maiores entraves das imagens de radar em diversas áreas de aplicações é a presença do ruído *speckle*. Em geral, este ruído prejudica os aspectos radiométricos e texturais da imagem e sua redução através de filtros adaptativos resulta na melhora da discriminação entre diferentes tipos de alvos tanto para os classificadores digitais por *pixel* como para os classificadores texturais (Lopes et al., 1990).

Entre as diversas técnicas de processamento digital de imagens de radar, destaca-se a classificação. A classificação é realizada sobre imagens multiespectrais, como ocorre com as imagens adquiridas por sensores ópticos ou sobre imagens SAR monoespectrais obtida por radares acoplados em plataformas orbitais como o satélite canadense RADARSAT-1. O desempenho da classificação de imagens de radar monoespectrais pode ser melhorado com a utilização da informação textural da imagem que se refere à variação espacial dos níveis de cinza de um determinado alvo na imagem (Haralick et al., 1973). Essa variação é produzida por uma associação de feições pequenas demais para serem detectadas e delimitadas individualmente, mas que permitem a identificação e a definição de áreas da superfície com propriedades específicas. A variação de textura numa imagem de radar é função do comprimento de onda, resolução e ângulo de incidência do sistema assim como a disposição e composição das características ambientais (Lewis e Henderson, 1997). Segundo os autores, os componentes de textura nas imagens de radar podem ser de três tipos: micro, meso e macro.

Os atributos texturais e estatísticos podem ser úteis em uma classificação digital de imagens de radar, pois auxiliam a discriminação de diferentes classes de uso do solo. Isto pode ser constatado em diversos trabalhos como Ulaby et al. (1986a), Rennó (1995), Soares et al. (1997), Morais et al. (1999), Silva Junior (2002) e Presutti et al. (2001).

McNairn et al. (2002) avaliaram os resultados de classificações realizadas em imagens RADARSAT-1 adquiridas ao longo da estação de crescimento de culturas agrícolas e

observaram que as melhores classificações eram obtidas quando as culturas se encontravam na fase de máximo desenvolvimento.

Desse modo, o presente trabalho tem por objetivo principal verificar o potencial das imagens RADARSAT-1 como ferramenta na identificação e discriminação das culturas de soja e cana-de-açúcar na região de Assis-SP, através de classificação textural.

Os objetivos específicos são:

- Analisar a capacidade de discriminar visualmente diferentes alvos agrícolas em imagens RADARSAT-1;
- Analisar o potencial das medidas de textura na discriminação e classificação digital de diferentes classes de uso do solo;
- Avaliar e comparar os resultados das classificações das imagens de radar original, filtradas e as de textura.



## CAPÍTULO 2

### FUNDAMENTAÇÃO TEÓRICA

#### 2.1 Sensoriamento Remoto na Faixa de Microondas

O RADAR (*Radio Detection and Ranging*) utiliza sensores que operam na faixa de microondas, e existem diferentes tipos de radares para diversas aplicações.

Há dois tipos de sistemas de sensoriamento remoto por microondas: os *ativos* e os *passivos*. O termo ativo refere-se ao sensor que possui sua própria fonte de energia ou iluminação. Já o termo passivo refere-se aos radiômetros de microondas que captam níveis baixos de energia emitidos ou refletidos por alvos terrestres (Lillesand e Kiefer, 1987). Os radares imageadores são sensores de microondas ativos e, portanto, os mais utilizados em sensoriamento remoto.

Para o sensoriamento remoto, utilizam-se radares imageadores de visada lateral (*Side-Looking Airborne Radar* - SLAR), que podem ser radares de abertura real (*Real Aperture Radar* - RAR) ou de abertura sintética (SAR). A diferença entre o RAR e o SAR está basicamente no processamento do sinal retornado e na resolução azimutal dos dois sistemas. O RAR é o mais simples e sua resolução em azimute é uma função da distância entre o radar e o alvo e o comprimento da antena. O SAR é um sistema que, através de gravações e processamento dos sinais de retorno, cria uma antena virtual centena de vezes maior que o seu tamanho físico. Possui uma resolução azimutal boa que independe da distância entre o radar e o alvo. Detalhes sobre a geometria de aquisição de imagens RAR e SAR podem ser encontrados em Raney (1997) e Ulaby et al. (1982).

O princípio básico de funcionamento dos radares imageadores consiste na emissão da radiação eletromagnética direcionada à superfície terrestre e na gravação de intensidade e tempo de retardo da energia retroespalhada pelo alvo na superfície. Esta informação é transportada através de ondas eletromagnéticas que são definidas por: direção de

propagação, amplitude, comprimento de onda ( $\lambda$ ) ou freqüência, polarização e fase. Os radares utilizados em sensoriamento remoto emitem pulsos que se propagam à velocidade da luz. Estes pulsos são modificados pelos alvos de forma que o sinal de retorno (eco) traz informações sobre esses alvos. A razão entre a energia de microondas espalhada e a incidente é chamada de retroespalhamento ( $\sigma^o$ ). O retroespalhamento é governado pelas propriedades geométricas relacionadas com atributos da superfície dos alvos e propriedades dielétricas caracterizadas pela constante dielétrica do solo e da vegetação para um dado comprimento de onda (Moran et al., 2002).

Os radares imageadores operam num intervalo de comprimento de onda que varia de 5 a 75 cm no espectro eletromagnético e pode ser dividido em bandas representadas pelas letras K, X, C, S, L e P, como mostra a Figura 2.1.

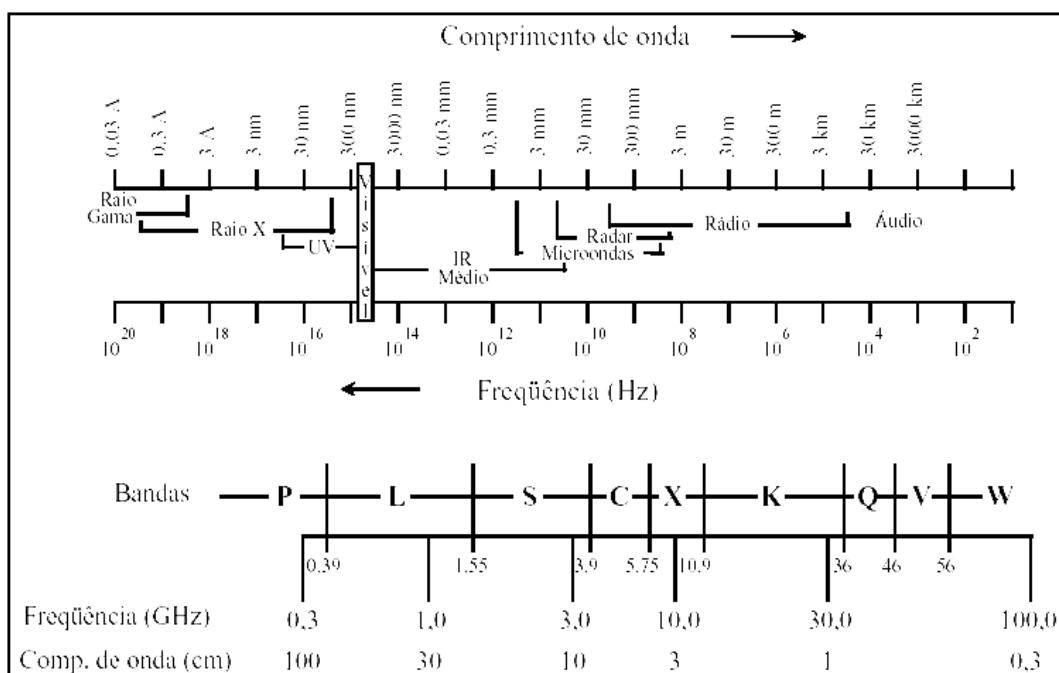


FIGURA 2.1 - Espectro eletromagnético e as bandas utilizadas na região de microondas.  
FONTE: Dallemand et al. (1993).

Uma importante característica das microondas é a capacidade de penetrar a atmosfera praticamente sob qualquer condição (chuva, neve, nuvens e fumaça), pois nesse intervalo as ondas eletromagnéticas são levemente atenuadas pela atmosfera (Figura

2.2), sendo especialmente interessante para diversas aplicações que envolvem a observação da terra.

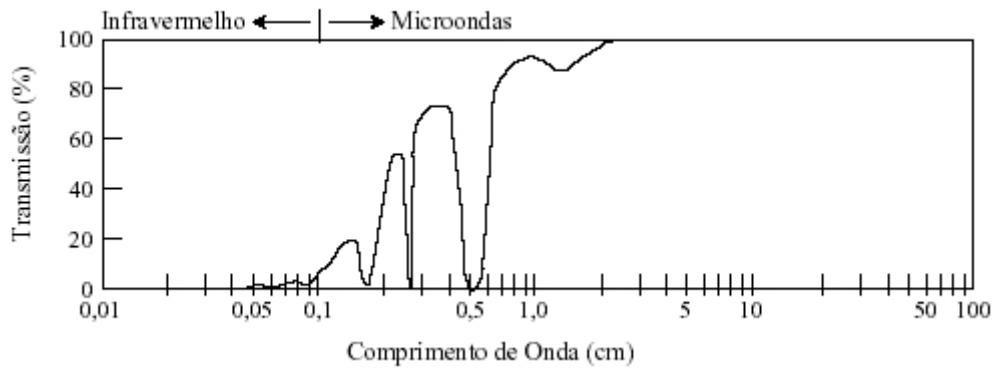


FIGURA 2.2 - Janelas de transmissão atmosférica na região de microondas.  
FONTE: Adaptada de Curlander e McDonough (1991).

Segundo Lewis e Henderson (1997), a equação do radar é uma relação entre os parâmetros do sistema, a geometria de propagação do pulso e as propriedades geométricas do alvo que determinam o sinal de retorno e o tipo de interação da energia incidente com os alvos. Os autores apresentaram a equação do radar de forma simplificada sem os termos que descrevem os efeitos da polarização, ângulo de visada, direção de visada, propriedades dielétricas do alvo, entre outros. Porém, a equação apresentada abaixo descreve a variação de tons de cinza numa imagem em função dos parâmetros básicos do sistema e do alvo, o que atende os conhecimentos requeridos para o desenvolvimento desse estudo. Uma descrição detalhada da equação do radar pode ser encontrada em Raney (1997) e Ulaby et al. (1982).

Se for considerado um pulso transmitido pelo radar e se for utilizada uma antena omnidirecional (isotrópica), a potência por unidade de área é definida pela razão da potência transmitida ( $P_T$ ) pela área da superfície de uma esfera imaginária de raio igual à distância em *range* ( $R_T$ ) ou  $4\pi R_T^2$ . Assim, o fluxo de potência transmitido ( $R$ ) pode ser calculado pela equação:

$$R = \frac{P_T}{4\pi R_T^2} \quad (2.1)$$

Quando a antena não é isotrópica, ou seja, quando possui uma direção preferencial para transmissão (radares de visada lateral), acrescenta-se um fator à equação, ( $G_T$ ) que se refere ao ganho da antena transmissora para uma dada direção. A equação que define o fluxo de potência nos alvos ( $P_A$ ) torna-se:

$$P_A = \frac{P_T G_T}{4\pi R_T^2} \quad (2.2)$$

Uma vez que o pulso de microonda atinge o alvo, o próximo parâmetro a ser considerado é o próprio alvo. A energia total interceptada pelo alvo é proporcional à área do mesmo ( $A_S$ ). Parte dessa energia incidente é absorvida ( $\alpha$ ) e o restante é refletido em todas as direções (isotrópico) ( $1 - \alpha$ ). Assim, o alvo atua como um difusor de energia, que é caracterizado pelo tamanho e geometria do mesmo. Quando este caminha em direção ao sistema de radar operante, há um ganho ( $g_s$ ). A equação que define os parâmetros do alvo mencionados acima se torna  $A_S(1 - \alpha)g_s$  e é geralmente associada a um parâmetro simples chamado de retroespalhamento ( $\sigma$ ).

$$\sigma = A_S(1 - \alpha)g_s \quad (2.3)$$

Quando a equação 2.2 e 2.3 são combinadas, a equação resultante define a potência total reirradiada pelo alvo em direção ao receptor ( $Pr$ ):

$$P_R = \frac{P_T G_T}{4\pi R_T^2} (\sigma) \quad (2.4)$$

O pulso retroespalhado definido na Equação 2.4 percorre a distância do alvo até o receptor ( $R_R$ ). Assim, o fluxo de potência no receptor é dividido por  $4\pi R_R^2$  e a equação torna-se:

$$R_R = \frac{P_T G_T}{4\pi R_T^2} (\sigma) \left( \frac{1}{4\pi R_R^2} \right) \quad (2.5)$$

A potência total recebida pelo sensor ( $P_R$ ) é a abertura efetiva ou área receptora da antena ( $A$ ) que atua como um receptor ( $A_R$ ). Quando o fator  $A_R$  é multiplicado pela equação anterior, torna-se:

$$P_R = \frac{P_T G_T}{4\pi R_T^2} (\sigma) \left( \frac{1}{4\pi R_R^2} \right) (A_R) \quad (2.6)$$

A Equação 2.6 é a equação do radar. Porém, a equação pode ser combinada e simplificada quando várias suposições são consideradas e algumas relações incorporadas. A primeira é considerar o fator  $A_R$  como o ganho ( $G$ ), a seguinte relação é introduzida:

$$A_R = A_T = A = \frac{\lambda^2 G}{4\pi} \quad (2.7)$$

sendo que  $\lambda$  é o comprimento de onda do sistema.

Esta relação é válida para radares monoestáticos, isto é, quando a mesma antena é usada tanto para transmitir como para receber a energia microonda ativa, o que ocorre com radares acoplados em plataformas orbitais e em aviões. Substituindo o fator  $A_R$  da equação anterior, a equação do radar torna-se:

$$P_R = \frac{P_T G_T}{4\pi R_T^2} (\sigma) \left( \frac{1}{4\pi R_T^2} \right) \left( \frac{\lambda^2 G_R}{4\pi} \right) \quad (2.8)$$

Para radares com difusor e receptor em localizações diferentes,  $G_T$ ,  $G_R$ ,  $R_T$  e  $R_R$  não são iguais. Porém, para radares monoestático esses parâmetros são iguais, isto é,  $R_T = R_R = R$  e  $G_T = G_R = G$ . Quando todos os parâmetros, exceto o retroespalhamento ( $\sigma$ ), estão relacionados ao sistema ou à geometria do radar para o pulso de microonda transmitido e recebido, a equação do radar torna-se:

$$P_R = P_T (\sigma) \left( \frac{G^2 \lambda^2}{(4\pi)^3 R^4} \right) \quad (2.9)$$

A equação acima descreve eficientemente a  $P_R$  de uma fonte pontual; porém, para radares de observação da terra aerotransportados e orbitais, a  $P_R$  está relacionada à potência de retorno a partir da área iluminada ( $A$ ) definida pela célula de resolução do sistema imageador. A fim de manter a independência do sinal e do alvo, o retroespalhamento ( $\sigma$ ) é redefinido como espalhamento por unidade de área ( $\sigma^o$ ), também conhecido como coeficiente de espalhamento. O retroespalhamento total de uma área ( $A$ ) torna-se ( $\sigma^o A$ ), e a forma final da equação do radar para um alvo extenso torna-se:

$$P_R = P_T (\sigma^o A) \left( \frac{G^2 \lambda^2}{(4\pi)^3 R^4} \right) \quad (2.10)$$

Os termos da equação do radar que descrevem o sistema e a geometria do sinal são descritos a seguir. A potência do sinal recebido ( $P_R$ ) é diretamente proporcional à potência do sinal transmitido ( $P_T$ ). O ganho ( $G$ ) e o comprimento de onda ( $\lambda$ ) elevado à segunda potência influenciam a  $P_R$  diretamente. A distância em *range* ( $R$ ) é inversamente proporcional à quarta potência de  $P_R$ . O termo ( $\sigma^o A$ ) da equação do radar refere-se aos parâmetros do alvo e está diretamente relacionado com a potência do sinal recebido ( $P_R$ ).

### 2.1.1 Interpretação de Imagens de Radar

Um dos maiores problemas na interpretação de imagens de radar é a presença do ruído *speckle*. A presença do *speckle* prejudica os aspectos radiométricos e texturais da imagem, o que dificulta a discriminação dos alvos. Reduzir o *speckle* significa melhorar a discriminação de diferentes tipos de alvos e faz com que tanto os classificadores digitais por *pixel* como os texturais apresentem melhores resultados em imagens de radar (Lopes et al., 1990). O efeito do ruído *speckle* é muito mais acentuado em imagens de abertura sintética (SAR) do que em imagens de abertura real (RAR).

As imagens SAR são formadas por uma interferência coerente entre os difusores que formam cada *pixel* da imagem. Como cada elemento de resolução é composto por um grande número de difusores, o sinal de retorno resulta da soma coerente do sinal

elementar retornado por cada um dos elementos difusores. Este processo causa flutuações aleatórias ou interferências que dão um aspecto granuloso característico às imagens SAR, o qual é conhecido como ruído *speckle*. Assim, torna-se difícil determinar se as variações no retroespalhamento para *pixels* homogêneos, ou seja, *pixels* com valores digitais próximos, são atribuídos às características do alvo ou ao ruído *speckle* (Lewis e Henderson, 1997).

Desse modo, as imagens SAR são geralmente processadas de forma a reduzir esse tipo de ruído característico através do processamento *multilook* ou multivisada.

O processamento *multilook* consiste em dividir a abertura sintética da antena em alguns setores (normalmente de 4 a 8), processando-os independentemente e somando-se em seguida cada um desses *looks*. Este processamento reduz o efeito do *speckle*, mas causa a diminuição da resolução espacial pelo mesmo fator, o que resulta numa relação inversa entre o efeito do *speckle* e a resolução espacial. Uma imagem SAR de um *look*, por exemplo, contém efeito de *speckle* acentuado. Já uma imagem de 3 ou 4 *looks* contém efeito de *speckle* reduzido, mas com resolução espacial inferior.

Uma outra maneira de reduzir o *speckle* é a utilização de filtros em imagens já processadas. Os filtros convolucionais simples (Média e Mediana, por exemplo) e os pontuais adaptativos são os mais utilizados e têm a vantagem de minimizar o efeito do ruído *speckle* sem comprometer a resolução espacial.

Segundo Lopes et al. (1990), os filtros adaptativos são os mais apropriados, pois estes preservam as informações radiométricas e de textura da imagem mais eficientemente, isto é, os valores de retroespalhamento e as bordas de regiões diferentes em áreas homogêneas (ex. áreas agrícolas). Já em áreas heterogêneas (ex. áreas de floresta), os filtros preservam a informação radiométrica e a variabilidade espacial do sinal.

Os filtros adaptativos são baseados nos cálculos da média e da variância dos níveis de cinza de uma janela posicionada na imagem (Mather, 1999). Entre os filtros adaptativos mais utilizados, destacam-se os filtros Frost, Lee, Sigma, Kuan e Gamma.

## 2.1.2 Interação das Microondas com Alvos Agrícolas

Para o melhor entendimento do retroespalhamento ( $\sigma^o$ ) de alvos agrícolas, é necessário estudar os parâmetros do sistema sensor em função dos próprios alvos agrícolas. Os parâmetros do sistema são governados basicamente pelo comprimento de onda, polarização e ângulo de incidência. Já os parâmetros do alvo pelas propriedades geométricas e elétricas dos alvos (Brisco e Brown, 1997). Outros parâmetros que influenciam no retroespalhamento, tais como resolução em *range* e azimute, largura de cobertura, comprimento do pulso, potência do transmissor e largura de bandas são de importância secundária e não serão tratados aqui.

### 2.1.2.1 Parâmetros do Sistema Sensor

Para alvos agrícolas, a magnitude do retroespalhamento é função direta da freqüência, da polarização e do ângulo de incidência.

O poder de penetração da onda também é função do comprimento de onda, ou seja, quanto maior o comprimento de onda, maior o poder de penetração num alvo agrícola. Uma superfície pode ser considerada lisa ou rugosa segundo o critério de Rayleigh se:

$$h < \frac{\lambda}{8\cos\theta} \text{ ou } h < \frac{c}{8\cos\theta} \frac{1}{f} \quad (2.11)$$

onde  $h$  é a altura média das variações da superfície,  $\lambda$  é o comprimento de onda,  $c$  é a velocidade da luz,  $f$  é a freqüência, e  $\theta$  é o ângulo de incidência. Assim, para a banda L ( $\lambda = 23,5$  cm) e ângulo de visada de  $21^\circ$ , uma superfície será rugosa se  $h$  for igual ou maior que 3,1 cm.

Comprimentos de onda menores, como as bandas X e K, em geral são dominados pelo retroespalhamento do dossel, enquanto que para comprimentos de onda maiores, como as bandas L e P são dominados pelo retroespalhamento do solo (Brisco e Brown, 1997). A Figura 2.3 ilustra três níveis de retroespalhamento num dossel agrícola.

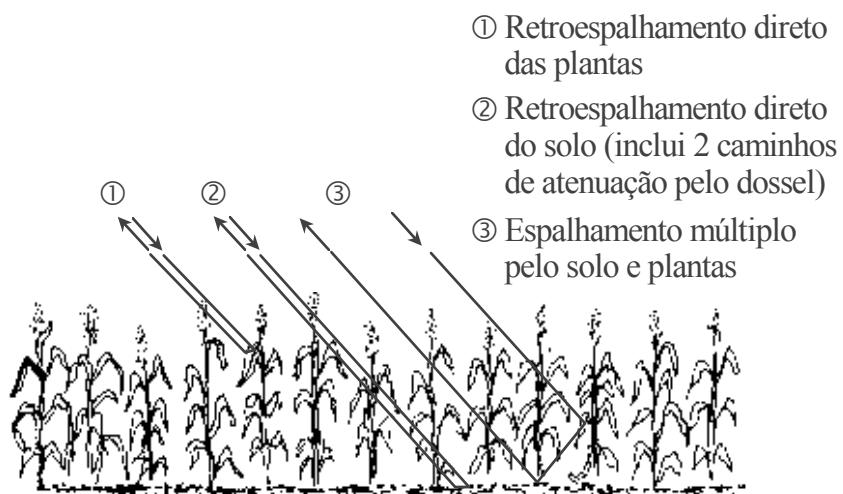


FIGURA 2.3 - Contribuições do retroespalhamento de um dossel agrícola.  
FONTE: Ulaby et al. (1984, p. 115).

A polarização é outro parâmetro importante que influencia o retroespalhamento de alvos agrícolas. A polarização refere-se à direção do campo elétrico na onda eletromagnética, que pode ser orientada horizontalmente (H) ou verticalmente (V). Existem quatro combinações lineares possíveis de polarização: HH, VV, HV e VH. As polarizações HH e VV são chamadas de polarizações lineares paralelas horizontal e vertical respectivamente. Atualmente são as mais utilizadas em SARs orbitais. A primeira letra refere-se à polarização da radiação transmitida pela antena e a segunda à polarização recebida pela antena. As polarizações HV e VH são chamadas de polarizações cruzadas e, até o momento, não estão disponíveis em sensores orbitais operacionais. Segundo Brisco e Brown (1997), em geral, a polarização cruzada separa alvos agrícolas mais eficientemente do que as lineares.

O efeito do ângulo de incidência sobre o retroespalhamento de alvos agrícolas também é função dos efeitos da freqüência e polarização. O ângulo de incidência pode ser definido como aquele formado entre a linha de visada do radar com a vertical local. Em geral, os ângulos de incidência menores que  $30^\circ$  têm sido mais utilizados para estimar umidade do solo devido à diminuição dos efeitos da rugosidade e atenuação da vegetação, enquanto que ângulos de incidência maiores que  $40^\circ$  aumentam o trajeto da radiação através da vegetação, maximizando sua resposta. Ângulos de incidência maiores são melhores na discriminação de culturas agrícolas (Brisco e Brown, 1997). Neste

contexto, as imagens de radar utilizadas nesse estudo foram adquiridas a partir de ângulos de incidência maiores que 40°.

### **2.1.2.2 Parâmetros do Alvo**

Segundo Ulaby et al. (1984), as características geométricas e dielétricas de culturas agrícolas e dos solos influenciam a interação das microondas com os alvos agrícolas e determinam a magnitude do retroespalhamento. As propriedades dielétricas controlam a magnitude do espalhamento e a atenuação do sinal, determinando a proporção da energia incidente que é transmitida, absorvida e espalhada. As propriedades geométricas controlam a distribuição espacial do espalhamento, determinando em que direção do espaço tridimensional o espalhamento se dá preferencialmente (Dobson et al., 1995).

Brisco e Brown (1997) ressaltaram que estas duas características influenciam o retroespalhamento simultaneamente, sendo quase sempre necessários trabalhos de campo para o entendimento do efeito que os fatores geométricos e dielétricos exercem separadamente sobre o retroespalhamento.

A quantidade de energia que é transmitida, absorvida e espalhada é grandemente influenciada pelas propriedades elétricas do meio. O parâmetro que quantifica essa propriedade é a constante dielétrica relativa  $\epsilon_r$ . A constante dielétrica é um número complexo e possui uma parte real e uma imaginária, conforme descrita abaixo:

$$\epsilon_r = \frac{\epsilon_c}{\epsilon_0} = \epsilon_r' - j\epsilon_r'' \quad (2.12)$$

onde  $\epsilon_c$  é a constante dielétrica do material e  $\epsilon_0$  é a constante dielétrica do vácuo. A parte real  $\epsilon_r'$  rege a energia transmitida e espalhada. Em combinação com  $\epsilon_r'$ , a parte imaginária  $\epsilon_r''$  determina a quantidade de energia absorvida. A constante dielétrica relativa é a constante dielétrica do meio normalizada pela constante dielétrica do vácuo. Os valores para  $\epsilon_r'$  e  $\epsilon_r''$  dependem das características intrínsecas do meio, isto é, tipo e proporção dos seus componentes, e dos fatores externos, tais como, o comprimento de onda e temperatura. Ulaby e Jedlicka (1984) ressaltaram que a umidade do solo e da

planta, o comprimento de onda e o ângulo de incidência são os principais fatores que influenciam as propriedades dielétricas dos alvos.

Entre os principais fatores geométricos que controlam o retroespalhamento do dossel podem-se destacar: o Índice de Área Foliar (IAF); a largura, espessura e comprimento da folha; a altura, o diâmetro e a densidade do caule; o estádio fenológico; a direção de plantio, o espaçamento e a porcentagem de cobertura. Para o solo, os fatores que governam o retroespalhamento são a rugosidade e a constante dielétrica do solo.

Brisco e Brown (1997) ainda ressaltaram que tanto os fatores dielétricos como os geométricos devem ser considerados em função do comprimento de onda, polarização e ângulo de incidência, a saber:

- O espalhamento varia se o comprimento de onda incidente for maior ou menor que o objeto;
- A influência da direção de plantio e das estruturas verticais do dossel no retroespalhamento variam com a polarização;
- A maior ou menor influência do dossel e do solo no retroespalhamento é função do ângulo de incidência.

## 2.2 Descrição do RADARSAT-1

O RADARSAT-1 é o primeiro satélite de recursos naturais da Terra do Canadá e foi lançado no dia 4 de novembro de 1995, com vida útil prevista de 5 anos. O RADARSAT-1 utiliza um sensor SAR de frequência única (banda C-5,6 cm) e polarização linear paralela horizontal HH. O RADARSAT-1 permite a aquisição de imagens em diferentes resoluções podendo variar o ângulo de incidência ajustável de acordo com a aplicação (Tabela 2.1 e Figura 2.4).

TABELA 2.1 - Modos de imageamento do RADARSAT-1.

Modo	Resolução nominal (m)	Numero de <i>looks</i>	Largura da faixa (km)	Angulo de incidência (°)
Fino	8	1	45	37-47
Standard	30	4	100	20-49
Largo	30	4	150	20-45
Scan SAR estreito	50	2-4	300	20-49
Scan SAR largo	100	4-8	500	20-49
Extendido alto	18-27	4	75	52-58
Extendido baixo	30	4	170	10-22

FONTE: RADARSAT Internacional (1995).

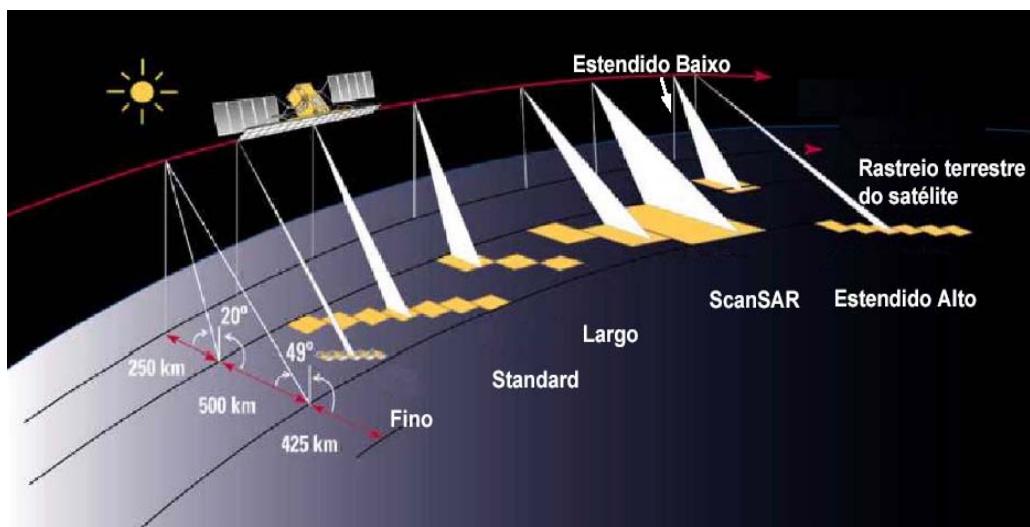


FIGURA 2.4 - Módulos de imageamento do RADARSAT-1.

FONTE: CCRS (2003).

A órbita do RADARSAT-1 é quase-polar e sol síncrona, permitindo a exposição dos painéis solares à luz solar em tempo integral, dispensando o uso de baterias. O período de revisita do RADARSAT-1 é de 24 dias, podendo chegar a 3 dias em baixas latitudes e 6 dias na região equatorial, dependendo do ângulo de visada. Sua altitude é de 798 km, com inclinação da órbita de 98,6 graus. O satélite circula a Terra 14 vezes ao dia e uma órbita completa dura 100,7 minutos. A aquisição de dados pode durar 28 minutos em cada órbita (Tabela 2.2).

TABELA 2.2 - Parâmetros de imageamento do RADARSAT-1.

Parâmetros	Especificações
Freqüência	5,3 GHz
Comprimento de onda	5,6 cm - banda C
Polarização	HH
Ângulo de incidência	10° a 60°
Resolução em range (produtos em <i>ground range</i> )	8 a 100 m
Resolução em azimute (produtos em <i>ground range</i> )	8 a 100 m
Resolução temporal	24 dias
Faixa de imageamento	50 a 500 km
Número de órbitas por dia	14
Altitude	798 km
Inclinação da plataforma	98,6°
Órbita	Circular, quase-polar, sol síncrona
Tamanho da antena	15 x 1,5 m
Vida útil	5 anos

FONTE: RADARSAT Internacional (1995).

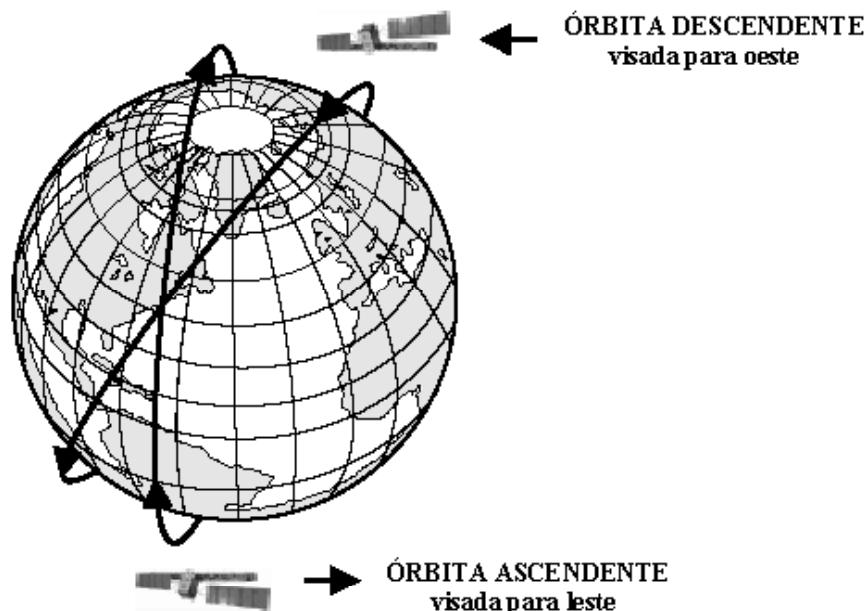


FIGURA 2.5 - Órbitas ascendente e descendente do RADARSAT-1.  
FONTE: RADARSAT Internacional (1995).

O RADARSAT-1 pode adquirir imagens tanto na órbita ascendente, com visada para leste, quanto na órbita descendente, com visada para oeste (Figura 2.5). Isto pode ser de

grande utilidade em regiões que tenham feições com orientações preferenciais, como ocorre em áreas agrícolas, por exemplo, que podem ser suprimidas se o alinhamento é paralelo à direção de visada, além de outras utilidades.

A passagem do satélite RADARSAT-1 sobre um mesmo ponto geográfico ocorre em dois horários diferentes durante o dia. Quando a passagem se dá na órbita descendente, o satélite cruza o Equador por volta das 6:00h da manhã (horário local). Se a passagem for ascendente, o satélite cruza o Equador por volta das 6:00h da tarde (horário local).

Os dados gerados e distribuídos para os usuários podem ser desde aqueles não processados de nível 0 (dado bruto) até imagens processadas ortorretificadas. Ao todo, estão disponíveis sete níveis de processamento representados pelas siglas RAW, SLC, SGF, SGX, SSG, SPG e ORI. O tipo de dado a ser escolhido deve corresponder às necessidades do usuário. As imagens utilizadas nesse trabalho correspondem ao nível de processamento SGF, isto é, as imagens são do tipo *ground range*, quantizada em 16 bits (imagem amplitude). As imagens RADARSAT-1 já são distribuídas com a correção do padrão da antena.

Os dados do RADARSAT-1 estão disponíveis no formato CEOS (*Committee on Earth Observation Satellites*) e corresponde a um formato próprio que contém cinco arquivos, sendo que um contém a imagem e os demais são referentes ao processamento da imagem (dados radiométricos, altitude, posição da plataforma, entre outros).

### **2.3 Utilização de Imagens RADARSAT-1 em Aplicações Agrícolas**

As imagens RADARSAT-1 podem ser adquiridas sob condições de nuvens, e o satélite pode ser programado para coletar imagens numa ampla faixa de modos e ângulos de incidência. Esta flexibilidade aumenta a resolução temporal e assegura que as imagens podem ser adquiridas durante períodos chaves da fase de crescimento das culturas agrícolas. Os usuários também têm a flexibilidade de escolher as aquisições tanto para órbitas ascendentes como descendentes (Wood et al., 2002). Desde o lançamento do RADARSAT-1 vários estudos têm sido realizados para maximizar a discriminação e

identificação de culturas agrícolas utilizando diferentes combinações e configurações de imagens.

McNairn et al. (1998) avaliaram as mudanças do retroespalhamento de culturas agrícolas na fase de máximo desenvolvimento utilizando imagens RADARSAT-1 adquiridas no mês de julho com os ângulos de 37° (modo *Standard 4*), 24° (modo *Standard 1*) e 41° (modo *Fine 2*). Eles confirmaram a variação do retroespalhamento das culturas agrícolas analisadas em função do ângulo de incidência (Figura 2.6). As culturas de canola, feijão e girassol apresentaram pouca mudança no retroespalhamento. Isto pode ser resultado da estrutura foliar larga e horizontal e da pouca mudança fenológica das culturas durante a aquisição das imagens. As culturas de cevada, aveia e trigo apresentaram maiores mudanças no retroespalhamento principalmente para os ângulos de 37° e 41° devido às maiores mudanças fenológicas dessas culturas no período de aquisição das imagens. Assim, os efeitos causados pelas variações nos ângulos de incidência das imagens RADARSAT-1, podem ser compensados com a aplicação de um fator de correção simples como o proposto pelos autores.

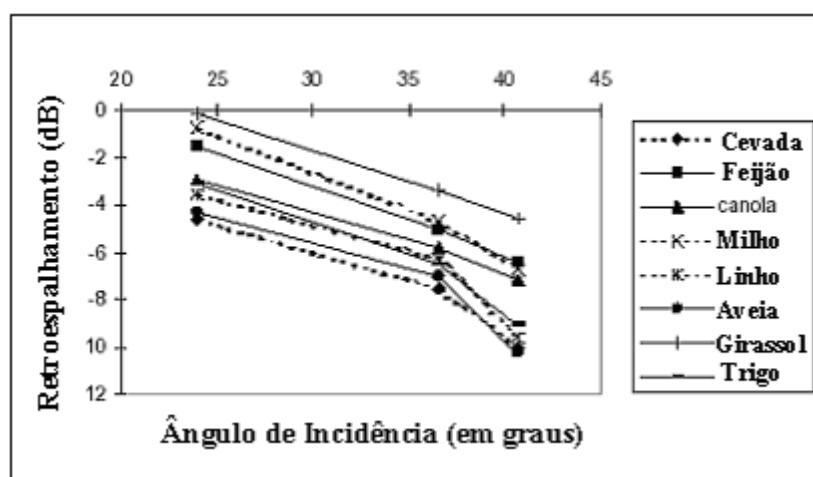


FIGURA 2.6 - Variação do retroespalhamento em função do ângulo de incidência.  
FONTE: Adaptado de McNairn et al. (1998).

Panigrahy et al. (1999) utilizaram quatro imagens RADARSAT-1 no modo *Standard 7* para avaliar a descriminação de culturas de arroz e batata adquiridas ao longo da estação de crescimento. Os resultados indicaram que os retroespalhamentos mais baixos

ocorreram durante o período inicial de crescimento da cultura de arroz sobre campos alagados devido à maior influência da água e foi aumentando conforme o desenvolvimento da cultura (variou de – 18 dB a – 8 dB). A precisão da classificação das áreas de arroz foi de 94% com a utilização das quatro imagens RADARSAT-1 e de 92% com a utilização de duas imagens, uma adquirida no começo e outra no fim da estação de crescimento.

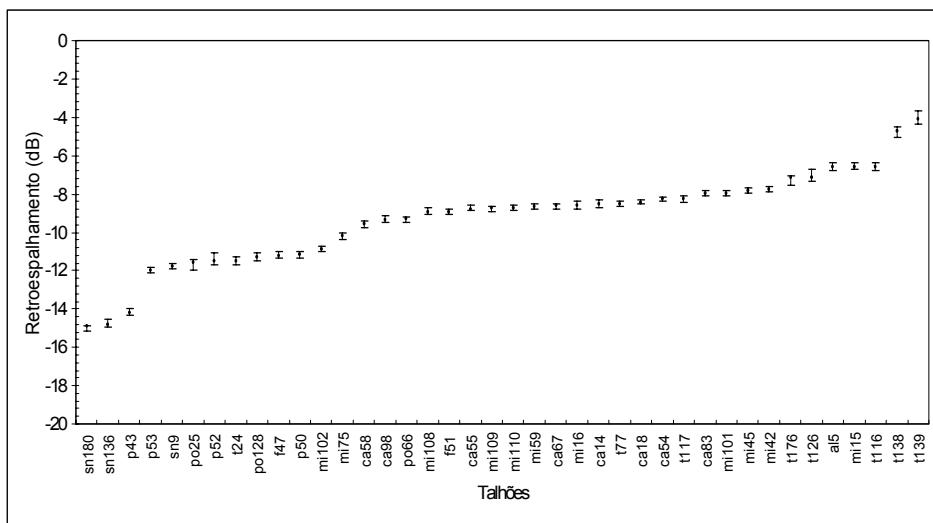
Para a cultura da batata, os retroespalhamentos variaram de – 9 dB a –6 dB durante a fase de crescimento, com variações amplas durante o começo da fase vegetativa. Os solos parcialmente cobertos pelo dossel apresentaram altos valores de retroespalhamento devido à influência da umidade do solo. Quando o solo estava completamente coberto pelo dossel, ocorreram valores mais baixos de retroespalhamento. Os autores concluíram que as imagens RADARSAT-1 adquiridas ao longo da estação de crescimento das culturas de arroz e batata apresentaram resultados satisfatórios, apresentando retroespalhamentos característicos para a cultura de arroz em cada imagem RADARSAT-1.

Presutti et al. (2001) testaram uma metodologia para mapear culturas agrícolas a partir da classificação de imagens texturais e espectrais do RADARSAT-1 e Landsat TM, respectivamente, no sul da província de Buenos Aires, Argentina. Os resultados indicaram que a tonalidade e a textura das imagens RADARSAT-1 melhoraram a classificação em aproximadamente 10%, quando comparadas às classificações das imagens originais. O resultado geral da classificação foi de aproximadamente 62% de acerto (95% de intervalo de confiança igual a 57,8% - 66,5%). Para a cultura do trigo, a de maior interesse no estudo, o acerto foi de 81% na classificação.

Formaggio et al. (2001) utilizaram três passagens do RADARSAT-1 (modo Fine 4 descendente) para agrupar os valores de retroespalhamento representativos das diversas condições de talhões agrícolas em uma região intensamente cultivada. Através de um diagrama de dispersão de valores de retroespalhamento (Figura 2.7), os autores verificaram a existência de três grandes regiões: uma caracterizada por áreas de superfície lisa de baixos valores de retroespalhamento (valores menores que –11 dB) e

constituída por solo exposto, solo preparado, pousio e pastagens; a segunda, com valores de retroespalhamento intermediários (entre -11 e -7 dB) e constituída por culturas de milho e cana-de-açúcar bem desenvolvidas; e uma terceira, com altos valores de retroespalhamento (maiores que -7 dB), constituída por superfícies muito rugosas, particularmente quando os sulcos de plantio eram perpendiculares à direção de visada do satélite.

Os autores concluíram que, em geral, não se verificou um padrão de retroespalhamento que pudesse ser utilizado para discriminar culturas agrícolas bem desenvolvidas, como observado entre a cultura de milho e de cana-de-açúcar, por exemplo.



**FIGURA 2.7** - Valores de retroespalhamento para cada área em março. As letras indicam o uso: sn (solo exposto), mi (milho), a (algodão), po (pousio), ca (cana-de-açúcar), t (tomate) e sp (solo preparado).

FONTE: Adaptado de Formaggio et al. (2001).

Wood et al. (2002) analisaram o efeito do orvalho no retroespalhamento de culturas agrícolas utilizando imagens nas órbitas ascendente (passagem noturna) e descendente (passagem diurna) do RADARSAT-1. Eles observaram que houve um aumento médio significativo de 2,5 dB no retroespalhamento devido à presença do orvalho no dossel das imagens descendentes (Figura 2.8).

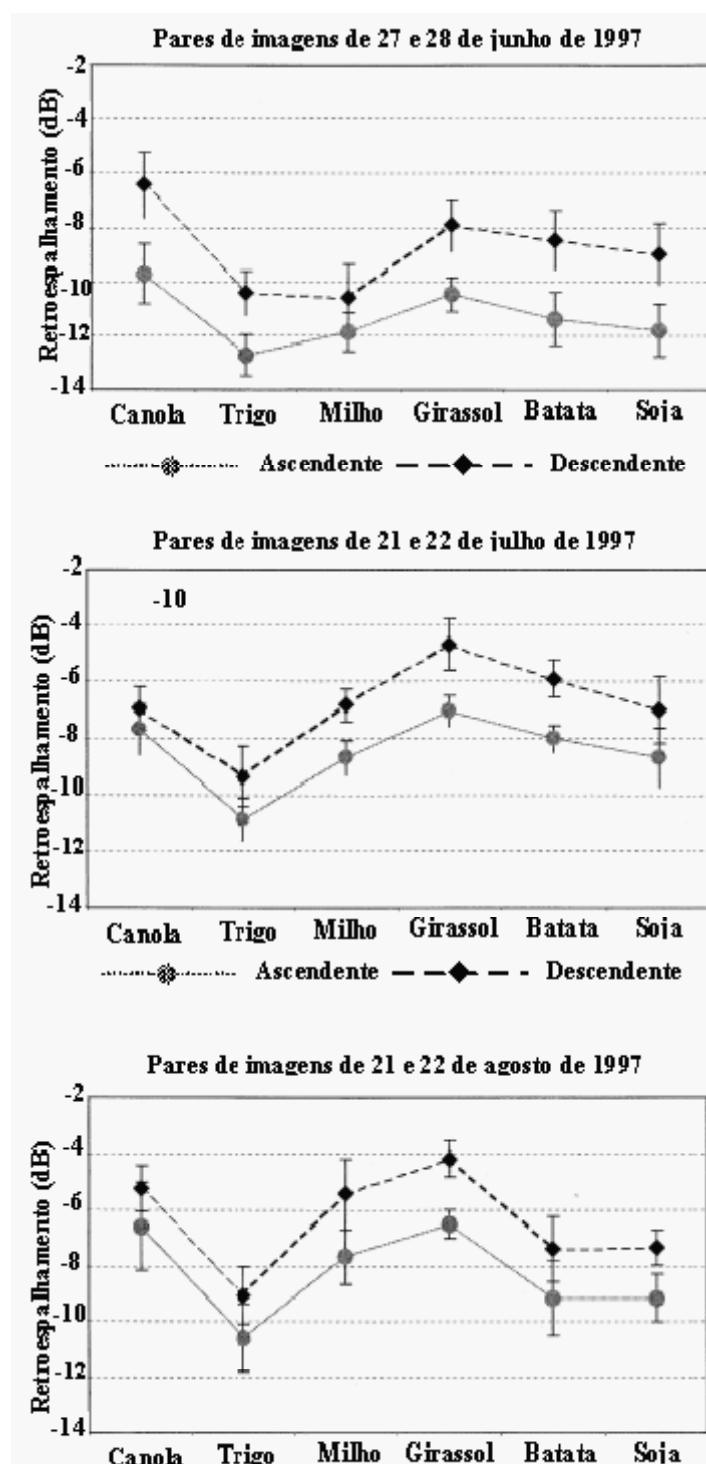


FIGURA 2.8 - Retroespalhamento médio de culturas agrícolas para pares de imagens RADARSAT-1 ascendente e descendente. A variação do retroespalhamento em cada cultura é indicada pela barra de erro.  
FONTE: Adaptada de Wood et al. (2002).

Apesar disso, os autores concluíram que, em geral, as mudanças no retroespalhamento entre as passagens ascendente e descendente foram similares para os vários tipos de cultura. Assim, a presença do orvalho no dossel não afetou a discriminação entre as culturas. Quando comparados todos os pares de imagens utilizados no estudo, as culturas de estrutura foliar larga como girassol, batata, soja e milho, apresentaram maiores mudanças no retroespalhamento do que as culturas de estrutura foliar menor como canola e trigo. Segundo os autores, a presença de orvalho em culturas de estrutura foliar larga é mais intensa do que em culturas de estrutura foliar menor.

McNairn et al. (2002) analisaram o potencial de imagens RADARSAT-1 (modos *Standard* e *Fine*) para mapear diferentes tipos de culturas agrícolas (canola, trigo, cevada, aveia, girassol, soja, milho, batata e linho), identificar as melhores datas de aquisição das imagens e determinar o impacto das variações da fase de crescimento vegetativo das culturas no mapeamento das mesmas.

Para o mapeamento, os resultados indicaram que a utilização de imagens RADARSAT-1 adquiridas em várias datas apresentaram resultados precisos, independentemente da utilização complementar de imagens de satélites ópticos. As melhores classificações foram obtidas com as imagens adquiridas nos períodos em que as culturas se encontravam na fase de máximo desenvolvimento vegetativo, com exceção da cultura de canola. Segundo os autores, a menor influência do solo no retroespalhamento total e, consequentemente, a maior interação das microondas com o dossel resulta na maximização da discriminação das culturas.

Os autores avaliaram a discriminação das culturas sobre uma única imagem RADARSAT-1 e concluíram que as culturas de estrutura foliar larga (girassol e milho, por exemplo) se diferenciaram das culturas de estrutura foliar menor (trigo e cevada, por exemplo). Entretanto, os retroespalhamentos entre as culturas de mesma estrutura foliar foram similares. Neste caso, não foi possível a discriminação das mesmas sobre uma única imagem RADARSAT-1.

A variação nos coeficientes de retroespalhamento em função da fase de crescimento vegetativo das culturas foi evidente, principalmente devido aos efeitos da umidade e das

mudanças na estrutura do dossel como mostra a Figura 2.9. Para as culturas de grãos (trigo, aveia, soja, milho e cevada) os retroespalhamentos diminuíram na fase reprodutiva. Para cultura de canola, houve um aumento do retroespalhamento na fase de florescimento até a formação de vagens.

Para as correlações do retroespalhamento com as variáveis das culturas (Índice de Área Foliar - IAF, altura e biomassa seca e verde), os autores concluíram que a altura e o IAF foram as que apresentaram maior correlação positiva com o retroespalhamento.

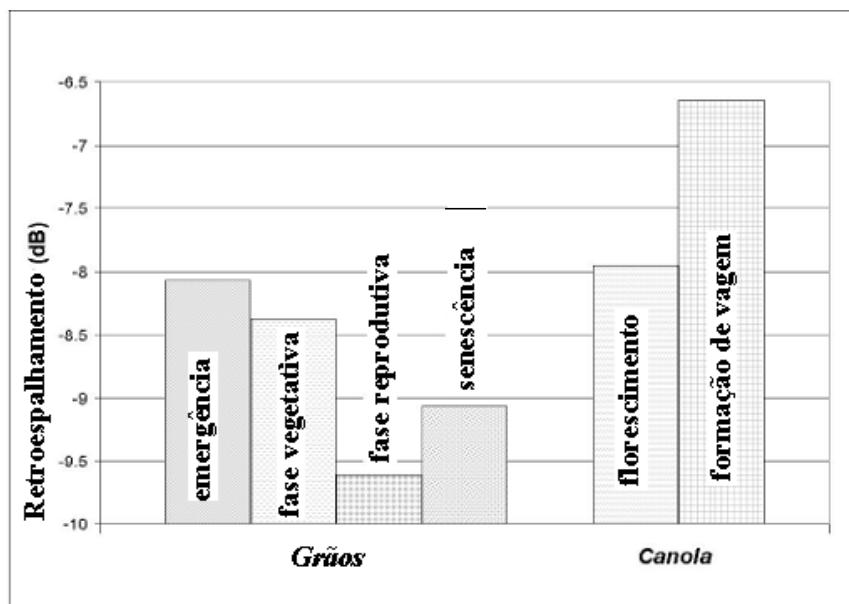


FIGURA 2.9 - Variação do retroespalhamento em função da fase de crescimento de culturas de grãos e canola. Estes valores médios de retroespalhamento foram derivados da imagem RADARSAT-1 modo *Fine* adquirida em 22 de julho de 1997.

FONTE: Adaptada de McNairn et al. (2002).

Baghdadi et al. (2002) investigaram o potencial de imagens SAR para mapear a rugosidade de talhões de solo em áreas agrícolas. Foram avaliadas as variáveis que influenciam no retroespalhamento, isto é, o ângulo de incidência, a rugosidade da superfície do solo e a direção de plantio em relação à geometria de imageamento para determinar a melhor configuração de imagens de radar SAR. Duas imagens RADARSAT-1 (*Standard 5* (39°) descendente e *Fine 5* (47°) ascendente) e uma imagem ERS (23°) foram utilizadas.

Os resultados indicaram uma alta correlação positiva do retroespalhamento com o ângulo de incidência na discriminação de diferentes classes de rugosidade do solo. As imagens RADARSAT-1 (ângulos de incidência maiores) apresentaram maior correlação com a direção de plantio quando comparada à imagem ERS (ângulo de incidência menor). Entretanto, o retroespalhamento nas imagens RADARSAT-1 foi mais intenso em função dos efeitos da rugosidade do solo do que os efeitos da umidade e direção de plantio.

Análises estatísticas indicaram que apenas a imagem RADARSAT-1 *Fine* ( $47^\circ$ ) foi adequada para o mapeamento de classes de rugosidade. Limiares baseados em 37 amostras de treinamento foram escolhidos considerando as médias de diferentes categorias para um nível de 99% de confiança: áreas lisas ( $\sigma^0 < -13\text{dB}$ ), áreas de rugosidade média ( $-13\text{ dB} \leq \sigma^0 \leq -11,5\text{ dB}$ ) e áreas rugosas ( $\sigma^0 > -11,5\text{ dB}$ ). Estes limiares foram então usados para classificar solos expostos sobre toda a área de estudo. Um classificador *pixel a pixel* foi utilizado e, para as três classes de solo exposto (lisa, média e rugosa), a precisão da classificação geral foi de 85,3%.

Os autores concluíram que o coeficiente de retroespalhamento em solos rugosos aumenta com o ângulo de incidência e, neste caso, as imagens adquiridas em ângulos de incidência maiores (RADARSAT-1) apresentam os melhores resultados.

## 2.4 Classificação de Imagens Orbitais

A classificação digital de imagens orbitais consiste no estabelecimento de um processo de decisão no qual um grupo de *pixels* é definido como pertencente a uma determinada classe ou a um tema que descreve um objeto no mundo real (Venturieri e Santos, 1998). O resultado de uma classificação é uma imagem temática, onde os *pixels* classificados são representados por símbolos gráficos ou cores definidos pelo usuário.

Lillessand e Kiefer (1987) definiram classificação digital como sendo os procedimentos de categorização automática de todos os *pixels* de uma imagem, atribuindo um rótulo para cada *pixel* que contenha informações de um objeto do mundo real.

Segundo Moreira (2001), a caracterização (rotulação) dos valores dos níveis de cinza é feita utilizando algoritmos estatísticos (programas computacionais) de reconhecimento de padrões espectrais. Dependendo do algoritmo utilizado, a classificação pode ser supervisionada ou não-supervisionada.

#### **2.4.1 Classificação Supervisionada**

Segundo Dutra et al. (1981), a classificação supervisionada utiliza algoritmos de classificação que necessitam de uma fase de treinamento, na qual o sistema determina, a partir de padrões pré-selecionados, chamados amostras de treinamento, as características das classes a serem usadas como termo de comparação na classificação. O algoritmo classificador utiliza parâmetros estatísticos referentes às amostras representativas de cada classe na classificação dos demais *pixels* da imagem. Os *pixels* referentes às amostras são, então, exemplos que o classificador utiliza como treinamento para determinar a qual classe cada *pixel* da imagem será atribuída. Assim, para que a classificação apresente um bom resultado, é fundamental que as amostras de treinamento sejam homogêneas e representativas das classes de interesse.

No contexto do sensoriamento remoto, as amostras de treinamento representam os objetos ou classes que correspondem aos alvos da superfície terrestre, como florestas, corpos d'água, pastagens, culturas agrícolas e outros tipos de uso do solo (Mather, 1999).,

Entre os métodos interativos de classificação, os mais comumente utilizados são os classificadores Paralelepípedo (*Single Cell*) e o classificador por Máxima Verossimilhança (*Maximum Likelihood*) ou MAXVER (Lillesand e Kiefer, 1987).

O método da classificação por MAXVER baseia-se no cálculo da distância estatística entre cada *pixel* e a média dos níveis de cinza da classe previamente definida a partir de amostras de treinamento (Dutra et al., 1981). Mather (1999) destacou que a classificação por MAXVER tem por base a estimativa da média do vetor e da matriz de variância/covariância dos níveis de cinza de cada classe.

Este classificador utiliza, então, a distância estatística entre cada *pixel* e a média dos níveis de cinza da classe, avaliando, assim, a probabilidade que cada *pixel* tem de pertencer a cada uma das classes identificadas e o designa àquela cuja probabilidade é maior (Dutra et al., 1981). A probabilidade de um dado *pixel* pertencer a uma das classes predefinidas é calculada por uma função de probabilidade  $P(x)$ . O cálculo é realizado para o conjunto de classes que intervêm na classificação temática. Em resumo, o *pixel* é atribuído àquela classe que maximiza a função de probabilidade (Mather, 1999).

#### 2.4.1.1 O Classificador MAXVER-ICM

Como o classificador MAXVER é do tipo *pixel-a-pixel*, ou seja, cada *pixel* é classificado independentemente dos *pixels* vizinhos, este classificador geralmente apresenta baixo desempenho em imagens SAR devido à alta variância introduzida pelo ruído *speckle* (Ahern, 1995). Além disso, a maior parte dos sistemas de classificação disponíveis se baseia na hipótese de que os dados possuem distribuição normal, hipótese esta raramente observada em imagens SAR (Vieira et al., 1997).

Verifica-se, assim, a necessidade de desenvolver técnicas e procedimentos estatísticos específicos para a análise e classificação de imagens SAR (Vieira et al., 1997) que complementem o método MAXVER. Segundo os autores, o MAXVER não leva em conta a informação contextual, supondo que as radiometrias dadas às classes são eventos independentes. A incorporação das informações contextuais aos algoritmos classificadores que só consideram as informações no domínio espacial surge então como uma alternativa promissora para a classificação de imagens de radar.

Assim, alguns modelos que incorporam a informação contextual têm sido propostos, mas a grande maioria deles, apesar de permitirem uma maior flexibilidade, envolvem muita complexidade computacional (Frery, 1993). Uma versão de algoritmo de classificação contextual foi apresentada por Frery (1993), que tem características de desempenho e facilidade de uso, sendo denominado “Iterated Conditional Modes” (ICM). Este algoritmo foi aprimorado por Vieira (1996): o tempo de processamento foi diminuído e a implementação pelo usuário tornou-se mais amigável. Para aplicá-lo, o

usuário não necessita de mais conhecimentos que os requeridos para utilizar o método de classificação MAXVER.

O algoritmo ICM é um método interativo de refinamento de classificações e consiste em substituir a classe associada a cada coordenada pela classe que maximiza um determinado critério. Esse critério é a distribuição a posteriori da classe, dadas a radiometria (componente MAXVER) e as classes vizinhas (componente de contexto). A influência das classes vizinhas é quantificada por um parâmetro real, que é estimado iterativamente supondo um modelo para a distribuição espacial das classes (Vieira et al., 1997). As descrições matemáticas e os modos de implementações do algoritmo ICM tornam-se impraticáveis aqui. Assim, mais detalhes sobre o ICM, que abrangem formalidades estatísticas, bem como outras referências que tratam do tema, podem ser encontradas em Frery (1993) e Vieira (1996).

## 2.5 Análise de Textura

Os quatro elementos mais importantes na interpretação humana de imagens em geral e, em particular, nas imagens de radar são: espectral, textural, temporal e contextual. O elemento espectral descreve as variações tonais médias banda a banda numa imagem multiespectral, enquanto que o elemento textural descreve a distribuição espacial dos valores tonais numa banda. O elemento contextual contém informações sobre o arranjo relativo de grandes segmentos pertencentes a categoriais diferentes e o elemento temporal descreve as mudanças nos atributos da imagem em função do tempo, ou seja, das diferentes datas de aquisição das imagens (Frost et al., 1984).

Segundo Haralick et al. (1973), a textura e a tonalidade estão sempre presentes em uma imagem e são propriedades intrinsecamente relacionadas, embora uma propriedade possa dominar sobre a outra. Quando uma área pequena de uma imagem tem pouca variação de níveis de cinza, a propriedade dominante é a tonalidade, caso contrário, a propriedade dominante é a textura. A textura pode ser definida como sendo a variabilidade de tons de cinza vizinhos ou o padrão das relações espaciais entre os níveis de cinza dos *pixels* vizinhos (Mather, 1999). Pode ser rugosa, se o padrão espacial for bem definido por conter várias células de resolução, ou lisa, se não houver

padrão espacial e a variação do tom de cinza entre as feições for ampla (Haralick et al., 1973).

Para imagens de radar, a textura refere-se ao grau de rugosidade ou homogeneidade de uma área da imagem e está relacionada com a rugosidade da superfície. A variação de textura numa imagem radar é função do comprimento de onda, resolução espacial e ângulo de incidência do sistema, assim como da disposição e composição das características ambientais (Lewis e Henderson, 1997). Segundo estes autores, os componentes de textura nas imagens de radar podem ser de três tipos: micro, meso e macro. A micro-textura é inerente ao sistema do radar e está associada ao *speckle* da imagem. A meso-textura é caracterizada pela variação média do retroespalhamento na escala de um elemento de resolução ou *pixel* e está associada, por exemplo, às variações num dossel florestal. A macro-textura está mais associada com a topografia, o que resulta em variações de brilho por muitos elementos de resolução.

A textura é uma importante característica utilizada na interpretação visual de imagens e, por isso, pode aumentar o desempenho de classificadores digitais, principalmente em imagens com alta resolução espacial. Em interpretação de imagens de radar, o atributo textural apresenta maior eficácia do que o atributo tonal (Ulaby et al., 1986a). Vários estudos mostram que a utilização de técnicas de análises texturais em imagens de radar têm melhorado a classificação de alvos terrestres (Silva Junior, 2002; Soler, 2002; Presutti et al., 2001; Morais et al., 1999; Soares et al., 1997 e Rennó, 1995).

O reconhecimento de padrões de textura é fácil de ser executado por intérpretes humanos, pois eles usam processos cognitivos complexos que ainda não são bem entendidos, mas é muito difícil quando se trata de um processo automatizado. Uma das razões para isto é que não existe uma definição matemática precisa para a textura (Greenspan et al., 1994; Haralick, 1979; Mather, 1999).

Dois métodos de análise de textura são os mais utilizados: a análise estrutural e a análise estatística. A análise estrutural pode ser considerada como a repetição dos padrões primitivos básicos com uma certa regra de posicionamento. O método estatístico é caracterizado por propriedades estocásticas da distribuição espacial dos níveis de cinza

numa imagem. A matriz de co-ocorrência é freqüentemente usada neste método (Wang e He, 1990).

O método de análise estatística de textura tem sido desenvolvido usando-se padrões de freqüência (Chen, 1990), estatísticas de primeira ordem (Hsu, 1978; Irons e Peterson, 1981) e estatísticas de segunda ordem (Haralick et al., 1973).

Os métodos que se baseiam em atributos de primeira ordem, não levam em consideração a distribuição espacial dos níveis de cinza da imagem.

As medidas de primeira ordem mais utilizadas são:

- a variância

$$V = \sum_i [i - M]^2 P(i), \quad (2.13)$$

sendo  $P(i)$  a freqüência relativa com que o nível de cinza  $i$  ocorre na imagem e  $M$  é a média dos níveis de cinza da imagem, ou seja,

$$M = \sum_i iP(i) \quad (2.14)$$

- o coeficiente de variação

$$CV = \frac{\sqrt{V}}{M} \quad (2.15)$$

- a assimetria

$$AS = \frac{\sum_i |(i - M)^3| P(i)}{V^{\frac{3}{2}}} \quad (2.16)$$

- a assimetria da média em relação à mediana

$$ASM = \frac{|M - MED|}{\sqrt{V}} \quad (2.17)$$

sendo  $MED$  é a mediana dos níveis de cinza da imagem.

- a curtose

$$CUR = \frac{\sum_i (i - M)^4 P(i)}{V^2} \quad (2.18)$$

Haralick et al. (1973) apresentaram a matriz de co-ocorrência dos níveis de cinza (Gray Level Co-occurrence Matrix – GLCM), que representa a distância e as relações espaciais angulares sobre uma sub-região de uma imagem de tamanho especificado. Cada elemento da GLCM é uma medida de probabilidade de ocorrência de valores de níveis de cinza separados por uma dada distância numa dada direção (Mather, 1999).

Para descrever a GLCM, é necessário enfatizar a noção de *pixels* vizinhos mais próximos entre si. A Figura 2.10 representa uma janela  $3 \times 3$  de uma imagem onde o *pixel* central da janela possui oito *pixels* vizinhos.

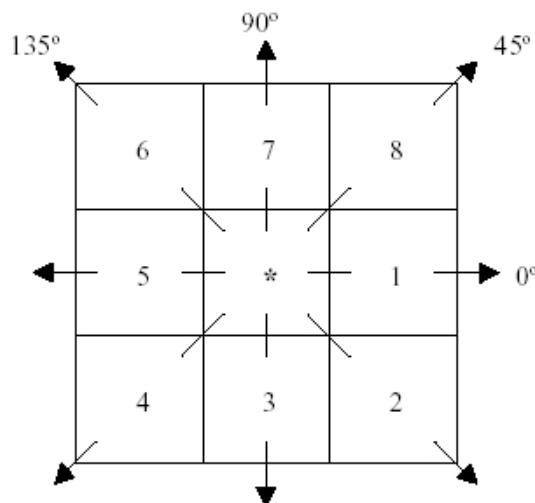


FIGURA 2.10 - Janela  $3 \times 3$  de uma imagem com *pixel* central (\*) e 8 vizinhos.  
FONTE: Adaptada de Haralick et al. (1973).

Pela figura observa-se que os *pixels* 1 e 5 são os vizinhos mais próximos do *pixel* central (\*) que tem orientação horizontal  $0^\circ$ . Os *pixels* 3 e 7 são os vizinhos mais próximos do *pixel* central que tem orientação  $90^\circ$ . Os *pixels* 4 e 8 são os vizinhos mais próximos do *pixel* central com orientação de  $45^\circ$ . Os *pixels* 2 e 6 são os *pixels* mais próximos do *pixel* central com orientação  $135^\circ$ . Estes conceitos são estritamente espaciais e não possuem relação com os valores de níveis de cinza dos *pixels*.

O conceito da GLCM pode ser mais facilmente entendido num exemplo numérico simples. Considere uma imagem  $4 \times 4$  com níveis de cinza variando de 0 a 3 conforme a Figura 2.11a. Geram-se quatro matrizes de co-ocorrência dos níveis de cinza para  $\theta$  igual a  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  e  $135^\circ$ , as quais estão representadas nas Figuras 2.11b, 2.11c, 2.11d e 2.11e respectivamente. Quando a relação for com o *pixel* vizinho horizontal então  $d = 1$  e  $\theta = 0$  e existirão  $2(N_x - 1)$  pares de *pixels* vizinhos em cada linha e existirão  $N_y$  colunas, totalizando  $2N_y(N_x - 1)$  pares de *pixels* vizinhos horizontais mais próximos. Quando a relação for com o vizinho mais próximo da diagonal direita, então  $d = 1$  e  $\theta = 45^\circ$  e existirão  $2(N_x - 1)$  *pixels* naquela direção para cada linha (exceto a primeira, a qual não existe) e existirão  $N_y$  colunas, totalizando  $2(N_y - 1)(N_x - 1)$  pares de *pixels* vizinhos mais próximos da diagonal direita. Por simetria, existirão  $2N_y(N_x - 1)$  pares de vizinhos mais próximos verticais e  $2(N_y - 1)(N_x - 1)$  pares de *pixels* de vizinhos mais próximos da diagonal esquerda. Após determinar o número ( $R$ ) de *pixels* vizinhos mais próximos, usado para calcular a matriz de co-ocorrência, essa matriz será normalizada dividindo-se cada valor da matriz por ( $R$ ) (Haralick et al., 1973).

A GLCM pode ser denominada como sendo um histograma bidimensional que fornece a freqüência de ocorrência  $P(i,j,d,\theta)$ , de um determinado par de níveis de cinza  $i$  e  $j$ , numa determinada distância  $d$  e uma direção  $\theta$ .

0	0	1	1
0	0	1	1
0	2	2	2
2	2	3	3

(a)

$$0^\circ \quad P_H = \begin{pmatrix} 4 & 2 & 1 & 0 \\ 2 & 4 & 0 & 0 \\ 1 & 0 & 6 & 1 \\ 0 & 0 & 1 & 2 \end{pmatrix}$$

(b)

$$45^\circ \quad P_{DD} = \begin{pmatrix} 4 & 1 & 0 & 0 \\ 1 & 2 & 2 & 0 \\ 0 & 2 & 4 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

(c)

$$90^\circ \quad P_V = \begin{pmatrix} 6 & 0 & 2 & 0 \\ 0 & 4 & 2 & 0 \\ 2 & 2 & 2 & 2 \\ 0 & 0 & 2 & 0 \end{pmatrix}$$

(d)

$$135^\circ \quad P_{DE} = \begin{pmatrix} 2 & 1 & 3 & 0 \\ 1 & 2 & 1 & 0 \\ 3 & 1 & 0 & 2 \\ 0 & 0 & 2 & 0 \end{pmatrix}$$

(e)

FIGURA 2.11 - Imagem 4 x 4 com níveis de cinza entre 0 e 3 (a). As matrizes de co-ocorrência com ângulos de  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  e  $135^\circ$  são apresentadas em (b), (c), (d) e (e), respectivamente.

FONTE: Adaptada de Haralick et al. (1973).

Tendo como exemplo o elemento (3,1) da matriz de co-ocorrência dos níveis de cinza da Figura 2.11(b), cujos valores de  $d=1$  e  $\theta=0^\circ$ , o valor 0 (zero) indica que o valor 3 não ocorre como vizinho do valor 1, na distância  $d=1$  e direção  $\theta=0^\circ$  na imagem numérica da Figura 2.11(a).

Essa matriz de co-ocorrência de níveis de cinza é então normalizada, onde cada elemento da matriz é dividido pelo valor da somatória de todos os seus elementos. A Figura 2.12 mostra uma matriz de co-ocorrência de níveis de cinza da Figura 2.11(d) normalizada. A matriz de co-ocorrência de níveis de cinza normalizada que será usada para calcular as medidas de textura.

$$P_V = \begin{pmatrix} 90^\circ & \begin{matrix} 6/24 & 0/24 & 2/24 & 0/24 \\ 0/24 & 4/24 & 2/24 & 0/24 \\ 2/24 & 2/24 & 2/24 & 2/24 \\ 0/24 & 0/24 & 2/24 & 0/24 \end{matrix} \end{pmatrix}$$

FIGURA 2.12 - Matriz de co-ocorrência de níveis de cinza.

Haralick et al. (1973) sugeriram algumas medidas de textura baseadas na matriz de co-ocorrência de níveis de cinza, no vetor soma.

$$P^S(k)_{\Delta x, \Delta y} = \sum_i \sum_j P(i, j)_{\Delta x, \Delta y} \forall i + j = k \quad (2.19)$$

e no vetor diferença de níveis de cinza (Soares et al., 1997)

$$P^D(k)_{\Delta x, \Delta y} = \sum_i \sum_j P(i, j)_{\Delta x, \Delta y} \forall |i - j| = k, \quad (2.20)$$

sendo  $P(i, j)_{\Delta x, \Delta y}$  cada elemento da matriz de co-ocorrência de níveis de cinza e representa a freqüência relativa com que dois *pixels* vizinhos ( $i$  e  $j$ ), separados por uma distância de  $\Delta x$  colunas e  $\Delta y$  linhas, ocorrem na imagem.

A seguir, apresentam-se algumas medidas de textura baseados na matriz de co-ocorrência de níveis de cinza.

- Segundo momento angular (energia)

$$ENE_{\Delta x, \Delta y} = \sum_i \sum_j P(i, j)^2_{\Delta x, \Delta y} \quad (2.21)$$

Esta medida avalia a uniformidade textural, que é a repetição de pares de níveis de cinza. Quando a área de interesse apresenta textura uniforme (valores de níveis de cinza próximos) o valor de energia tende para 1. Caso a área não seja uniforme o valor da energia tende a 0 (zero).

- Entropia

$$ENT_{\Delta x, \Delta y} = - \sum_i \sum_j p(i, j)_{\Delta x, \Delta y} \log P(i, j)_{\Delta x, \Delta y} \quad (2.22)$$

Mede a desordem em uma imagem. Quando a imagem não apresenta textura uniforme, os valores da entropia tendem a ser muito baixos. A entropia alcança seu valor máximo quando os *pixels* na área de interesse apresentam níveis de cinza com valores aleatórios. A entropia apresenta uma correlação linear negativa com a energia e não é correlacionada com a medida de correlação.

- Contraste

$$CON_{\Delta x, \Delta y} = \sum_i \sum_j (i - j)^2 P(i, j)_{\Delta x, \Delta y} \quad (2.23)$$

O contraste mede a presença de transição abrupta de níveis de cinza, isto é, as bordas. Baixos valores indicam a ausência de bordas na área de interesse. Neste caso, a matriz de co-ocorrência de níveis de cinza apresenta valores concentrados em torno de sua diagonal principal.

- Homogeneidade local

$$HOM_{\Delta x, \Delta y} = \sum_i \sum_j \frac{P(i, j)_{\Delta x, \Delta y}}{1 + (i - j)^2} \quad (2.24)$$

Este parâmetro, também chamado de Momento da Diferença Inversa (Baraldi e Permiggiani, 1995), mede a homogeneidade da imagem e assume valores grandes quando os pares de *pixels*, na área de interesse, têm pequena diferença de níveis de cinza. A homogeneidade apresenta uma correlação negativa com o contraste.

- Correlação

$$COR_{\Delta x, \Delta y} = \frac{\sum_i \sum_j ij P(i, j)_{\Delta x, \Delta y} - \mu_l \mu_c}{\sigma_l \sigma_c} \quad (2.25)$$

onde

$$\mu_l = \sum_i i P(i, *)_{\Delta x, \Delta y}, \quad (2.26)$$

$$\mu_c = \sum_j j P(*, j)_{\Delta x, \Delta y}, \quad (2.27)$$

$$\sigma_l = \sqrt{\sum (i - \mu_l)^2 P(i, *)_{\Delta x, \Delta y}}, \quad (2.28)$$

$$\sigma_c = \sqrt{\sum_j (j - \mu_c)^2 P(*, j)_{\Delta x, \Delta y}}, \quad (2.29)$$

$$P(i, *)_{\Delta x, \Delta y} = \sum_j P(i, j)_{\Delta x, \Delta y} \quad (2.30)$$

e

$$P(*, j)_{\Delta x, \Delta y} = \sum_i P(i, j)_{\Delta x, \Delta y} \quad (2.31)$$

Mede a dependência linear entre os níveis de cinza de pares de *pixels*. Valores próximos a um implicam numa forte relação entre os níveis de cinza dos *pixels*. A medida correlação não é correlacionada com a energia, isto é, altos valores de correlação podem ser encontrados em baixos ou altos valores de energia, para a mesma área de interesse.

- Dissimilaridade

$$DIS_{\Delta x, \Delta y} = \sum_i \sum_j |i - j|^2 P(i, j)_{\Delta x, \Delta y} \quad (2.32)$$

A dissimilaridade mede o quanto o nível de cinza dos pares de *pixels* são diferentes entre si e tem maiores valores quando a diferença entre eles também é grande. A dissimilaridade é similar ao contraste, porém os valores obtidos por este são maiores.

- Chi-quadrado

$$CHI_{\Delta x, \Delta y} = \sum_i \sum_j \frac{[P(i, j)_{\Delta x, \Delta y}]^2}{P(i, *)_{\Delta x, \Delta y} P(*, j)_{\Delta x, \Delta y}} \quad (2.33)$$

Pode ser entendida como a normalização da energia da área de interesse para uma dependência linear dos níveis de cinza na imagem. Esta medida apresenta uma correlação negativa com a energia.

As medidas *cluster shade* e *cluster prominence*, utilizadas no programa Texture (Rennó, 2003), são descritas a seguir.

- Cluster shade

$$SHA_{\Delta x, \Delta y} = \sum_i \sum_j [(i - \mu_l) + (j - \mu)]^3 P(i, j)_{\Delta x, \Delta y} \quad (2.34)$$

- Cluster prominence

$$PRO_{\Delta x, \Delta y} = \sum_i \sum_j [(i - \mu_l) + (j - \mu)]^4 P(i, j)_{\Delta x, \Delta y} \quad (2.35)$$

As medidas a seguir são derivadas do vetor soma (Equação 2.19) e vetor diferença (Equação 2.20) de níveis de cinza, que é baseada na diferença absoluta entre pares de níveis de cinza  $i$  e  $j$  a uma distância de  $\Delta x$  colunas e  $\Delta y$  linhas em uma direção fixa  $\theta$  (Soares et al., 1997; Van der Sanden, 1997). Estas medidas apresentam as mesmas características das medidas de segunda ordem anteriores.

- Média do vetor soma

$$MS_{\Delta x, \Delta y} = \sum_k k P^S(k)_{\Delta x, \Delta y} \quad (2.36)$$

- Variância do vetor soma

$$VS_{\Delta x, \Delta y} = \sum_k (k - MS_{\Delta x, \Delta y})^2 P^S(k)_{\Delta x, \Delta y} \quad (2.37)$$

- Energia do vetor soma

$$ENES_{\Delta x, \Delta y} = \sum_k [P^S(k)_{\Delta x, \Delta y}]^2 \quad (2.38)$$

- Entropia do vetor soma

$$ENTS_{\Delta x, \Delta y} = -\sum_k P^S(k)_{\Delta x, \Delta y} \log P^S(k)_{\Delta x, \Delta y} \quad (2.39)$$

- Média do vetor diferença

$$MD_{\Delta x, \Delta y} = \sum_k k P^D(k)_{\Delta x, \Delta y} \quad (2.40)$$

- Variância do vetor diferença

$$VD_{\Delta x, \Delta y} = \sum_k (k - MD_{\Delta x, \Delta y})^2 P^D(k)_{\Delta x, \Delta y} \quad (2.41)$$

- Energia do vetor diferença

$$ENED_{\Delta x, \Delta y} = \sum_k [P^D(k)_{\Delta x, \Delta y}]^2 \quad (2.42)$$

- Entropia do vetor diferença

$$ENTD_{\Delta x, \Delta y} = -\sum_k P^D(k)_{\Delta x, \Delta y} \log P^D(k)_{\Delta x, \Delta y} \quad (2.43)$$

## CAPÍTULO 3

### ÁREA DE ESTUDO

#### 3.1 Área de Estudo

A área de estudo deste trabalho localiza-se na região do Médio Vale do Paranapanema e pertence à região de Assis, São Paulo. As coordenadas do retângulo envolvente da área de estudo são  $23^{\circ}15'$  e  $22^{\circ}30'$  de latitude sul e  $51^{\circ}00'$  e  $50^{\circ}15'$  de longitude oeste. (Figura 3.1), compreende os municípios de Cândido Mota, Cruzália, Macaraí, Pedrinhas Paulista e Tarumã.

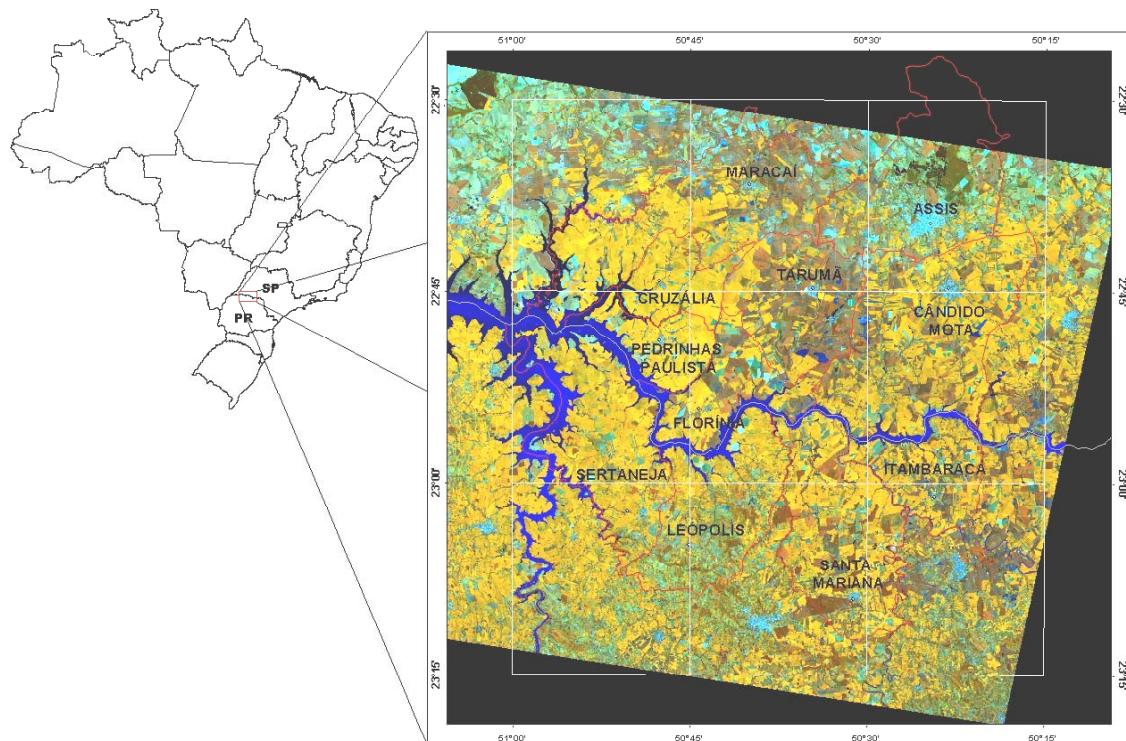


FIGURA 3.1 - Representação da área de estudo.

As razões para a escolha dessa região foram a existência de trabalhos anteriores desenvolvidos na área (Macedo, 2002), que proporcionam o conhecimento do histórico

de uso do solo e a relativa proximidade do INPE, facilitando a coleta de dados através de trabalhos de campo. Além disso, a região é uma das grandes produtoras de soja, sendo uma região teste ideal para atender os objetivos desse trabalho.

A área total dos municípios que abrangem a área de estudo é de 1733 km<sup>2</sup> sendo 1174 km<sup>2</sup> destinados às culturas agrícolas, ou seja, 68% (Tabela 3.1).

TABELA 3.1 - Áreas agrícolas (km<sup>2</sup>) dos municípios pertencentes à região de Assis-SP.

Município	Área total (em km <sup>2</sup> )	Área rural	Área rural (%)
Cândido Mota	596	402	67
Cruzália	149	111	74
Macarai	533	334	63
Pedrinhas Paulista	152	94	62
Tarumã	303	233	77
<b>Total</b>	<b>1733</b>	<b>1174</b>	<b>68</b>

FONTE: IBGE (2003a).

A região de Assis tem altitude de 500 m a oeste, a qual diminui gradativamente para a bacia do Paraná, onde as cotas altimétricas atingem 300 m. O relevo é fortemente a suavemente ondulado, apresenta colinas amplas e médias e morros alongados e esporões. Na rede hidrográfica destacam-se os Rios Paranapanema, Peixe, Feio (baixo curso), Sto. Anastácio e Aguapeí, todos de regime tropical (Troppmair, 2000).

No aspecto climático a média das máximas acusa 31°C, das mínimas 12°C e a média anual 22°C. Um ou dois dias de geada são comuns nessa região no período de inverno. O teor médio de umidade do ar é de 70%. As horas de insolação devido ao céu limpo somam 2400 horas. Na classificação de Koppen, o clima é do tipo “Aw”, “Tropical/Subtropical”, com forte atuação da massa polar. Nos solos da região, verifica-se um excedente de água de 100 mm no verão, com um déficit de 50 mm no inverno (Troppmair, 2000).

Segundo Boin et al. (2002), a região possui um dos maiores índices de pluviosidade do Oeste Paulista. As chuvas são provocadas, principalmente, por mecanismos frontológicos engendrados pela efetiva participação da massa Polar Atlântica,

especialmente em seus trajetos orientais, que se confrontam com a massa Tropical Atlântica, também presente nesta região. Os índices de chuva são altos em todas as estações do ano (maior que 1400 mm).

Como o teor de umidade no solo é um parâmetro do alvo que interfere no retroespalhamento, a seguir são apresentados na Tabela 3.2 os dados pluviométricos nos dias de imageamento do RADARSAT-1.

TABELA 3.2 - Dados Pluviométricos nos dias de imageamento.

<b>Imagens RADARSAT-1</b>	<b>Data</b>	<b>Precipitação (mm)</b>				
		A	CM	M	T	PP
30/jan/2003	29/jan/2003	5,6	0	0	31,6	1
	30/jan/2003	3,6	0	5,2	21	1
	31/jan/2003	0	0	38	15	0
14/fev/2003	12/fev/2003	49,9	6,4	8	0	0
	13/fev/2003	5,6	7,8	0	0	6
	14/fev/2003	27,2	53,2	5	5	22
23/fev/2003	21/fev/2003	3	4,8	2	7	51
	22/fev/2003	0	0	0	1,6	0
	23/fev/2003	0	0	0	1,6	0

FONTE: IAC/CIIAGRO (2003).

A – Assis; CM – Cândido Mota; M – Macaraí; T – Tarumã e PP - Pedrinhas Paulista.

Pela tabela observa-se que para as datas de 30/jan e 14/fev o índice pluviométrico foi relativamente alto, podendo ocasionar um maior efeito da umidade do solo no retroespalhamento. O índice pluviométrico foi baixo para quase todos os municípios na área de estudo para a data de 23/fev, o que torna o efeito da umidade do solo no retroespalhamento de importância secundária.

Segundo Oliveira et al. (1999), os solos predominantes na área de estudo são da classe LATOSOLO VERMELHO, além da presença, em menor escala, da classe NITOSOLO VERMELHO.

Os LATOSOLOS VERMELHOS Eutroféricos e Distroféricos, com A moderado, textura argilosa em relevo suave ondulado ocorrem em toda a área de estudo, ou seja, nos municípios de Cândido Mota, Pedrinhas Paulistas, Tarumã, Macaraí, Cruzália e

Florínia. Os NITOSSOLOS VERMELHOS Eutroféricos, com A moderado, textura argilosa em relevo suave ondulado e ondulado ocorrem próximos aos rios nos municípios de Tarumã, Florínia, Cruzália e Macaraí.

### **3.1.1 Uso do Solo**

Como visto anteriormente, os municípios que abrangem a área de estudo são predominantemente destinados à atividade agrícola. As outras classes de uso do solo que ocorrem na área de estudo são mostradas na Tabela 3.3.

TABELA 3.3 - Uso do solo dos municípios que abrangem a área de estudo.

<b>USO</b>	<b>Área total</b>	<b>%</b>
Lavouras permanentes	759	0,52
Lavouras temporárias	115.584	80
Lavouras temporárias em pousio	1.097	0,76
Pastagens naturais	4.402	3
Pastagens plantadas	13.562	9,4
Reflorestamentos	442	0,3
Vegetação natural	1.919	1,3
Áreas inaproveitadas	762	0,5
Áreas inaproveitáveis	5.125	3,5
Área total	143.657	100

FONTE: (IBGE, 2003b).

De acordo com os dados obtidos pela Produção Agrícola Municipal (PAM) do projeto SIDRA (Sistema IBGE de Recuperação Automática), o uso agrícola dos municípios em estudo caracteriza-se principalmente pelas culturas anuais (milho e soja) e semiperenes (cana-de-açúcar). A Tabela 3.4 mostra a área cultivada (em hectares) das principais culturas permanentes e temporárias para todos os municípios incluídos nesse estudo. As culturas de milho, soja e cana-de-açúcar ocupam a maior área plantada dos municípios em estudo com 83.830 ha, 77.700 ha e 41.250 ha, respectivamente.

TABELA 3.4 - Total de área cultivada (em hectares) por tipo de cultura dos municípios pertencentes à região de Assis-SP.

Municípios Culturas	Cândido Mota	Cruzália	Macaraí	Pedrinhas Paulistas	Tarumã	Total
Algodão	3	-	-	-	-	3
Amendoim	70	-	-	-	-	70
Arroz	200	80	50	315	320	965
Cana-de-açúcar	10.800	50	15.000	-	15.400	41.250
Feijão	400	-	20	-	-	420
Mandioca	2.025	-	20	-	-	2.045
Milho	31.000	10.000	20.000	11.330	11.500	83.830
Soja	26.000	10.000	21.100	8.700	11.900	77.700
Trigo	1.000	40	2.000	-	40	3.080
Tomate	20	-	-	-	-	20
Total	71.518	20.170	58.190	20.345	39.160	209.383

FONTE: (IBGE, 2003b).

Apesar da cultura de milho ocupar a maior área cultivada, as culturas de soja e cana-de-açúcar são as de maior ocorrência na área de estudo no período analisado. A seguir são apresentadas descrições da cultura da soja e da cana-de-açúcar e as condições das mesmas durante a aquisição das imagens pelo satélite RADARSAT-1.

### 3.1.2 A Cultura de Soja

A soja (*Glycine max* (L.) Merril) pertence à família Leguminosae, é de ciclo anual, tipicamente herbácea, e apresenta grande diversificação genética e morfológica devido ao elevado número de variedades e cultivares. A Figura 3.2 ilustra as partes do sistema vegetativo da soja.

O ciclo da soja varia entre 75 e 210 dias e pode atingir de 75 a 125 cm de altura, dependendo do cultivar. No seu estádio de florescimento pleno, a soja atinge o máximo de Índice de Área Foliar (IAF) de 5 a 8, declinando para 4 a 6 próximo à maturação fisiológica. A Tabela 3.5 ilustra os diferentes estádios fenológicos propostos por Álvares Filho (1988).

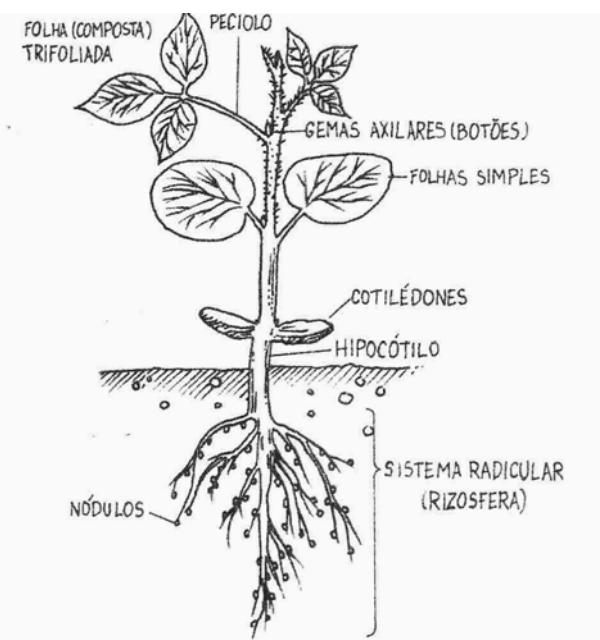


FIGURA 3.2 - As partes do sistema vegetativo da soja.  
FONTE: Adaptada de Alvares Filho (1988).

Para o plantio, o espaçamento entre as fileiras indicado é de 40 a 50 cm. Espaçamentos mais estreitos que 40 cm resultam no fechamento mais rápido da cultura, contribuindo para o controle de plantas daninhas.

A soja apresenta baixa produção de palha, por isso, a rotação de culturas permite a permanente cobertura e suficiente reposição de palhada sobre a superfície do solo, viabilizando o sistema de plantio direto (Embrapa, 2002).

Para o Estado de São Paulo, os cultivares indicados pertencem a quatro grupos de maturação: precoce (até 120 dias), semiprecoce (de 121 dias a 130 dias), médio (de 131 a 140 dias) e semitardio (de 141 dias a 150 dias).

Entre as cultivares predominantes para a safra de 2003 na área de estudo, destacam-se: BRS 133 e a IAC 18, que pertencem ao grupo de maturação semiprecoce (Embrapa, 2002). A data de plantio para esses cultivares ocorreram entre os dias 05 a 20 de novembro de 2002.

**TABELA 3.5 - Fases fenológicas da cultura de soja e respectivas simbologias.**

Símbolo	Denominação	Descrição
Estádio		
VE	Emergência	Os cotilénodes estão acima da superfície do solo
VC	Cotilénode desenvolvido	As margens das folhas unifoliadas e opostas não se tocam
V <sub>1</sub>	Primeiro nó	Folhas unifoliadas desenvolvidas
V <sub>2</sub>	Segundo nó	Folhas trifoliadas completamente desenvolvidas no nó acima ao da folha unifoliada
V <sub>3</sub>	Terceiro nó	Três nós sobre a haste principal com folhas completamente desenvolvidas iniciando-se com nós das folhas unifoliadas
V <sub>(n)</sub>	Enésimo nó	"N" números de nós sobre a haste principal com folhas completamente desenvolvidas, iniciando-se com nós das folhas unifoliadas
Estádio vegetativo		
R <sub>1</sub>	Início do florescimento	Uma flor aberta em qualquer nó da haste principal
R <sub>2</sub>	Florescimento pleno	Uma flor aberta no último nó da haste principal, com folha completamente desenvolvida
R <sub>3</sub>	Início da formação das vagens	Vagem com 2,0 cm de comprimento desenvolve-se em um dos quatro últimos nós da haste principal, com folha completamente desenvolvida.
R <sub>4</sub>	Plena formação das vagens	Vagem com 0,5 cm de comprimento desenvolve-se em um dos quatro últimos nós do caule com folha completamente desenvolvida
R <sub>5</sub>	Início do enchimento de grãos	Semente com 3 mm de comprimento em uma vagem, localizada em um dos quatro últimos nós da haste principal, com folha completamente desenvolvida
R <sub>6</sub>	Pleno enchimento de grãos	Vagem contendo semente verde que preencha a sua cavidade, localizada em um dos quatro últimos nós da haste principal, com a folha.
R <sub>7</sub>	Maturação fisiológica	Uma vagem normal sobre a haste principal que tenha atingido a cor da vagem madura
R <sub>8</sub>	Maturação de colheita	95% das vagens atingindo a cor da vagem madura

FONTE: Adaptado de Alvares Filho (1988).

Os talhões de soja analisados na área de estudo encontravam-se na fase de máximo desenvolvimento na ocasião do imageamento, ou seja, com dossel fechado e cobrindo praticamente todo o solo.

Fotos de alguns talhões de soja visitados durante o trabalho de campo e que ilustram as diferentes condições da cultura de soja são mostrados na Figura 3.3.



FIGURA 3.3 - Fotografias de diferentes talhões de soja da área de estudo em 24 e 25/Fev/2003.

### 3.1.3 A Cultura de Cana-de-Açúcar

A cana-de-açúcar (*Saccharum* sp) é uma gramínea semi-perene, chamada de “cana de ano” quando é plantada no inicio da estação chuvosa, entre setembro e novembro, pois apresenta um ciclo vegetativo com duração média de 12 meses. Quando é plantada no meio da estação chuvosa, é chamada de “cana de ano e meio” e seu ciclo vegetativo se estende de 14 até 21 meses. A variação na duração do ciclo depende, principalmente, do ambiente e das técnicas de manejo (Câmara, 1993).

Antes do primeiro corte, a cana é denominada de “cana-planta”. Após o corte restam no campo as socas ou soqueiras que, em torno de 20 a 30 dias brotam, originando a “cana-soca”, e seu ciclo se completa em, aproximadamente, um ano (Câmara, 1993).

Normalmente o canavial é reformado após 4 a 6 anos do plantio. A soqueira é removida do solo por gradeações pesadas, que são realizadas, em média, após 1 a 2 meses da colheita.

Em relação à indicação de plantio, o espaçamento entre linhas pode variar entre 0,90 e 1,50 metros, e em geral, um menor espaçamento favorece a produtividade (Câmara, 1993).

Na área de estudo, os talhões analisados encontravam-se na fase adulta de desenvolvimento, apresentando diversidade na altura e estrutura de plantas, o que ocasionou heterogeneidade nesta classe.



## CAPÍTULO 4

### MATERIAIS E MÉTODOS

#### 4.1 Materiais

##### 4.1.1 Imagens

Neste trabalho foram utilizadas três imagens do sistema RADARSAT-1/SAR e duas imagens do sistema LANDSAT-7/ETM+, da órbita/ponto 222/76.

Para satisfazer os objetivos do trabalho, as imagens foram adquiridas no período entre janeiro e março de 2003 durante a fase de máximo desenvolvimento da cultura de soja. As imagens do sistema LANDSAT-7/ETM+ datadas de 23 de fevereiro e 27 de março de 2003 foram utilizadas como dados de referência. As imagens RADARSAT-1/SAR, banda C e polarização HH utilizadas neste trabalho foram: *Fine-5/Descendente* (F5D), *Fine-5/Ascendente* (F5A) e *Standard-7/Descendente* (S7D). A Tabela 4.1 apresenta as principais características das imagens utilizadas no trabalho.

TABELA 4.1 - Características das imagens utilizadas no trabalho.

Modo	F5D <sup>1</sup>	F5A <sup>1</sup>	S7D <sup>1</sup>	ETM+
Data	30/01/2003	14/02/2003	23/02/2003	23/02/2003 e 27/03/2003
Ângulo de incidência	45°-47,8°	45°-47,8°	44,7°-49,2°	-
Número de <i>looks</i>	1 x 1 m	1 x 1 m	1 x 4 m	-
Horário de passagem	6:39 hs	6:04 hs	6:39 hs	10:11 hs
Dimensões do <i>pixel</i>	6,25 m	6,25 m	12,5 m	-
Resolução espacial	8 m	8 m	25 m	30 m
Área de cobertura	50 km	50 km	100 km	185 km
Formato do dado	CEOS	CEOS	CEOS	Geo tiff

<sup>1</sup>FONTE: RADARSAT Internacional (1995).

##### 4.1.2 Softwares

As características de cada software utilizado no trabalho são apresentadas a seguir.

- FUGAWI 3.0. Este aplicativo foi utilizado no trabalho de campo. Instalado a um laptop com sistema operacional Windows XP acoplado a um GPS de navegação

(Garmin GPS III+), permitiu a navegação sobre a imagem Landsat, a coleta de pontos georreferenciados e a aquisição de informações agronômicas em algumas áreas da região de estudo;

- SPRING 4.0. Este aplicativo permitiu o recorte das áreas comuns das imagens ortorretificadas;
- ENVI 3.6. Os procedimentos de coleta de amostras (treinamento e teste) e a validação das classificações geradas foram feitas com uso desse aplicativo;
- TEXTURE/ICM/FILTER TEXTURE 3.0. Estes programas foram desenvolvidos pelo INPE em linguagem IDL/ENVI 3.5. O aplicativo *Texture* permitiu a geração das medidas de textura a partir de amostras de treinamento. O aplicativo *ICM* permitiu a classificação das imagens. O aplicativo *filter texture* permitiu a geração das imagens de textura;
- PCI Geomatics 7.0. A correção geométrica das cartas topográficas e das imagens incluindo a coleta de pontos de controle, geração do Modelo Digital de Elevação (*Digital Elevation Model-DEM*) e ortorretificação foram realizadas no módulo *orthoengine* desse aplicativo.

#### **4.2 Metodologia**

O desenvolvimento do trabalho foi feito segundo os procedimentos descritos abaixo, também apresentados na forma de fluxograma (Figura 4.1).

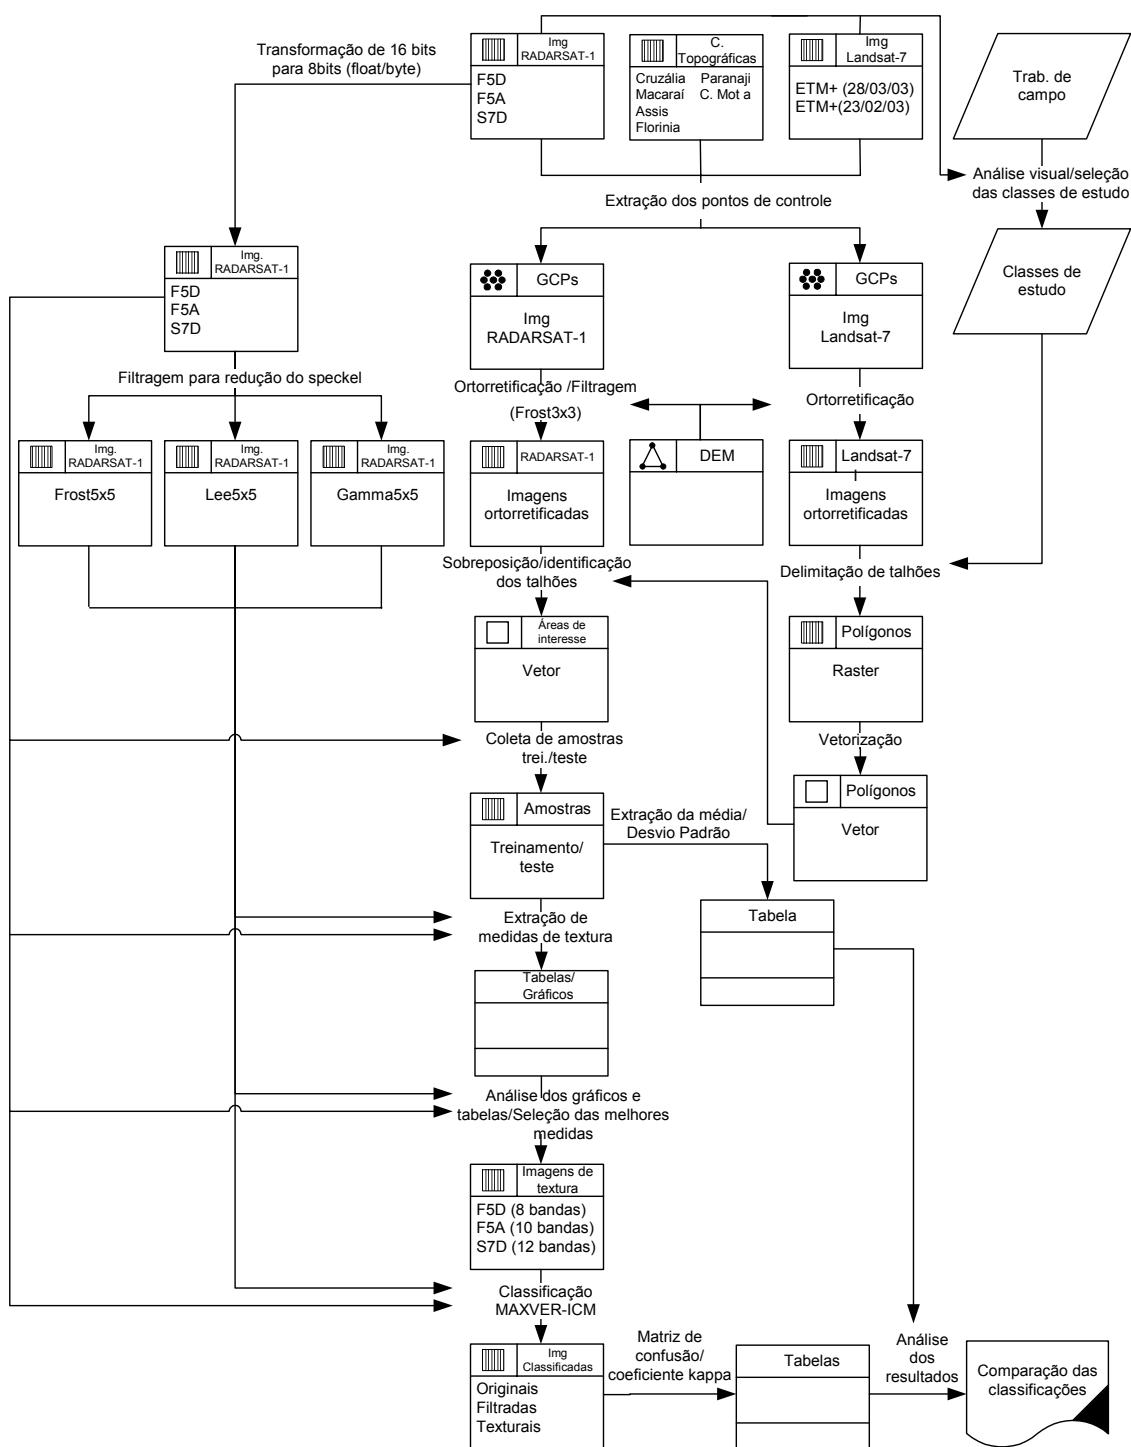


FIGURA 4.1 - Fluxograma em modelagem OMT-G (Object Modeling Techniques para aplicações geográficas).

#### **4.2.1 Correção Geométrica das Imagens**

As imagens adquiridas por sensores remotos geralmente apresentam diversas distorções espaciais tais como erro do instrumento, distorção panorâmica, rotação da Terra e instabilidade da plataforma. Desse modo, não apresentam uniformidade quanto ao posicionamento de áreas e objetos nelas representados (Mather, 1999).

A correção geométrica de imagens de sensoriamento remoto se faz necessária principalmente para a integração das mesmas com outros dados nas seguintes circunstâncias:

- Transformação da imagem para o ajuste a um sistema de projeção cartográfica (georreferenciamento);
- Localização de pontos de controle no mapa e na imagem;
- Integração de imagens de uma mesma área adquiridas por sensores diferentes;
- Integração de imagens e mapas num Sistema de Informação Geográfica (SIG).

Uma das técnicas mais utilizadas para a integração dos dados é o registro. O registro é o processo que faz os *pixels* de duas imagens coincidirem precisamente aos mesmos pontos no terreno (Schowengerdt, 1997). O uso de equações polinomiais é bastante comum no registro de imagens e relacionam as coordenadas da imagem às coordenadas de um sistema de referência como latitude e longitude. O registro é feito através de pontos de controle adquiridos pelo usuário (Richards, 1986; Mather, 1999). Entretanto, para imagens de radar, o método polinomial não é suficientemente preciso, sendo necessária a utilização de um método de alta precisão conhecido como ortorretificação.

##### **4.2.1.1 Ortorretificação**

A ortorretificação de uma imagem de sensoriamento remoto é um tipo de correção geométrica de alta precisão baseada no modelo fotogramétrico, ou seja, em uma fundamentação matemática e geométrica que leva em consideração as diferentes distorções relativas à plataforma, ao sensor, à Terra e à projeção cartográfica. Na ortorretificação, utiliza-se o Modelo Digital de Elevação (*Digital Elevation Model*-

DEM) para correção do deslocamento devido ao relevo. A imagem a ser ortorretificada deve conter as informações sobre as efemérides inerentes ao satélite.

Segundo Toutin (1999), correções geométricas baseadas no modelo fotogramétrico são mais precisas do que correções baseadas em modelos polinomiais. A Tabela 4.2 apresenta as principais diferenças.

TABELA 4.2 - Comparação das características dos métodos polinomial e fotogramétrico.

MÉTODO POLINOMIAL	MÉTODO FOTOGRAFÉTRICO
Não considera a geometria de visada	Considera a geometria de visada
Não identifica distorções	Identifica distorções
Não utiliza dados de altitude	Utiliza dados de efeméride e altitude
Não utiliza o DEM	Utiliza o DEM ou elevação próxima
Corrigé imagem localmente nos pontos de controle do terreno	Corrigé a imagem globalmente
Não filtra erros	Filtra erros por meio do conhecimento da geometria
Ajustamentos individuais de uma imagem	Ajustamento simultâneo de mais de uma imagem
Correção imagem para imagem	Correção imagem-terreno
Necessita de muitos pontos de controle (>20)	Utiliza poucos pontos de controle (3-8)
Sensível à distribuição de pontos de controle	Não é sensível à distribuição de pontos de controle
Problema de escolha para pontos vinculados	A escolha dos pontos de controle é função de cada imagem

FONTE: Adaptada de Toutin (1999).

Os dados de entrada para a ortorretificação das imagens utilizadas nesse trabalho foram pontos de controle extraídos das imagens e o DEM. O dado de referência utilizado para coleta dos pontos de controle bem como para geração do DEM foram seis cartas topográficas digitais do IBGE na escala 1:50.000 e no formato “raster” (INPE, 2003) referentes à área de estudo (Tabela 4.3).

TABELA 4.3 - Principais características das cartas topográficas utilizadas.

Cartas topográficas	Escala	Datum horizontal	Meridiano	Fonte
Cruzália	1:50000	Córrego Alegre	51°W, Gr	IBGE
Macaraí	1:50000	Córrego Alegre	51°W, Gr	IBGE
Assis	1:50000	Córrego Alegre	51°W, Gr	IBGE
Florínia	1:50000	Córrego Alegre	51°W, Gr	IBGE
Cândido Mota	1:50000	Córrego Alegre	51°W, Gr	IBGE
Paranaji	1:50000	Córrego Alegre	51°W, Gr	IBGE

As cartas topográficas em formato “raster” foram georreferenciadas por pontos de controle (*Ground Control Points* – GCP) adquiridos na grade de coordenadas das cartas topográficas. O sistema de projeção utilizado foi o UTM (Universal Tranversa de Mercator), Fuso 22° e Datum SAD69 (*South American Datum*). O RMSE (*Root Mean Square Error*) e o número de GCPs utilizados para o georreferenciamento das cartas são apresentados na Tabela 4.4.

TABELA 4.4 - Procedimentos adotados para o posicionamento de cartas topográficas.

<b>Cartas topográficas</b>	<b>GCPs</b>	<b>Reamostragem</b>	<b>Interpolador</b>	<b>RMSE (metros)</b>
Cruzália	7	Polinômio de 1°	Convolução cúbica	4,56
Macaraí	13	Polinômio de 2°	Convolução cúbica	5,2
Assis	12	Polinômio de 2°	Convolução cúbica	3,36
Florínia	13	Polinômio de 1°	Convolução cúbica	5,68
Cândido Mota	13	Polinômio de 2°	Convolução cúbica	3,84
Paranáji	13	Polinômio de 2°	Convolução cúbica	4,16

Para as cartas cujo RMSE apresentou maior erro utilizou-se polinômio de segundo grau. Em geral, os valores de RMSE foram satisfatórios, pois ficaram abaixo do valor equivalente a um *pixel*. O interpolador utilizado foi o de convolução cúbica.

Com as cartas topográficas georreferenciadas, o próximo passo foi a aquisição de pontos de controle das imagens a serem ortorretificadas. Adquiriram-se pontos comuns nas imagens e nas cartas. Os procedimentos utilizados na ortorretificação e o RMSE das imagens do sistema RADARSAT-1 e LANDSAT-7 são apresentadas na Tabela 4.5.

TABELA 4.5 - Procedimentos adotados para a ortorretificação.

<b>Imagens</b>	<b>GCPs</b>	<b>Filtro</b>	<b>Interpolador</b>	<b>RMSE (metros)</b>
F5D	42	Frost enhanced 3x3	Vizinho mais próximo	5,62
F5A	35	Frost enhanced 3x3	Vizinho mais próximo	5,06
S7D	37	Frost enhanced 3x3	Vizinho mais próximo	9,87
ETM+(23/02/03)	69	-	Vizinho mais próximo	20,1
ETM+(27/03/03)	75	-	Vizinho mais próximo	18,3

Entre os vários filtros disponíveis no *software PCI*, optou-se pelo filtro *Frost enhanced* (Lopes, 1990) com janela 3x3, pois este apresentou melhor qualidade visual. O interpolador utilizado foi o de vizinho mais próximo, pois este preserva o brilho original dos *pixels* das imagens (Richards, 1986). A Figura 4.2 ilustra o DEM e as imagens ortorretificadas dos sistemas RADARSAT-1 e LANDSAT-7.

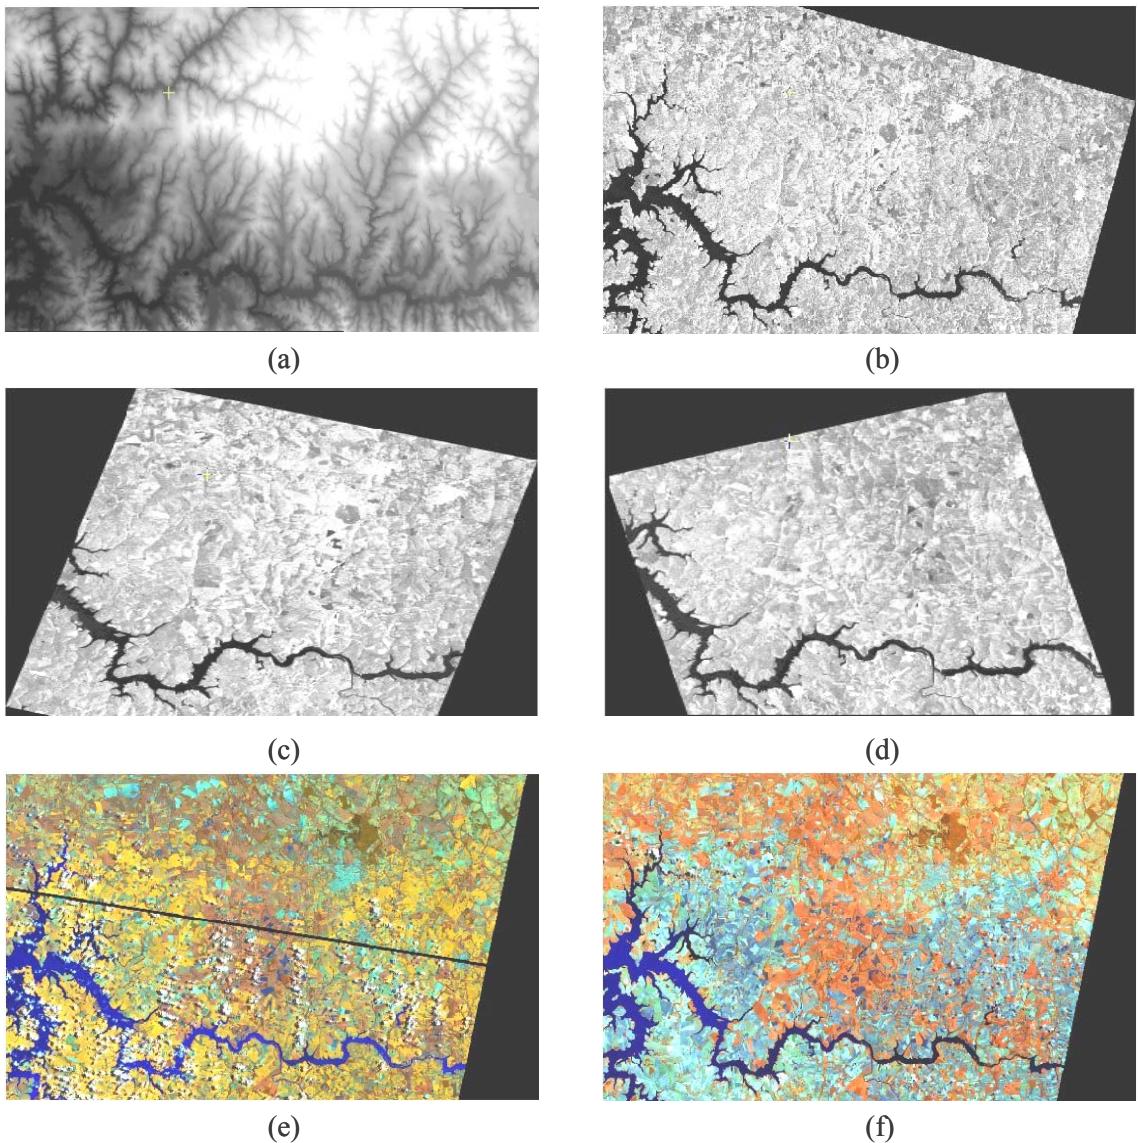


FIGURA 4.2 - Representação do DEM e das imagens ortorretificadas. (a) DEM, (b) S7D, (c) F5D; (d) F5A; (e) ETM+ 23/02/2003; (f) ETM+ 27/03/2003.

#### 4.2.2 Trabalho de Campo

O trabalho de campo foi realizado no mês de fevereiro de 2003 próximo às passagens do satélite RADARSAT-1 e LANDSAT-7. Duas imagens do satélite LANDSAT-7/ETM+ de 07 de fevereiro de 2002 e 06 de fevereiro de 2003 na composição colorida RGB 453 foram utilizadas como dado de referência. O uso da imagem de fevereiro de 2002 (um ano anterior ao trabalho de campo) justifica-se pelo fato de a imagem de fevereiro de 2003 apresentar grande porcentagem de cobertura de nuvem sobre a área de

estudo. A Figura 4.3 ilustra as áreas visitadas no campo para as duas imagens utilizadas. Os pontos vermelhos representam os pontos de GPS e as linhas azuis a rota percorrida. O uso de um equipamento GPS acoplado a um laptop permitiu visualizar nas imagens os locais visitados no campo em tempo real. As imagens foram registradas através da ferramenta *calibrate map* do software *Fugawi*, onde uma imagem registrada da mesma área foi utilizada como referência. Os erros de registro foram corrigidos com os pontos de GPS coletados durante o trabalho de campo.

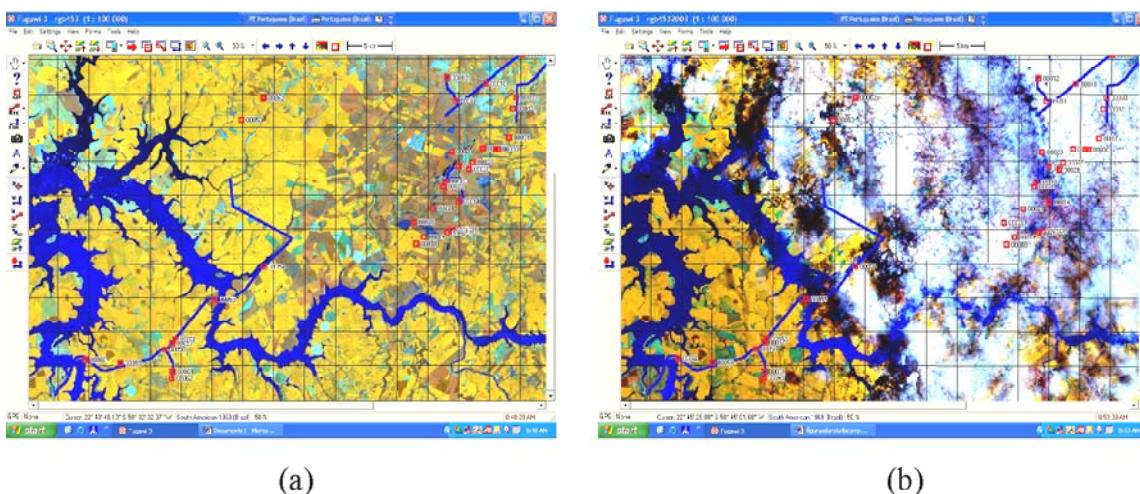


FIGURA 4.3 - Ilustração das áreas visitadas no campo (a) Imagem Landsat-7/ETM+ R(4)G(5)B(3) de 07/02/2002 (b) Imagem Landsat-7/ETM+ R(4)G(5)B(3) de 06/02/2003.

Foram feitos levantamentos do uso da terra, coleta de pontos com GPS de navegação, medições da porcentagem de cobertura vegetal, estádio fenológico e parâmetros agronômicos da cultura de soja. As informações obtidas determinaram as classes de uso de maior ocorrência ao longo da área de estudo e os talhões mais representativos referentes à cada classe para aquisição de amostras de treinamento.

#### **4.2.3 Análise de Textura nas Imagens RADARSAT-1**

Após a correção geométrica das imagens, efetuou-se uma análise de textura nas imagens de radar dentro das seguintes etapas: definição das principais classes de uso do solo na área de estudo, coleta das amostras de treinamento e teste, seleção e geração das bandas

de textura, classificação supervisionada MAXVER-ICM e avaliação das classificações geradas através da matriz de confusão e estatística *kappa*.

#### **4.2.3.1 Definição das Classes de Estudo**

Com as informações obtidas em campo e a interpretação visual das imagens do sensor ETM+/LANDSAT-7 observa-se que, no período analisado, as principais classes de uso do solo na área de estudo são predominantemente agrícolas, entre elas destacam-se: extensas áreas de soja e cana-de-açúcar, pequenas áreas de milho e banana, áreas de solo exposto incluindo solo preparado e com palha, algumas regiões de campo sujo e pastagens, poucas áreas de mata nativa e ciliar localizadas em áreas próximas a rios.

Para a análise de textura em imagens monoespectrais a escolha de um número elevado de classes não é apropriado, pois só aumenta a confusão entre as classes (Rennó, 1995). Portanto, as classes de uso selecionadas foram aquelas de maior ocorrência na área de estudo: soja, cana-de-açúcar e solo exposto.

A análise visual das imagens RADARSAT-1 mostram uma grande heterogeneidade de tons de cinza entre uma mesma classe. A Figura 4.4 ilustra um exemplo de solo exposto, onde é representada pela cor azul delimitada por um contorno de cor vermelha na imagem (a) LANDSAT-7/ETM+ (23/02/2003) composição colorida R(4)G(5)B(3) e apresenta grande variabilidade tonal nas imagens RADARSAT-1 (b), (c) e (d) com tom de cinza claro, intermediário e escuro.

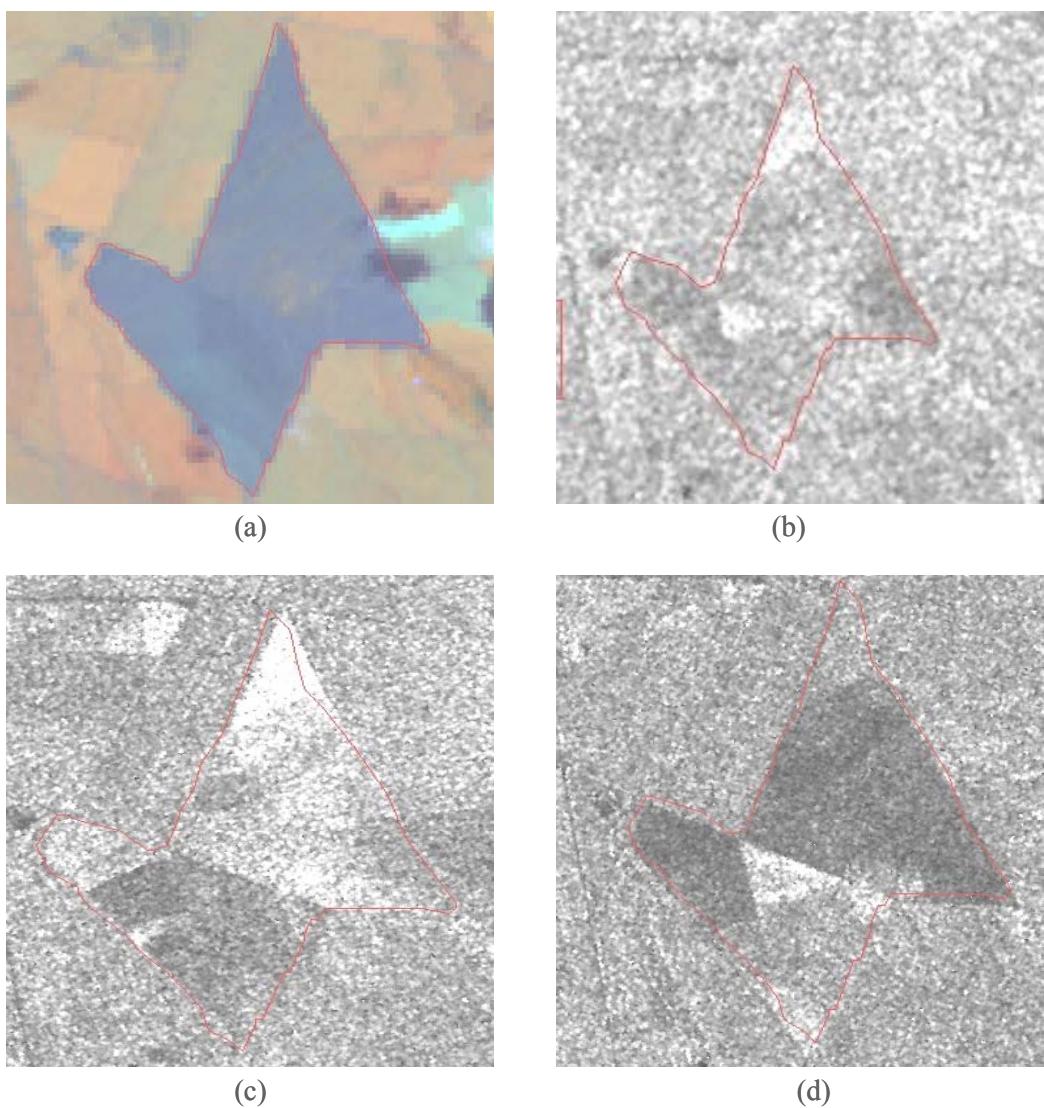


FIGURA 4.4 - Exemplo de variação tonal. (a) ETM+ R(4)G(5)B(3) de 23/02/2003, (b) S7D de 23/02/2003, (c) F5D de 31/01/2003, (d) F5A de 14/02/2003.

Assim, para evitar uma variância muito elevada de uma mesma classe, dividiram-se as mesmas em subclasses resultando num total de 9 classes selecionadas:

- Água (rios e lagos).
- Área urbana
- Soja
- Cana de açúcar 1 (tonalidade escura)

- Cana de açúcar 2 (tonalidade média)
- Solo exposto 1 (tonalidade escura)
- Solo exposto 2 (tonalidade clara)
- Solo exposto 3 (tonalidade média)
- Solo com palha

#### **4.2.3.2 Extração de Amostras de Treinamento e Teste**

A extração das amostras de treinamento e teste foi composta de polígonos retangulares sobre as imagens RADARSAT-1 originais sem correção geométrica para evitar perda de informação de textura provocada pela reamostragem dos níveis de cinza durante o processo de correção geométrica.

Para garantir uma boa amostragem, delimitaram inicialmente polígonos sobre a imagem do sensor LANDSAT-7/ETM+ de 23 de fevereiro de 2003 ortorretificada sobre os talhões mais representativos de cada classe. Os polígonos foram transformados para o formato vetorial, o que permitiu a sobreposição dos mesmos nas imagens RADARSAT-1 ortorretificadas. Este procedimento permitiu uma amostragem precisa e garantiu a confiabilidade das amostras na representação de cada classe. A Figura 4.5 ilustra polígonos na cor vermelha, amostras de treinamento e teste sobre um talhão representativo de soja.

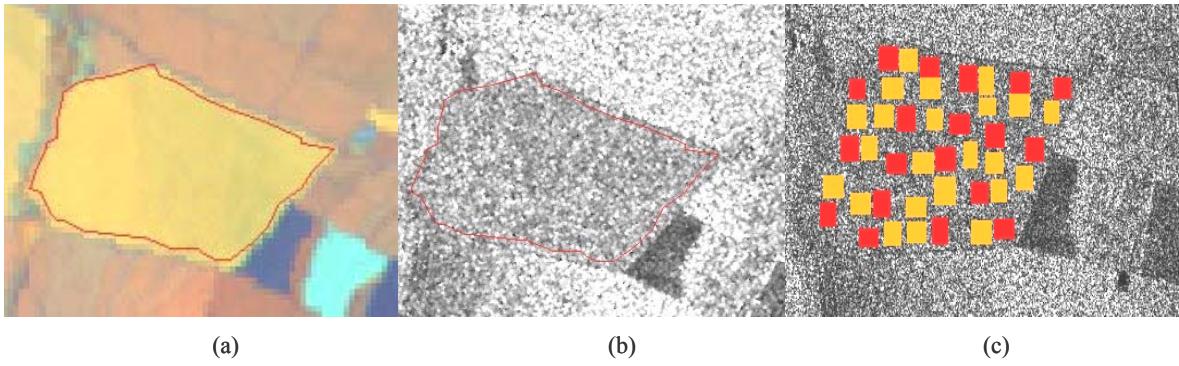


FIGURA 4.5 - Ilustração do procedimento utilizado para extração de amostras de treinamento e teste. (a) ETM+ ortorretificada, (b) F5D ortorretificada, (c) F5D original.

As amostras de treinamento representadas na Figura 4.5c pelos quadrados de cor vermelha foram utilizadas para a geração das medidas de textura. As amostras de teste, representadas pelos quadrados de cor laranja foram utilizadas como referência para avaliar os resultados obtidos nas classificações geradas. O programa *texture* necessita que as amostras sejam compostas de vários polígonos, para que não seja gerado um único valor de textura para cada classe. Os polígonos estão na forma de quadrados de lado de aproximadamente 15 *pixels*, ou seja, cada amostra constitui um conjunto aproximado de 225 *pixels*.

Como as imagens utilizadas neste trabalho foram adquiridas a partir de modos distintos do sistema RADARSAT-1, as imagens não apresentam homogeneidade quanto ao número de linhas e colunas, tamanho de *pixel*, ângulo de visada e, consequentemente, área de cobertura. Foi então necessário sobrepor as imagens para a identificação, delimitação e o recorte da área comum entre as imagens. Este procedimento foi feito através da ferramenta *recortar planos de informação* do aplicativo SPRING. Assim, assegurou-se que as amostras de treinamento e teste fossem adquiridas nas mesmas áreas para as três imagens e garantissem análises comparativas. A Figura 4.6 ilustra as imagens dos sistemas RADARSAT-1 e LANDSAT-7/ETM+ (23/02/2003) recortadas.

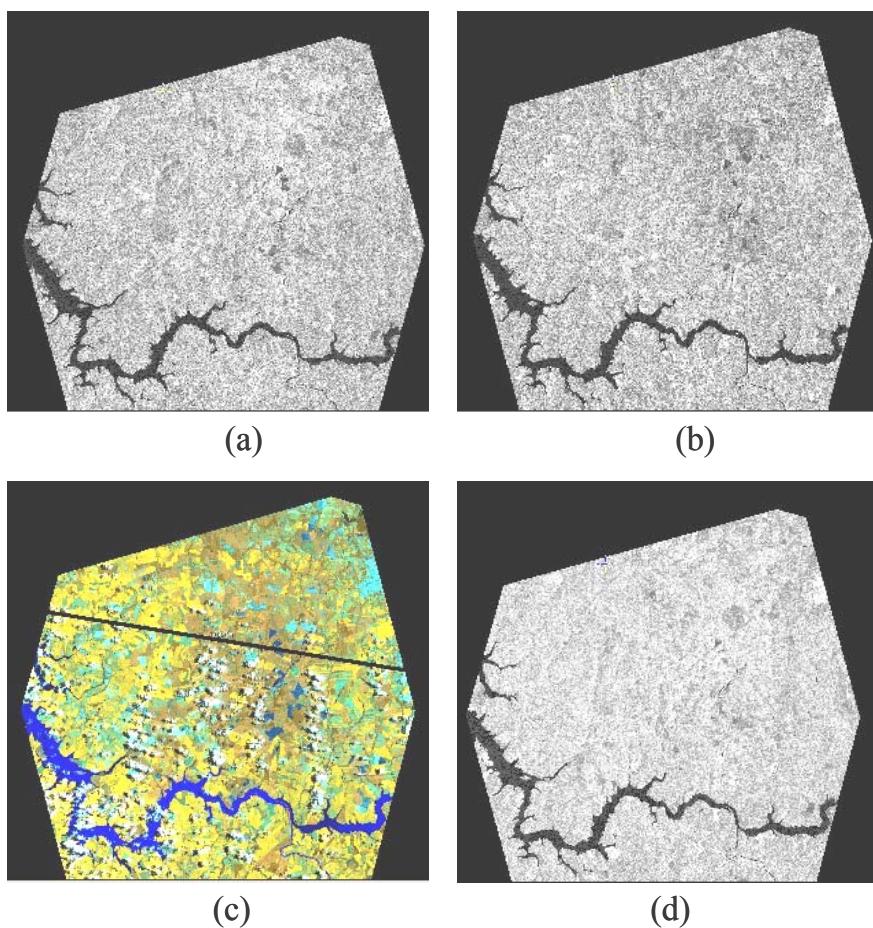


FIGURA 4.6 - Recortes representativos das áreas comuns. (a) Fine5D, (b) F5A, (c) ETM+ R(4)G(5)B(3) e, (d) S7D.

#### 4.2.3.3 Análise das Medidas e Geração das Bandas de Textura

A utilização de todas as medidas de textura na caracterização de um alvo é impraticável e desnecessária uma vez que a demanda computacional para extração dessas informações seria extremamente elevada e, devido à alta correlação existente entre várias dessas medidas, haveria muita informação redundante que poderia ser descartada. Desse modo, faz-se necessária a adoção de um critério para a seleção das melhores medidas de textura, ou seja, aquelas que melhor discriminem os alvos de interesse.

Após a extração das amostras de treinamento, foi realizada a geração das medidas de textura no aplicativo *texture* desenvolvido pelo INPE (Rennó et al., 1998). Este algoritmo foi desenvolvido em linguagem IDL, para extrair e analisar medidas de textura de imagens. A partir de amostras de treinamento, o programa *texture* calcula as

medidas de textura das áreas de treinamento escolhidas, como: 1) medidas de primeira ordem, pelas quais são calculadas sem a consideração da distribuição espacial dos dados; 2) medidas distribucionais que são estimadores de parâmetros estatísticos de distribuição; 3) medidas de Haralick, que são baseadas na matriz de co-ocorrência; 4) medidas de autocorrelação espacial.

Depois da análise de todas as medidas, foram geradas as bandas de textura que corresponderam às que apresentaram melhor discriminação.

Para a análise das medidas de textura selecionou-se um conjunto de medidas de primeira ordem e Haralick apresentados na Tabela 4.6 (seção 2.5). Ao todo são 7 medidas de textura de primeira ordem e 18 medidas de Haralick disponíveis no programa *texture*. O potencial de discriminação entre classes de interesse foi avaliado através do fator discriminante  $F_d$ .

TABELA 4.6 - Medidas de textura selecionadas.

Atributos de textura	
Medidas de primeira ordem	Medidas de Haralick
	Contraste
	Entropia
	Energia
	Homogeneidade
	Correlação
Desvio padrão absoluto	Dissimilaridade
<i>Skewness</i>	Qui-quadrado
<i>Curtose</i>	Cluster shade
Coeficiente de variação	<i>Cluster Prominence</i>
Média	Média do vetor soma
Entropia	Variância do vetor soma
Energia	Entropia do vetor soma
	Energia do vetor soma
	Média do vetor diferença
	Variância do vetor diferença
	Entropia do vetor diferença
	Energia do vetor diferença
	Contraste do vetor diferença

O fator discriminante é calculado da seguinte forma: Consideram-se duas classes, 1 e 2, para uma determinada medida hipotética A, o fator discriminante  $F_d$  é definido por:

$$F_d = \frac{S_{12} + S_{21}}{S_{11} + S_{22}} \quad (4.1)$$

onde,

$$S_{11} = \sum \frac{(VA_1 - m_1)^2}{n_1} \quad (4.2)$$

$$S_{22} = \sum \frac{(VA_2 - m_2)^2}{n_2} \quad (4.3)$$

$$S_{12} = \sum \frac{(VA_1 - m_2)^2}{n_1} \quad (4.4)$$

$$S_{21} = \sum \frac{(VA_2 - m_1)^2}{n_2} \quad (4.5)$$

VA = valores de A para classe 1;

VA = valores de A para classe 2;

$m_1$  = média da medida A para classe 1;

$m_2$  = média da medida A para classe 2;

$n_1$  = número de valores para classe 1; e

$n_2$  = número de valores para classe 2.

A situação ideal para um bom valor discriminante é aquela onde o desvio padrão da medida A para as classes 1 e 2 ( $S_{11}$  e  $S_{22}$ ) é pequeno e o desvio padrão da medida A entre as classes 1 e 2 ( $S_{12}$  e  $S_{21}$ ) é grande. Quanto maior o valor de  $F_d$  maior será o potencial discriminador da medida.

Os parâmetros de entrada requeridos para geração das medidas de Haralick no programa *texture* são: 1) número de quantização dos níveis de cinza; 2) a direção do vetor

deslocamento; e 3) a vizinhança para o cálculo da medida. Neste trabalho foram realizados testes com quantização de níveis de cinza de 64, 128 e 256. Verificou-se que os níveis de cinza iguais a 256 e 128 apresentaram os melhores resultados. Optou-se pelo nível de cinza igual a 128, pois esse apresentou um tempo computacional bem menor. A direção do vetor de deslocamento utilizada foi a omnidirecional e a vizinhança igual a 1, ou seja, o nível de cinza de um determinado *pixel* foi comparado com níveis de cinza dos 8 *pixels* vizinhos mais próximos.

Além das imagens originais, imagens filtradas foram utilizadas. Os filtros utilizados nesse trabalho foram os propostos por Frost et al. (1982), Lee (1980) e Lopes et al. (1993). Os filtros para redução do *speckle* Frost, Gamma e Lee com janelas 3x3, 5x5, e 7x7 foram aplicados e testados. Optou-se pela utilização da janela 5x5 para todos os filtros, pois esta apresentou os melhores resultados quando aplicada à imagem original.

Desse modo, as imagens submetidas às análises de textura foram: 1) Imagem original; 2) Imagem filtrada de Frost 5x5 (Frost5x5); 3) Imagem filtrada de Gamma 5x5 (Gamma5x5) e 4) Imagem filtrada de Lee 5x5 (Lee5x5). O programa *texture* gerou então um *layer* de medidas correspondente para cada imagem.

As melhores medidas de textura para cada par de classes foram selecionadas através da análise visual dos gráficos bem como pelos maiores valores de  $F_d$  gerados pelo programa *texture*, de forma que estes dois procedimentos se complementassem. Os valores de  $F_d$  gerados pelo programa *texture* foram exportados para uma planilha eletrônica, onde os dados puderam ser mais facilmente manipulados e analisados.

Com as melhores medidas selecionadas, as bandas de textura foram geradas no programa *filter texture* que utiliza um método de filtragem espacial e requer, além dos parâmetros de entrada para a geração das medidas de Haralick citados acima, o tamanho da janela de aquisição das medidas de textura (Van Der Sanden, 1997). A janela escolhida foi a 5x5, pois esta apresentou um tempo computacional bem menor quando comparada à janelas maiores.

Cabe ressaltar que as imagens RADARSAT-1 originais (CEOS) foram transformadas do formato “Float Point” (16 bits) para o formato “Byte” (8 bits) a fim de diminuir o tempo de processamento computacional e o tamanho dos arquivos.

Primeiramente efetuou-se o ajuste dos valores máximos do histograma das imagens para a obtenção do melhor contraste, representado por uma linha vertical na Figura 4.7a. As imagens transformadas para “byte” foram então geradas através da ferramenta *Band Math* (matemática de bandas) do aplicativo ENVI com uma função simples (byte(round(b1\*(255./40000)) < 255, por exemplo).

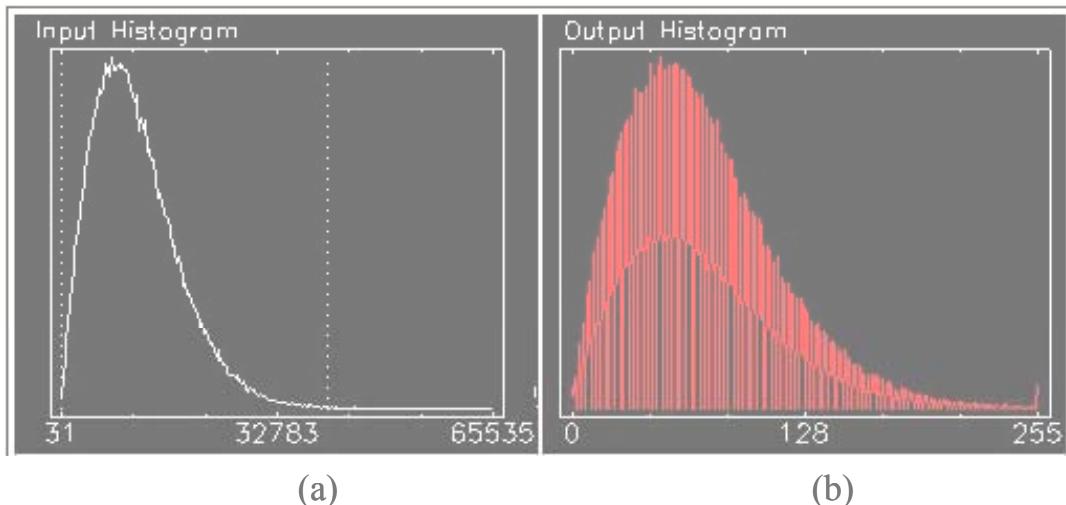


FIGURA 4.7 - Representação do ajuste do histograma. (a) Imagem de entrada; (b) Imagem de saída.

Após a geração das bandas de textura, as mesmas foram transformadas do formato “Float Point” para “Byte” seguindo mesmo procedimento descrito acima.

#### 4.2.3.4 Classificação das Imagens

Primeiramente foram realizadas as classificações das imagens RADARSAT-1 original, em seguida das imagens filtradas e por último das imagens de textura que foram classificadas pelo método de classificação pontual/contextual (Máxima Verossimilhança/ICM) no programa MAXVER/ICM desenvolvido em ambiente ENVI

3.4 (Vieira, 1996) (seção 2.4.1.1). O programa permite o ajuste das seguintes distribuições: Normal; Raiz quadrada da Gama; Amplitude; Amplitude G0; Log normal e Weibull (Vieira et al., 1997).

Após o procedimento das classificações foram construídas matrizes de confusão através de amostras de testes, utilizadas como dado de referência, para avaliar a quantidade de *pixels* classificados correta e incorretamente. A proporção de amostras corretamente classificadas corresponde à razão entre a soma da diagonal principal da matriz de confusão (amostras corretamente classificadas) e a soma de todos os elementos desta matriz (número total de amostras).

O método utilizado para avaliar a exatidão da classificação com matrizes de confusão foi o Coeficiente de Concordância *Kappa* (Rosenfield e Fitzpatrick, 1986; Hudson e Ramm, 1987; Foody, 1992). Este tem a vantagem de levar em consideração todos os elementos da matriz de confusão e não somente os elementos da diagonal. Portanto o coeficiente *Kappa* estima a proporção de acerto que efetivamente ocorre. O coeficiente *Kappa* é dado por:

$$\hat{k} = \frac{\theta_1 - \theta_2}{1 - \theta_2} \quad (4.6)$$

sendo,

$$\theta_1 = \sum_{i=1}^I \frac{x_{ii}}{N} \quad (4.7)$$

$$\theta_2 = \sum_{i=1}^I \frac{x_{i+}x_{+i}}{N^2} \quad (4.8)$$

onde  $x_{ii}, \dots, x_{i+}, \dots, x_{+i}, \dots N$  e  $I$  é o número total de classes da matriz de confusão.

O coeficiente *Kappa* pode assumir valores menores ou iguais a 1, podendo inclusive ter valores negativos. Quando todas as amostras são corretamente classificadas, ou seja, todos os elementos da matriz de confusão fora da diagonal possuem valores nulos, o

coeficiente *Kappa* possui valor 1. Valores de *Kappa* pequenos indicam que a classificação não apresentou bons resultados (Landis e Koch, 1977). Os autores propuseram a tabela abaixo, onde os valores *Kappa* iguais a 1 indicavam que as amostras tinham sido corretamente classificadas.

TABELA 4.7 - Conceitos de eficiência para o *Kappa*.

<b><i>Kappa</i></b>	<b>Conceito</b>
< 0	Péssima
$0 < k \leq 0,2$	Má
$0,2 < k \leq 0,4$	Razoável
$0,4 < k \leq 0,6$	Boa
$0,6 < k \leq 0,8$	Muito Boa
$0,8 < k \leq 1,0$	Excelente

FONTE: Landis e Koch (1977, p.165).



## CAPÍTULO 5

### RESULTADOS E DISCUSSÃO

O capítulo está dividido em quatro partes. Na primeira parte é feita uma análise visual das imagens no processo de escolha das classes de estudo. Na segunda parte apresenta-se a composição e avaliação das amostras de treinamento e teste. Na terceira parte apresentam-se os resultados da seleção das medidas de textura e a geração das imagens de textura. Na quarta parte são avaliados os resultados das classificações realizadas.

#### 5.1 Seleção das Classes de Estudo e Análise Visual

Como já mencionado na seção 4.2.3.1 foram feitas análises visuais nas imagens RADARSAT-1 quanto ao tom de cinza das principais classes de uso da terra encontradas na área de estudo. No exemplo de solo exposto ilustrado na Figura 4.4, um único talhão apresentou tons de cinza claro, médio e escuro. A seguir são apresentadas algumas características que governam o retroespalhamento, e consequentemente, as variações de tons de cinza que aparecem nas imagens para os principais alvos agrícolas na área de estudo.

Para uma área de solo exposto, as características que governam a refletividade SAR são o teor de umidade do solo e a rugosidade superficial (Ulaby et al., 1986b). O comportamento dessa classe seria determinado primeiramente pelo teor de umidade do solo e em segundo lugar pela rugosidade para a banda C para ângulos de incidência menores que 30° (Dobson e Ulaby, 1981). Apesar da umidade dos solos nas datas de 30/jan e 14/fev fosse relativamente alta (Tabela 3.2) considera-se sua importância secundária, pois o ângulo de incidência foi relativamente grande (45-47,8°).

As áreas com solo exposto que não foram aradas ou gradeadas têm baixa rugosidade, consequentemente, são consideradas lisas pelo sensor e possuem baixo retroespalhamento, aparecendo sempre em tons escuros. A presença de sulcos nos solos nus preparados para o plantio aumenta a rugosidade, aumentando, portanto, o

retroespalhamento destas áreas, que aparecem nas imagens com tons mais claros de cinza. A direção de linha de sulcamento ou de plantio em relação à direção de imageamento também condiciona o comportamento destas áreas. Áreas com sulcos perpendiculares ao sentido de imageamento têm normalmente retroespalhamento maior que áreas com o mesmo tipo de preparo do solo, mas com sulcos paralelos ao sentido do imageamento, como citado por Ulaby et al. (1986b) e Formaggio et al. (2001).

Entre os alvos agrícolas de maior ocorrência na área de estudo encontra-se a cultura de cana-de-açúcar. Os talhões de cana-de-açúcar analisados neste trabalho apresentavam grande diversidade de estádios fenológicos, arquitetura e altura de plantas e direção de linhas de plantio, ocasionando heterogeneidade nesta classe. Desse modo, a classe de cana-de-açúcar foi dividida em duas classes: cana-de-açúcar1 com tonalidade escura e cana-de-açúcar2 com tonalidade média.

A Figura 5.1 ilustra um exemplo da classe cana-de-açúcar1, onde o talhão é representado pela cor vermelha-escura delimitada por um contorno de cor vermelha numa amostra da imagem (a) (LANDSAT-7/ETM+ de 23/02/2003). Observa-se que a tonalidade escura ocorreu em todas as imagens RADARSAT-1 (b), (c) e (d) havendo pouca variação de tonalidade entre as mesmas. A fotografia (e) ilustra a classe de cana-de-açúcar com arquitetura erectófila em uma área do talhão.

Este padrão tonal observado para essa variedade de cana-de-açúcar pode ser explicado pelo fato de a cultura estar num estágio de crescimento mais avançado cobrindo totalmente o solo e possuir dossel bem fechado, eliminando qualquer efeito da direção da linha de plantio e solo-planta causando *double bounce*, o que poderia ocasionar altos valores de retroespalhamento. Por outro lado, a orientação predominantemente vertical dos caules e das folhas tem uma menor atenuação da radiação incidente polarizada horizontalmente (HH), o que poderia justificar os baixos valores de retroespalhamento, e, consequentemente, uma tonalidade mais escura presente na imagem (Dobson et al., 1995; Ulaby et al., 1982).

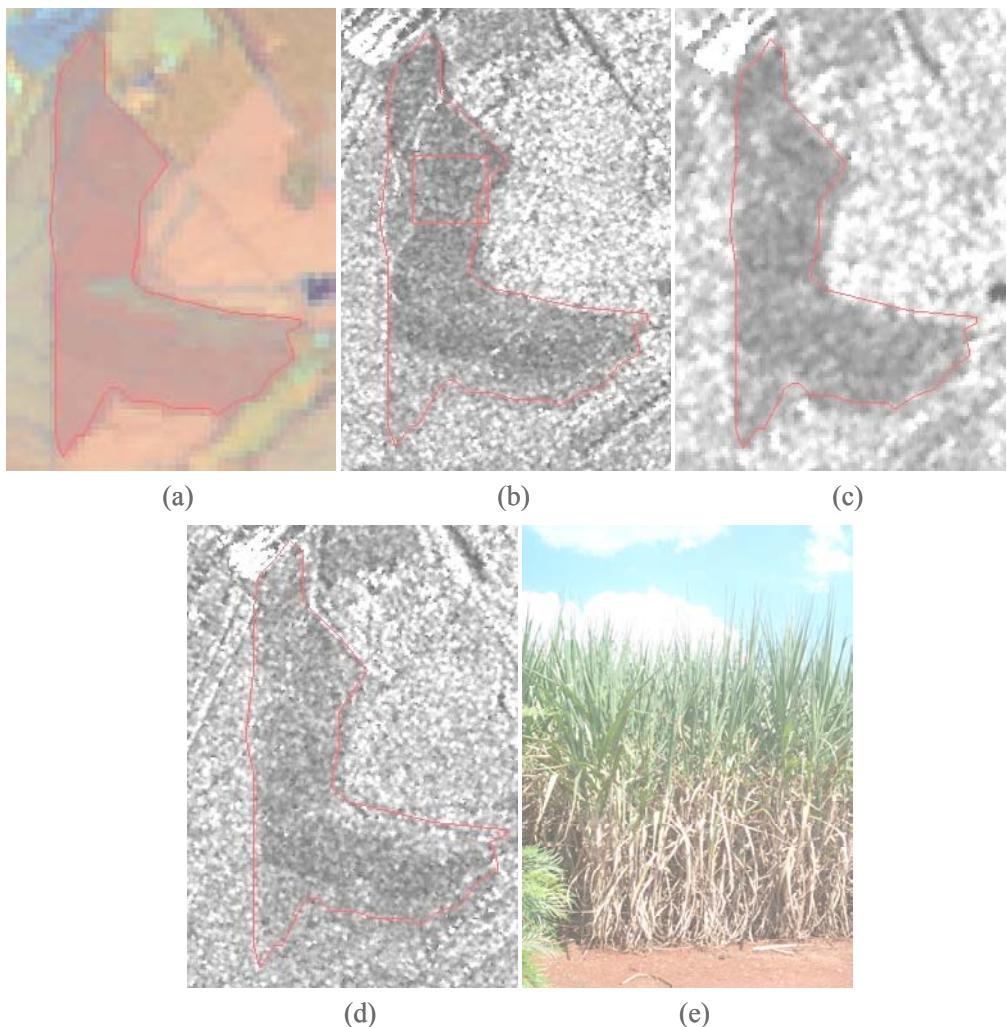


FIGURA 5.1 - Exemplo de tonalidade escura para um talhão de cana-de-açúcar. (a) ETM+ R(4)G(5)B(3), (b) F5D, (c) S7D, (d) F5A, (e) fotografia da cultura de cana-de-açúcar adulta de 25/fev/2003.

A Figura 5.2 ilustra um exemplo de classe cana-de-açúcar2, onde o talhão é representado pela cor amarela-escura delimitada por um contorno retangular de cor amarela numa amostra da imagem (a) (LANDSAT-7/ETM+ (23/02/2003). Observa-se que a tonalidade média ocorreu em todas as imagens RADARSAT-1 (b), (c) e (d) havendo pouca variação de tonalidade entre as mesmas. A fotografia (e) ilustra a classe de cana-de-açúcar com arquitetura erectófila com dobras presentes nas extremidades das folhas.

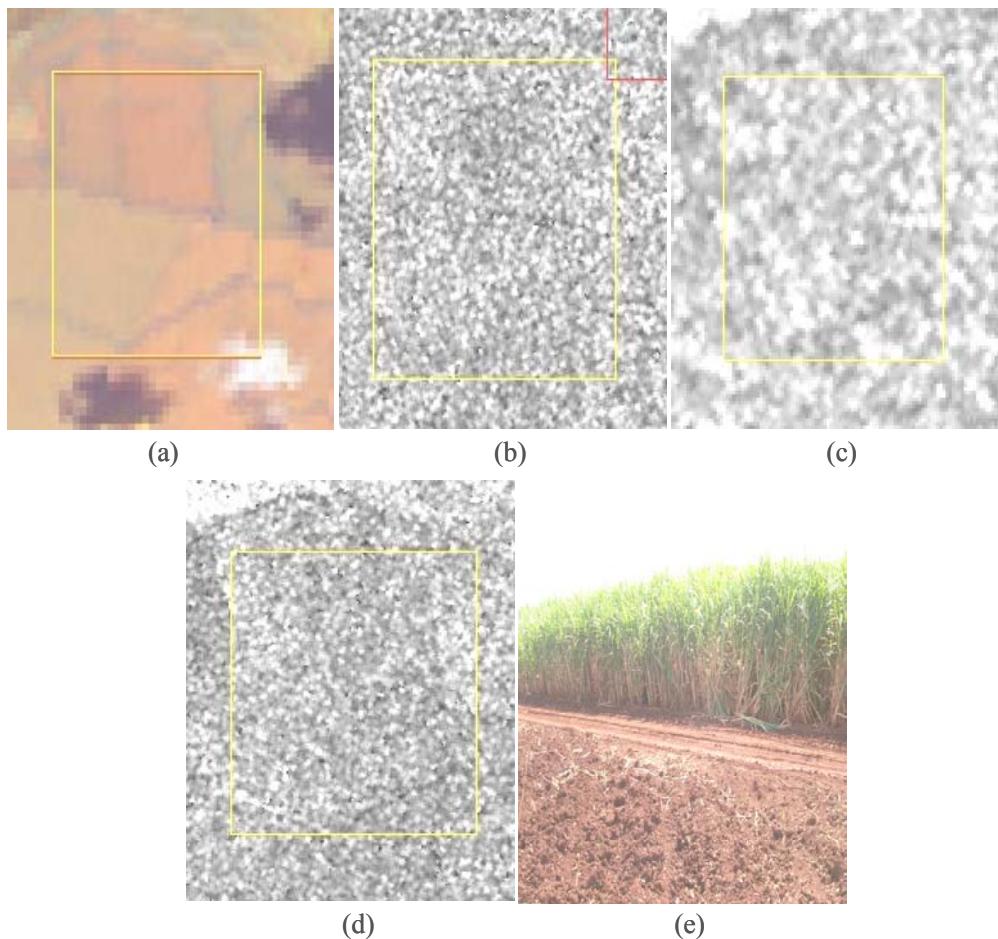


FIGURA 5.2 - Exemplo de tonalidade média para um talhão de cana-de-açúcar. (a) ETM+ R(4)G(5)B(3), (b) F5D, (c) S7D, (d) F5A, (e) fotografia da cana-de-açúcar adulta de 25/fev/2003.

Este padrão tonal observado para essa classe de cana-de-açúcar2, assim como para classe de cana-de-açúcar1, pode ser explicado pelo fato de a cultura estar num estágio de crescimento mais avançado, cobrir totalmente o solo e possuir dossel bem fechado eliminando qualquer efeito da direção da linha de plantio e solo-planta causando *double bounce*, o que poderia ocasionar altos valores de retroespalhamento. Diferentemente da classe de cana-de-açúcar1, a classe de cana-de-açúcar2 apresenta uma classe de cana-de-açúcar com arquitetura erectófila, mas com dobra nas extremidades das folhas, o que resulta numa maior atenuação da radiação incidente polarizada horizontalmente (HH) o

que poderia justificar maiores valores de retroespalhamento, e consequentemente, uma tonalidade média presente na imagem (Dobson et al., 1995; Ulaby et al., 1982).

Para a cultura de soja, os talhões analisados nesse trabalho encontravam-se na fase de máximo desenvolvimento, com dossel fechado cobrindo totalmente o solo, eliminando qualquer efeito da direção de plantio e solo-planta no retroespalhamento. Desse modo, o retroespalhamento é atenuado pela superfície do dossel, ocasionando um tom de cinza médio nas imagens (Figura 5.3). Variações de tons de cinza ocorreram em alguns talhões localizados próximos à área de encosta devido aos efeitos causados pelo relevo e declividade. É preciso ressaltar que a área de estudo não possui grandes variações do relevo.

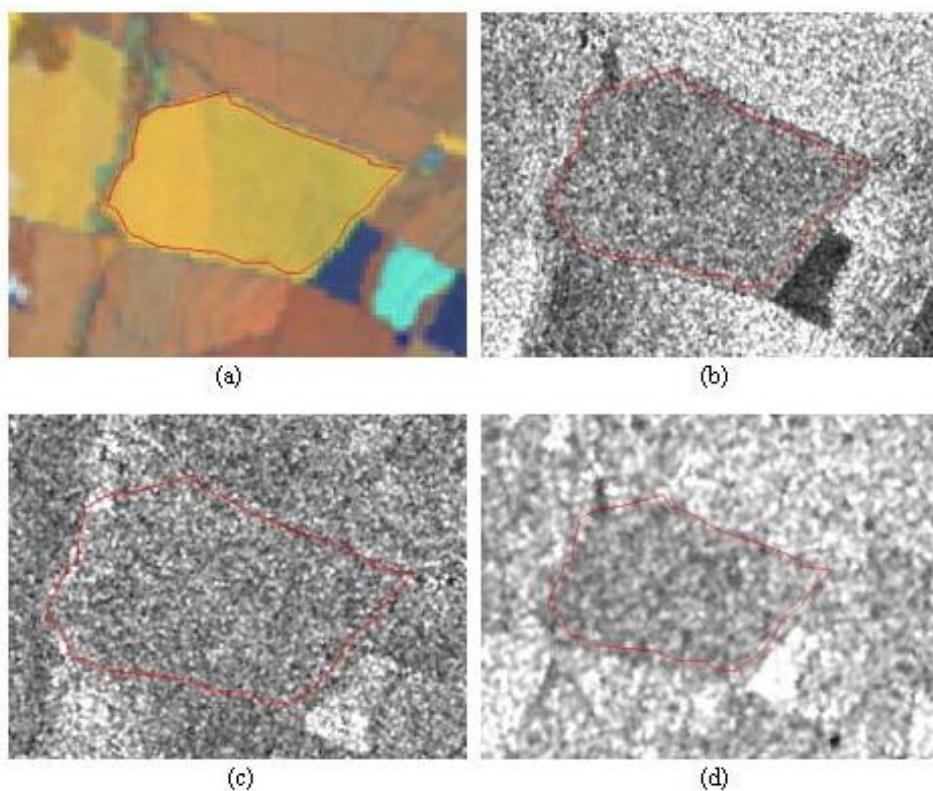


FIGURA 5.3 - Exemplo de tonalidade média para um talhão de soja. (a) ETM+ R(4)G(5)B(3), (b) F5D, (c) F5A, (d) S7D.

As outras classes, isto é, água, área urbana e solo com palha apresentaram homogeneidade nos tons de cinza para todas as imagens RADARSAT-1 utilizadas. A classe água apresentou tom de cinza escuro bem característico. A classe área urbana

apresentou tom de cinza claro com uma textura característica e a classe solo palha tons de cinza claros.

## 5.2 Seleção das Amostras de Treinamento e Teste

O conjunto de amostras de treinamento e teste utilizado para as imagens F5D, F5A e S7D encontra-se nas Tabelas 5.1, 5.2 e 5.3, respectivamente.

TABELA 5.1 - Número de amostras por classe de uso para a imagem F5D.

<b>Classes de uso</b>	<b>Nº de amostras de treinamento</b>	<b>Nº de pixels</b>	<b>Nº de amostras de teste</b>	<b>Nº de pixels</b>
Água (rios e lagos).	09	15034	08	14311
Área urbana	20	12815	19	11723
Soja	207	135550	188	145523
Cana de açúcar 1	57	30356	60	37440
Cana de açúcar 2	116	76141	119	78822
Solo exposto 1	38	24463	40	25006
Solo exposto 2	19	10957	20	12162
Solo exposto 3	50	30933	51	31076
Solo palha	25	15379	26	16964
Total	541	351628	531	373027

TABELA 5.2 - Número de amostras por classe de uso para a imagem F5A.

<b>Classes de uso</b>	<b>Nº de amostras de treinamento</b>	<b>Nº de pixels</b>	<b>Nº de amostras de teste</b>	<b>Nº de pixels</b>
Água (rios e lagos).	04	6384	04	6021
Área urbana	24	16032	23	17444
Soja	162	174373	181	182828
Cana de açúcar 1	100	84223	113	100631
Cana de açúcar 2	46	39041	44	39614
Solo exposto 1	44	24196	50	30659
Solo exposto 2	15	8173	14	8524
Solo exposto 3	33	23501	36	27032
Solo palha	15	15687	17	16585
Total	443	391610	482	429338

TABELA 5.3 - Número de amostras por classe de uso para a imagem S7D.

Classes de uso	Nº de amostras de treinamento	Nº de pixels	Nº de amostras de teste	Nº de pixels
Água (rios e lagos)	04	5230	04	5723
Área urbana	10	6563	10	7174
Soja	90	64941	98	75944
Cana de açúcar 1	17	11448	16	10752
Cana de açúcar 2	63	40477	62	40944
Solo exposto 1	05	2139	05	2006
Solo exposto 2	07	2563	07	2439
Solo exposto 3	09	4737	09	5012
Solo palha	05	2481	05	2445
Total	210	140579	216	152439

A fim de avaliar a amostragem realizada efetuou-se a extração da média (M) e o desvio padrão (DP) dos níveis de cinza (0-255) das amostras de treinamento e teste coletadas nas imagens F5D, F5A e S7D (Tabela 5.4).

TABELA 5.4 - Valores de Média e Desvio Padrão dos níveis de cinza de amostras de treinamento/teste.

Classe de uso	F5D				F5A				S7D			
	Amostras de treinamento		Amostras de teste		Amostras de treinamento		Amostras de teste		Amostras de treinamento		Amostras de teste	
	M	DP	M	DP	M	DP	M	DP	M	DP	M	DP
Agua	16,3	8,5	16,3	8,7	16,3	8,6	16,5	8,6	20,6	5,4	20,5	5,3
Área urbana	121,6	71,9	118,9	72,6	123,3	73,7	120,6	72,5	187,5	54,6	184,7	55
Cana-de-cúcar1	56,2	31,6	57	31,8	69,6	37,9	69,2	37,7	86,1	25,4	89,5	26
Cana-de-cúcar2	89,5	47,7	89,2	47,5	92,6	49,4	92,9	49,4	130,1	35,3	129,6	35,4
Soja	76,7	40,4	76,3	40,3	76,1	40,3	76	40,2	116,6	31,7	117,1	31,5
Solo exposto1	39	22,5	39,6	23	40,2	23,3	40,1	23,5	59,4	24,1	59	24,1
Solo exposto2	105,6	57,7	101,5	56	102,9	55,7	100,8	54,4	145,6	45,5	142,6	42,6
Solo exposto3	65,7	37,4	64,8	36,9	63,2	34,6	62,6	34,2	101,1	29,2	102,3	30,1
Solo palha	110,7	58,6	109,7	58,9	108,9	57,9	110,4	57,7	124,4	33,9	123,6	33,6

M = Média.

DP = Desvio Padrão.

Pela análise da Tabela 5.4, observa-se que a média e o desvio padrão dos níveis de cinza das amostras de treinamento e teste foram praticamente iguais para as três imagens, o que mostra que a amostragem foi apropriada.

Observa-se também que os valores da média e desvio padrão dos níveis de cinza das amostras de treinamento e teste nas imagens F5D e F5A, com exceção da classe cana-

de-açúcar1, foram similares para todas as outras classes. Desse modo, pode-se inferir que o efeito da direção de visada (imagem ascendente-F5A e descendente-F5D) no retroespalhamento e, consequentemente, nos tons de cinza para fins de classificação digital são mínimos, o que está de acordo com Wood et al. (2002).

Para a imagem S7D, as médias apresentaram maiores valores para todas as classes em relação às imagens F5D e F5A. Isso pode ter ocorrido devido ao fato de a imagem S7D apresentar resolução espacial inferior, que torna os tons de cinza mais suavizados.

Verifica-se ainda na imagem F5D que a classe soja apresentou valor de média próximo ao das classes cana-de-açúcar2 e solo exposto3, o que pode resultar numa maior confusão na classificação digital por *pixel*. Na imagem F5A, a classe soja apresentou valor de média próximo ao das classes cana-de-açúcar1 e solo exposto3. Na imagem S7D a classe soja apresentou valor de média próximo ao das classes cana-de-açúcar2 e solo palha.

### **5.3 Seleção das Medidas e Bandas de Textura**

Abaixo são apresentados os resultados obtidos a partir da análise das medidas de textura e os respectivos pares de classe. Os parâmetros que apresentaram os melhores resultados e os valores do fator discriminante  $F_d$  que indicam o potencial de discriminação entre e intraclasse duas a duas são apresentados nas tabelas e figuras abaixo para as imagens F5D, F5A e S7D. As bandas de textura correspondem às medidas que melhor discriminam os alvos de interesse a partir da análise dos valores do fator discriminante  $F_d$  e da análise visual dos gráficos.

A classe água não foi incluída nas tabelas, pois esta apresentou alta discriminação em relação às outras classes para praticamente todas as medidas de textura. Assim, as tabelas são constituídas de 28 pares de classe (referentes à combinação de 8 pares de classe) ao invés de 36 pares de classe (referentes à combinação das 9 classes).

### 5.3.1 Imagem F5D

Entre as 25 medidas de textura analisadas, sendo 7 de primeira ordem e 18 de Haralick, somente 6 medidas de Haralick e uma de primeira ordem (média) foram as que apresentaram maior potencial de discriminação para os 28 pares de classe analisados (Tabela 5.5).

TABELA 5.5 - Medidas selecionadas pelo fator discriminante  $F_d$  para a imagem F5D.

Medida	Filtro	Pares de classes	$F_d$
Energia do vetor diferença		C1 e S	17,59
		S e SE1	94,21
		S e SE3	4,88
		C1 e C2	21,06
		C1 e SE1	6,14
		SE1 e SE3	10,82
		C2 e SE3	9,89
		C2 e SE1	74,10
Média do vetor soma	Frost 5x5	C2 e S	5,29
	Frost 5x5	S e SP	35,69
	Frost 5x5	S e SE2	26,87
	Frost 5x5	SE2 e SE3	12,12
	Frost 5x5	C2 e SP	6,56
	Frost 5x5	C2 e SE2	4,30
Cluster Prominence		AU e S	332,05
		AU e C1	202,87
		AU e C2	80,74
		AU e SE2	17,68
		AU e SE3	103,11
		AU e SP	16,33
Variância do vetor soma		AU e SE1	213,87
Variância do vetor diferença		C1 e SE2	29,25
		C1 e SP	37,89
Média	Frost5x5	C1 e SE3	2,26
	Frost5x5	SE3 e SP	14,41
Contraste do vetor diferença		SE1 e SE2	57,85
		SE1 e SP	78,82
		Frost 5x5	1,23

Legenda: AU - Área urbana, C1 – Cana-de-açúcar1, C2 – Cana-de-açúcar2, S - Soja, SE1 - Solo exposto1, SE2 - Solo exposto2, SE3 - Solo exposto3 e SP - Solo palha.

As medidas de textura energia do vetor diferença, *cluster prominence*, variância do vetor soma, variância do vetor diferença e contraste do vetor diferença apresentaram os melhores resultados quando aplicada à imagem original. As medidas de textura média do vetor soma, média e contraste do vetor diferença apresentaram maior potencial de discriminação quando aplicadas à imagem filtrada pelo filtro Frost5x5. Esta última apenas para os pares de classe SE2/SP. No total foram gerados 8 gráficos referentes às medidas geradas a partir das imagens filtradas e da imagem original.

Pela análise dos valores do fator discriminante  $F_d$  apresentados na Tabela 5.5 e a dos gráficos da Figura 5.4 pode-se observar que a medida de textura energia do vetor diferença foi a medida que separou o maior número de pares de classe mais eficientemente. Entretanto, com exceção dos pares de classe S/SE1 e C2/SE1 que apresentaram alto valor de  $F_d$ , o restante dos pares de classe apresentaram um potencial de discriminação baixo. A média do vetor soma foi a melhor medida para 6 pares de classe onde o potencial de discriminação foi consideravelmente baixo para todos os pares de classe. A medida *cluster prominence* apresentou alto potencial de discriminação para os pares de classe AU/S, AU/C1, AU/C2 e AU/SE3. A variância do vetor soma foi uma boa medida para separar o par de classes AU/SE1 com alto valor de  $F_d$ . Para os pares de classes C1/SE3 e SE3/SP a melhor medida foi à variância do vetor diferença, mas com valores de  $F_d$  relativamente baixos. A média foi a melhor medida para 2 pares de classe, porém, com baixos valores de  $F_d$  e consequentemente baixo potencial de discriminação. O contraste do vetor diferença foi uma boa medida para separar as classes SE1/SE2 e SE1/SP com altos valores de  $F_d$ .

Pode-se notar que uma determinada medida não se aplica na separação de todas as classes ao mesmo tempo, mas sim em alguns pares de classes e as melhores medidas selecionadas podem não apresentar bom potencial de discriminação para algumas ou todas as classes correspondentes.

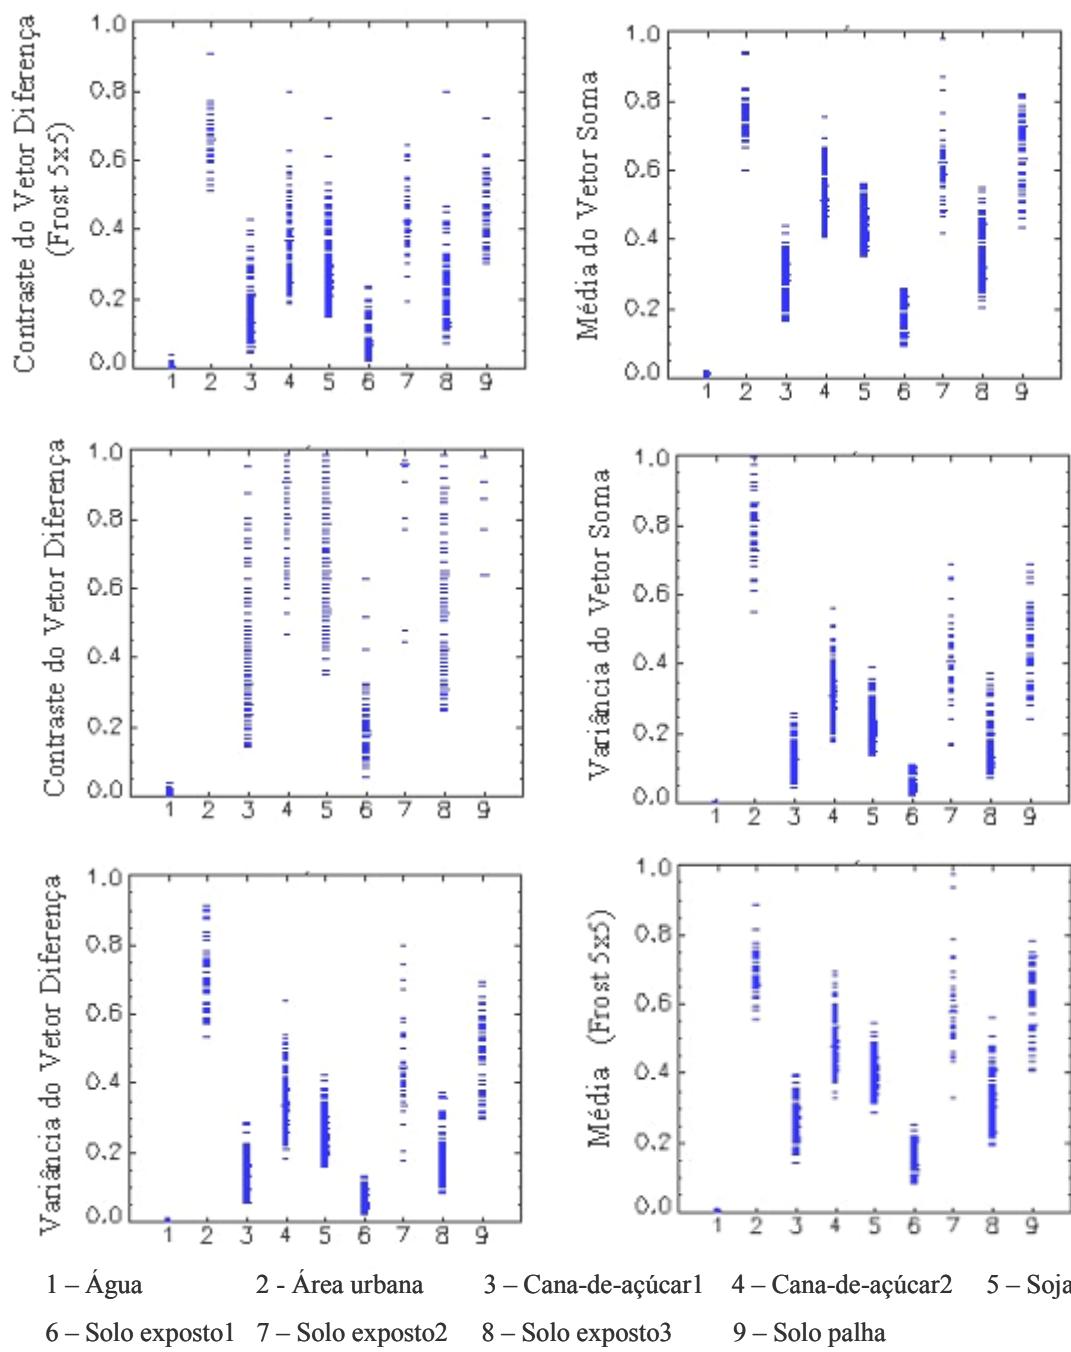


FIGURA 5.4 - Ilustração de gráficos de distribuição de classes em relação à medidas de textura para a imagem F5D.

(continua)

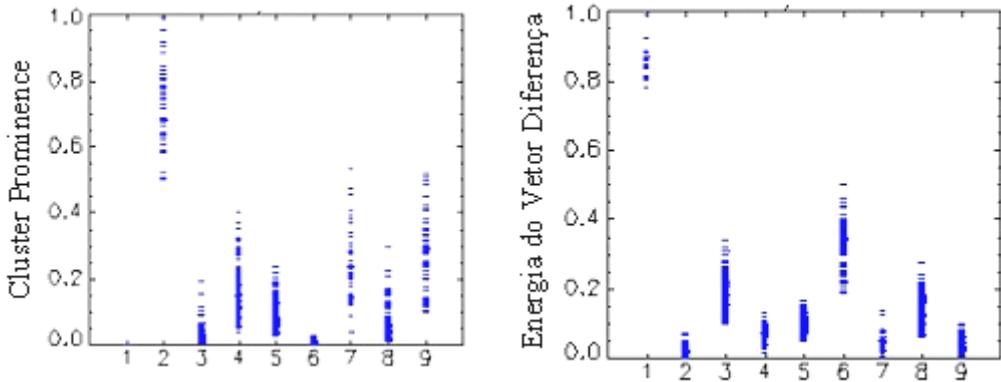


FIGURA 5.4 - (conclusão).

As imagens de textura geradas correspondem às medidas representadas na Figura 5.4, ou seja, 8 bandas foram geradas e podem ser visualizadas no apêndice A1.

### 5.3.2 Imagem F5A

Para a imagem F5A 8 medidas de textura (7 medidas de Haralick e 1 de primeira ordem (média)) foram selecionadas entre as que apresentaram maior potencial de discriminação para 28 pares de classe analisados (Tabela 5.6).

As medidas de textura energia do vetor diferença, *cluster prominence*, entropia do vetor diferença, variância do vetor diferença, entropia (esta última somente para as classes C2/SE2), contraste do vetor diferença e qui-quadrado apresentaram os melhores resultados quando aplicada à imagem original. As medidas de textura entropia e média apresentaram maior potencial de discriminação quando aplicadas à imagem filtrada pelo filtro de Frost5x5 e Lee5x5, respectivamente. No total foram gerados 10 gráficos referentes às medidas geradas a partir das imagens filtradas e da imagem original.

TABELA 5.6 - Medidas selecionadas pelo fator discriminante  $F_d$  para a imagem F5A.

Medida	Filtro	Par de classes	$F_d$
Energia do vetor diferença		S e C1	2,13
		S e SE1	51,14
		S e SE3	9,6
Cluster Prominence		AU e S	370,43
		S e SE2	30,6
		AU e C1	227,41
		AU e C2	52,54
		AU e SE2	14,5
		AU e SE3	102,6
		AU e SP	16,03
		C1 e SE2	23,42
Entropia do vetor diferença		C1 e SE1	18,14
Variância do vetor diferença		S e C2	10,08
		S e SP	33,44
		AU e SE1	187,63
		C1 e C2	10,3
		C1 e SP	24,55
		C2 e SE3	16,2
		SE1 e SE2	70,41
		SE2 e SE3	20,72
		SE3 e SP	19,21
Entropia	Frost5x5	C1 e SE3	3,1
		C2 e SE2	7,96
Média	Frost5x5	SE1 e SE3	8,18
		SE2 e SP	1,58
Contraste do vetor diferença		C2 e SE1	57,06
		SE1 e SP	78,95
Qui-quadrado		C2 e SP	4,69

Legenda: AU - Área urbana, C1 – Cana-de-açúcar1, C2 – Cana-de-açúcar2, S - Soja, SE1 - Solo exposto1, SE2 - Solo exposto2, SE3 - Solo exposto3 e SP - Solo palha.

Pela análise dos valores do fator discriminante  $F_d$  apresentados na Tabela 5.6 e a dos gráficos da Figura 5.5, pode-se observar que a medida *cluster prominence*, semelhantemente à imagem F5D, apresentou alto potencial de discriminação para as classes AU/S, AU/C1 e AU/SE3. A variância do vetor diferença apresentou alto potencial de discriminação para as classes AU/SE1 e SE2/SE3, e a medida contraste do vetor diferença para a classe SE1/SP. As demais medidas e os pares de classes correspondentes apresentaram baixo potencial de discriminação.

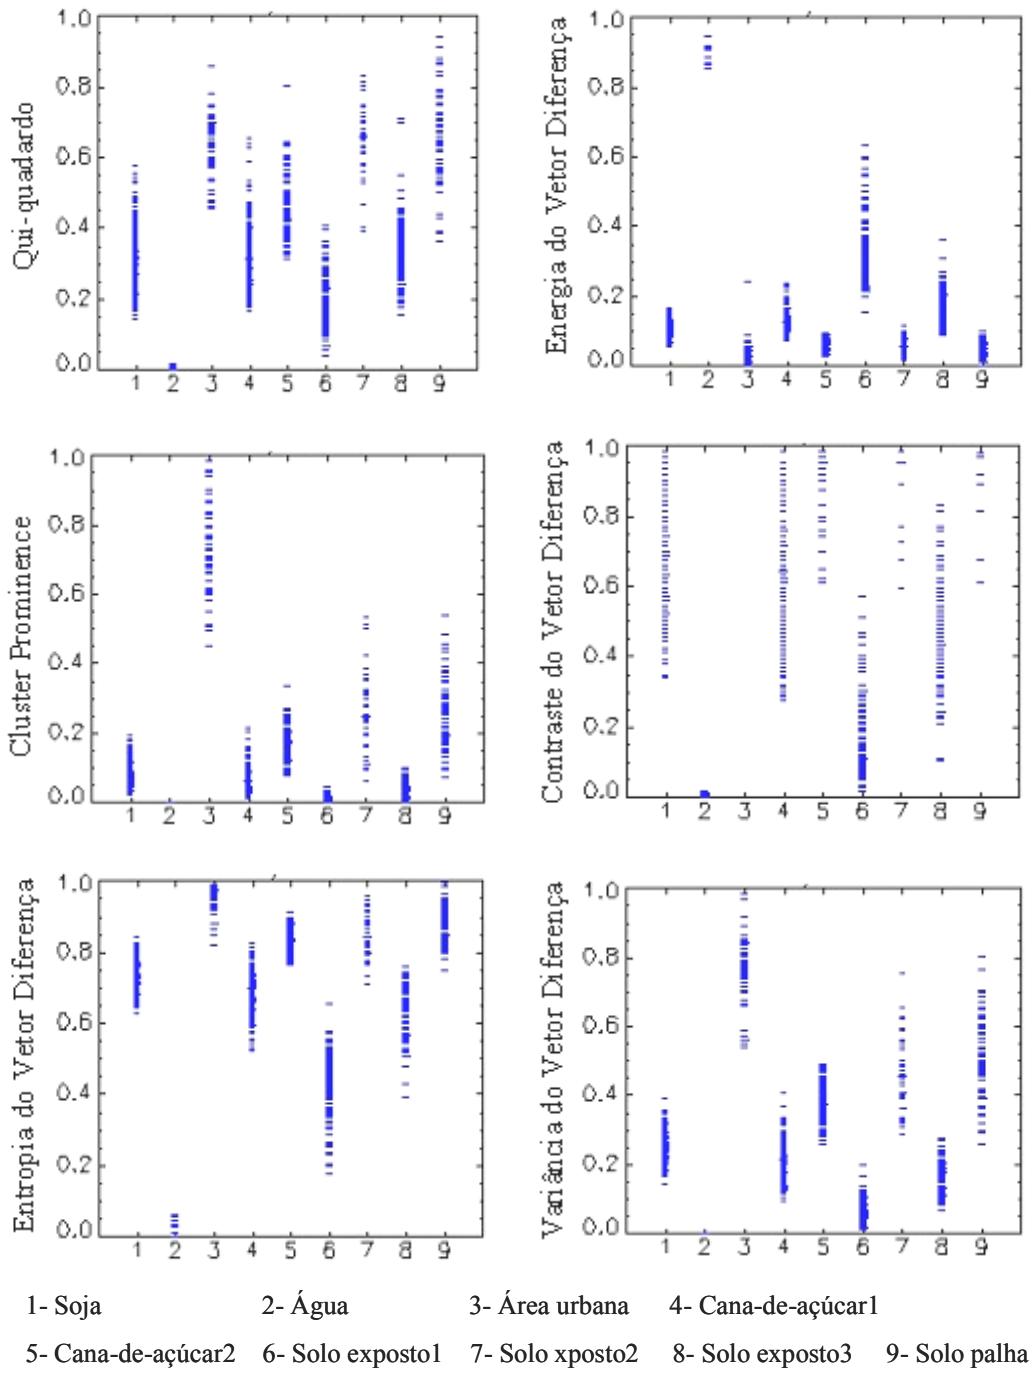


FIGURA 5.5 - Ilustração de distribuição de classes em relação às medidas de textura para a imagem F5A.

(continua)

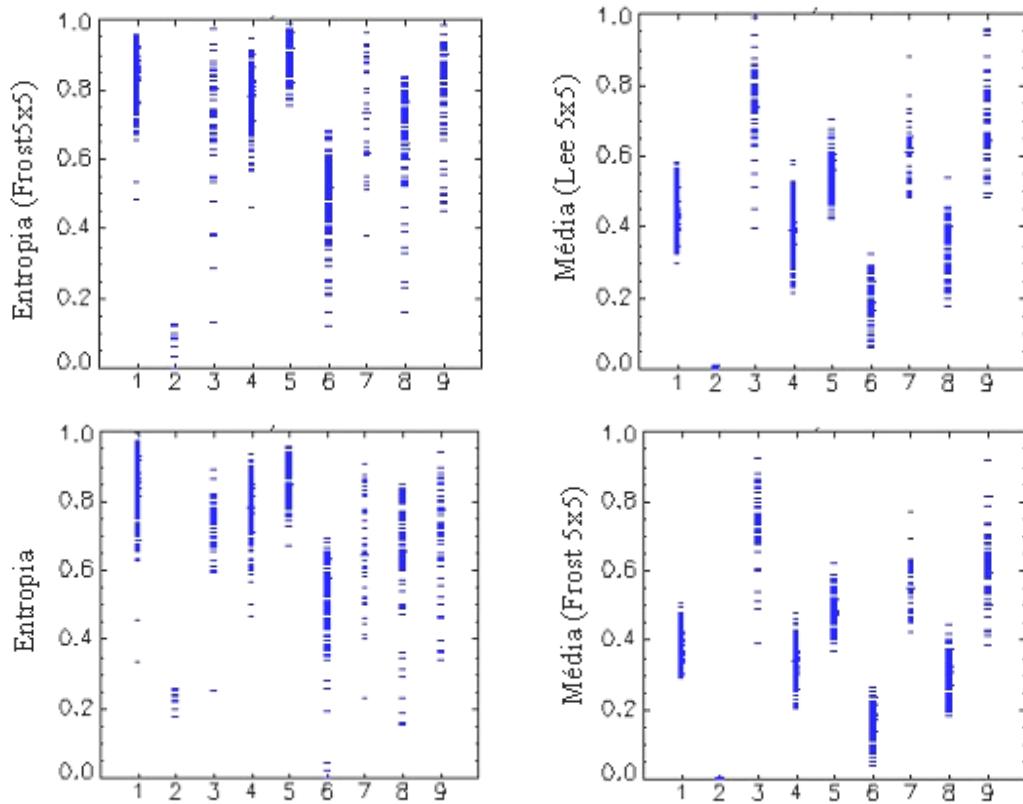


FIGURA 5.5 - (conclusão).

As imagens de textura geradas correspondem às medidas representadas na Figura 5.5, ou seja, 10 bandas foram geradas e podem ser visualizadas no apêndice A2.

### 5.3.3 Imagem S7D

Para a imagem S7D, 10 medidas de textura (8 medidas de Haralick e 2 de primeira ordem (desvio médio absoluto e média)) foram selecionadas entre as que apresentaram maior potencial de discriminação para 28 pares de classe analisados (Tabela 5.7).

As medidas de textura energia do vetor diferença, contraste, média do vetor soma, homogeneidade, energia, variância do vetor diferença, desvio médio absoluto, média (esta última somente para as classes SE1/SP), qui-quadrado e média do vetor diferença apresentaram os melhores resultados quando aplicadas à imagem original. A medida de textura média apresentou maior potencial de discriminação, ora quando aplicada à imagem filtrada pelo filtro de Frost5x5, ora pelo filtro de Gamma5x5. No total foram

gerados 12 gráficos referentes às medidas geradas a partir das imagens filtradas e da imagem original.

TABELA 5.7 - Medidas selecionadas pelo fator discriminante  $F_d$  para a imagem S7D.

Medida	Filtro	Par de classes	$F_d$
Energia do vetor diferença		S e C1 S e SE1	17,53 138,29
Contraste		AU e S	212,68
Média do vetor soma		C1 e C2	21,73
Homogeneidade		C1 e SE1	13,12
Energia		S e SE2	28,29
		S e SE3	9,74
		C2 e SE2	12,51
Variância do vetor diferença		AU e C1	99,98
		AU e C2	100
		AU e SE1	100
		AU e SP	100
		C1 e SE2	32,74
Desvio da média absoluto		AU e SE2	9,37
Média	Gama5x5	SE3 e SP	5,48
	Gama5x5	C1 e SE3	3,30
	Gama5x5	C1 e SP	17,80
	Frost5x5	C2 e SE1	63,64
	Frost5x5	C2 e SE3	11,10
	Frost5x5	C2 e SP	1,53
	Frost5x5	SE1 e SE3	15,10
	Frost5x5	C2 e S	3,86
	Frost5x5	SE1 e SP	28,99
Qui-quadrado		S e SP	3,34
Média do vetor diferença		AU e SE3	48,65
		SE1 e SE2	27,80
		SE2 e SE3	12,05
		SE2 e SP	3,71

Legenda: AU - Área urbana, C1 – Cana-de-açúcar1, C2 – Cana-de-açúcar2, S - Soja, SE1 - Solo exposto1, SE2 - Solo exposto2, SE3 - Solo exposto3 e SP - Solo palha.

Pela análise dos valores do fator discriminante  $F_d$  apresentados na Tabela 5.7 e a dos gráficos da Figura 5.6, observa-se que a medida de textura energia do vetor diferença apresentou alto potencial de discriminação para a classe S/SE1, a medida contraste para a classe AU/S, a medida variância do vetor diferença para as classes AU/C1, AU/C2,

AU/SE1 e AU/SP, a medida média para a classe C2/SE1. As demais medidas e os pares de classe correspondentes apresentaram baixo potencial de discriminação.

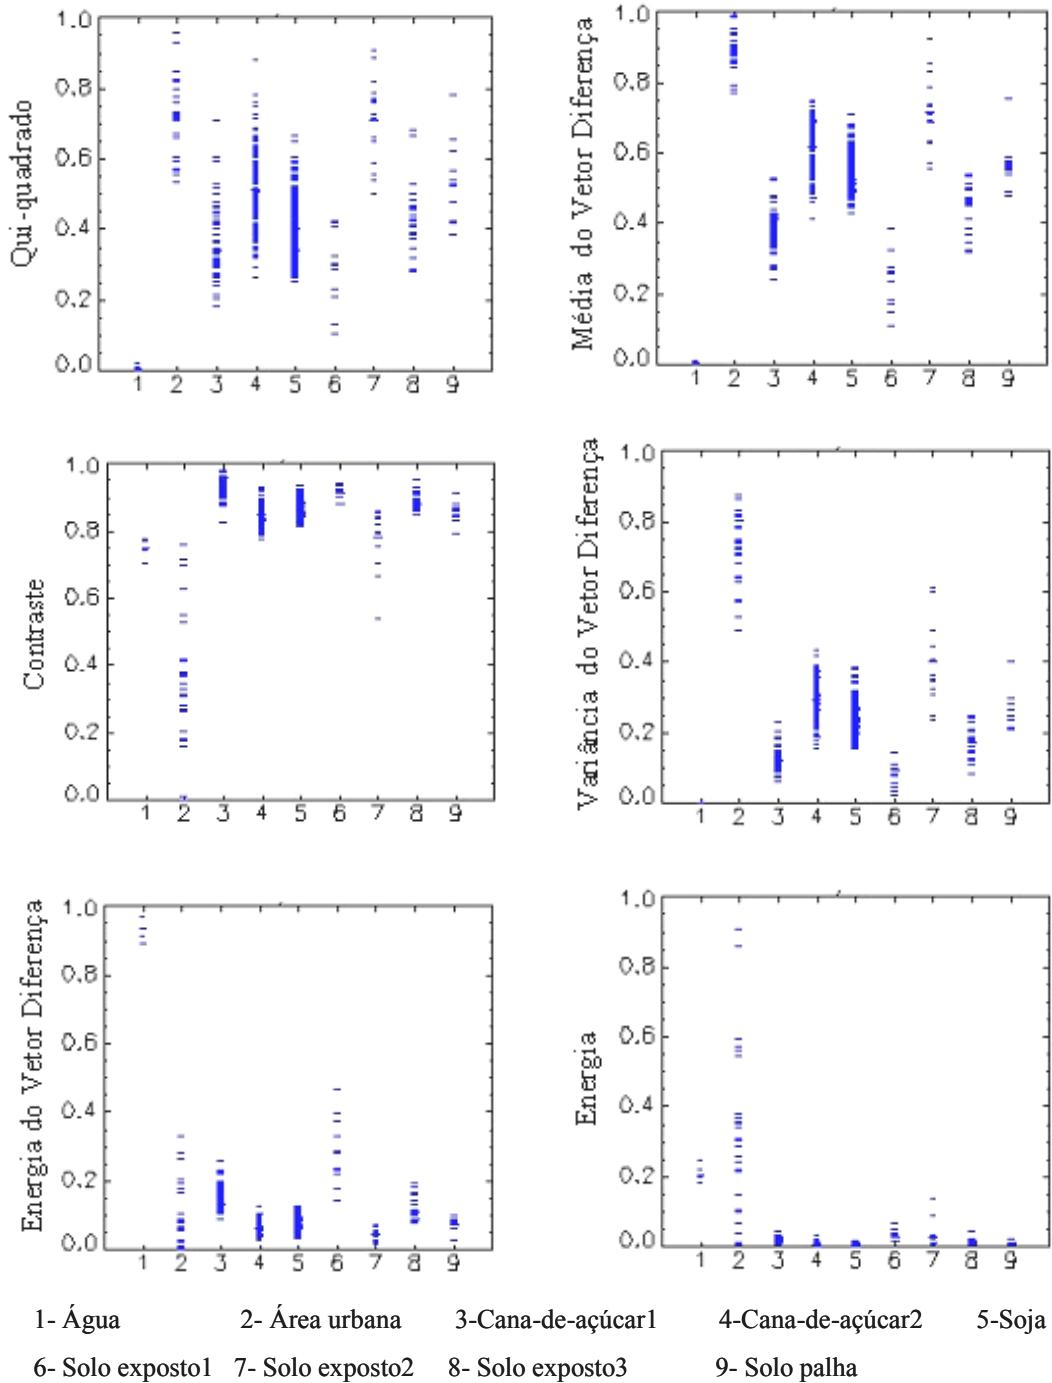


FIGURA 5.6 - Ilustração de distribuição de classes relacionados às medidas de textura para a imagem S7D.

(continua)

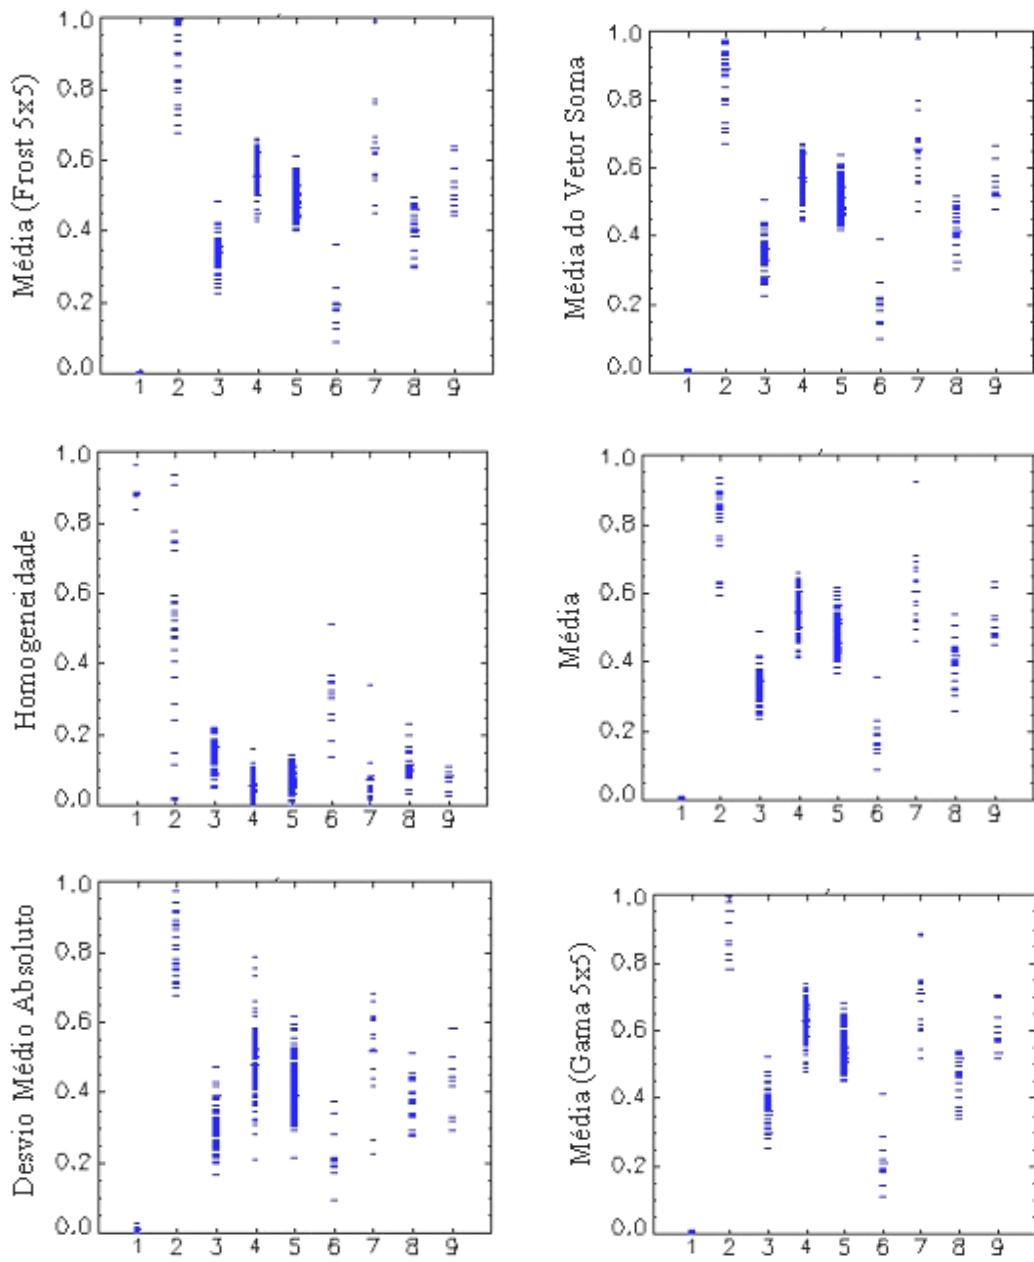


FIGURA 5.6 - (conclusão).

As imagens de textura geradas correspondem às medidas representadas na Figura 5.6, ou seja, 12 bandas foram geradas e podem ser visualizadas no apêndice A3.

#### 5.4 Classificação das Imagens

Foram realizadas três classificações: sobre a imagem original, imagens filtradas e imagens de textura.

A seguir são apresentados os resultados das classificações através da matriz de confusão e do valor *kappa* para as imagens F5D, F5A, S7D.

#### 5.4.1 Classificação da Imagem F5D

A imagem F5D original foi classificada utilizando o algoritmo ICM, onde cada classe foi ajustada às distribuições estatísticas Raiz Quadrada da Gama, Normal, Log normal ou Weibull.

A Figura 5.7 ilustra a classificação da imagem F5D original.

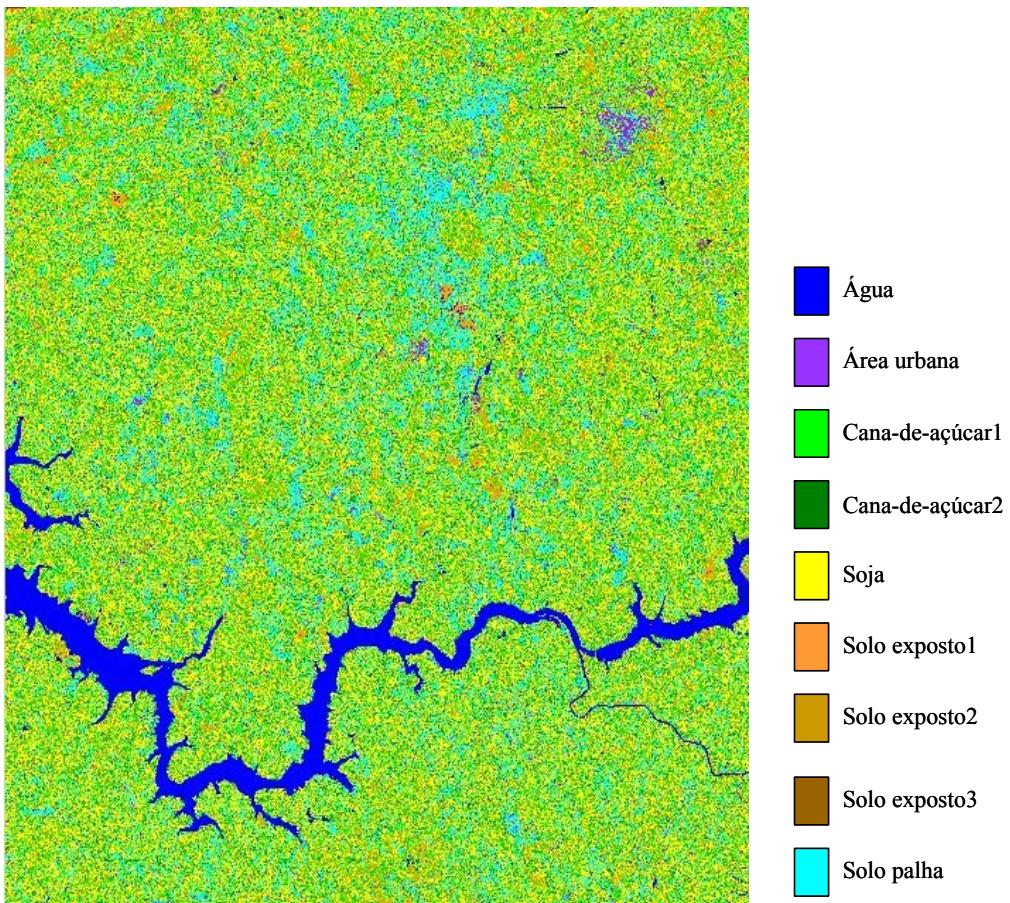


FIGURA 5.7 - Classificação da imagem F5D original.

A Tabela 5.8 mostra a matriz de confusão e o coeficiente de concordância *kappa* para a imagem F5D classificada.

TABELA 5.8 - Matriz de confusão da classificação da imagem F5D original.

classes	Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Referência (%)				Total	
						Solo exposto1	Solo exposto2	Solo exposto3	Solo palha		
Classificadas	Água	<b>100</b>	0,12	0,36	0,02	0,07	9,65	0,02	0,51	0,01	4,6
	Área urbana	0	<b>49,37</b>	0,01	1,56	0,2	0	9,78	0,24	15,21	2,99
	Cana-de-açúcar1	0	<b>4,76</b>	<b>31,24</b>	10,73	22,04	11,5	5,87	28,34	4,03	17,65
	Cana-de-açúcar2	0	3,23	1,90	<b>10,54</b>	9,26	0,16	9,21	3,97	4,69	6,99
	Soja	0	10,78	16,47	34,29	<b>44,65</b>	1,31	21,86	27,14	15,99	30,45
	Solo exposto1	0	3,98	48,08	3,42	10,04	<b>77,31</b>	2,84	32,46	0,78	17,6
	Solo exposto2	0	1,63	0,19	2,67	1,21	0,02	<b>1,4</b>	0,56	1,8	1,28
	Solo exposto3	0	0,24	0,66	0,47	0,7	0,01	0,3	<b>0,55</b>	0,09	0,51
	Solo Palha	0	25,89	1,1	36,3	11,83	0,05	48,73	6,23	<b>57,41</b>	17,93
	Total	100	100	100	100	100	100	100	100	100	100
Exatidão total		36,05%		<i>kappa</i> 0,2251							

Esta classificação mostra uma performance baixa na discriminação das classes em questão com uma exatidão total de apenas 36,05% e o valor de *kappa* de 0,2251. Apenas as classes água e solo exposto1 apresentaram uma boa discriminação atingindo uma porcentagem de acerto de 100% e 77,31% respectivamente. A classe solo palha apresentou uma discriminação razoável com uma porcentagem de acerto de 57,41%. As demais classes apresentaram uma discriminação ruim com uma porcentagem de acerto abaixo de 50%.

As razões para esse desempenho baixo pode ser atribuído ao fato de o número de *looks* da imagem F5D ser igual a 1, contendo, portanto, alto efeito do ruído *speckle* o que aumenta a confusão entre as classes.

Foram aplicados os filtros Frost5x5, Gamma5x5 e Lee5x5 de redução do ruído *speckle* na imagem original F5D e geradas as classificações para cada imagem filtrada. Observou-se que a classificação sobre a imagem filtrada de Frost5x5 apresentou o melhor resultado em relação às classificações realizadas com os outros dois filtros. A

classificação sobre a imagem filtrada de Frost5x5 apresentou resultado consideravelmente melhor que a imagem original.

A Figura 5.8 ilustra a classificação da imagem F5D com filtro de Frost5x5.

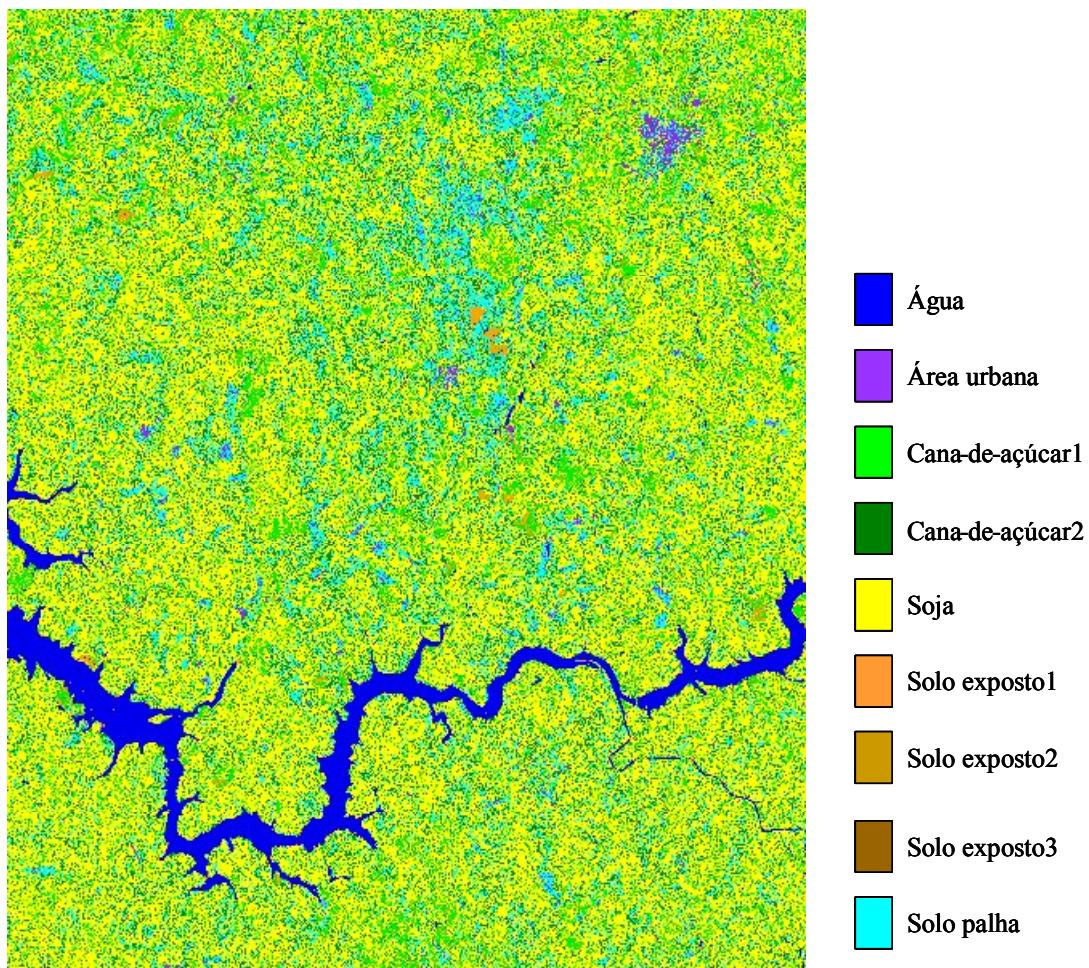


FIGURA 5.8 - Classificação da imagem F5D com filtro de Frost5x5.

A Tabela 5.9 mostra a matriz de confusão e valor de *kappa* para a imagem F5D com filtro de Frost5x5.

TABELA 5.9 - Matriz de confusão da imagem F5D filtrada (Frost5x5).

	classes	Referência (%)									Total
		Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Solo exposto1	Solo exposto2	Solo exposto3	Solo palha	
Classificadas	Água	<b>99,95</b>	0	0	0	0	1,28	0,01	0	0	3,92
	Área urbana	0	<b>53,82</b>	0,04	1,67	0,16	0,01	11,82	0,18	23,33	3,57
	Cana-de-açúcar1	0	1,62	<b>64</b>	1,8	1,8	25,40	2,06	43,85	0,47	15,93
	Cana-de-açúcar2	0	6,11	1,39	<b>25,7</b>	9,30	0,09	17,14	5,92	11,37	12,54
	Soja	0	8,71	21,57	41,69	<b>71,69</b>	1,14	21,23	39,73	12,55	43,87
	Solo exposto1	0	0,27	12,21	0,04	0,13	<b>71,99</b>	0,01	6,53	0,01	6,67
	Solo exposto2	0	0	0	0	0	0	0	0	0	0
	Solo exposto3	0	0,21	0,33	0,13	0,34	0,06	0,06	<b>0,51</b>	0	0,25
	Solo Palha	0	29,26	0,46	28,96	5,04	0,04	47,68	3,27	<b>52,48</b>	13,26
	Total	100	100	100	100	100	100	100	100	100	100
Exatidão total		52,6%		<i>kappa</i> 0,3868							

Esta classificação mostra uma performance razoável com exatidão total de 52,6% e valor *kappa* de 0,3868. As classes água, soja e solo exposto1 apresentaram boa discriminação com porcentagem de acerto de 99,95%, 71,69% e 71,99%, respectivamente. As classes área urbana, cana-de-açúcar1 e solo palha apresentaram discriminação razoável com porcentagem de acerto de 53,82%, 64% e 52,48%, respectivamente. As demais classes apresentaram baixa discriminação, e a classe solo exposto2 apresentou 100% de confusão, ou seja, todos os *pixels* dessa classe foram classificados como pertencendo a outras classes, principalmente a classe solo palha.

A seguir, é apresentado o resultado das classificações sobre as imagens de textura. A Tabela 5.10 mostra o resultado da classificação das classes por imagem de textura, os valores *kappa* e a exatidão total extraídos da matriz de confusão de cada classificação.

TABELA 5.10 - Resultado das classificações de imagens de textura F5D em %.

Classes	Imagens de textura							
	Energia do vetor diferença	Média do vetor soma (Frost 5x5)	Cluster prominence	Variância do vetor soma	Variância do vetor diferença	Média (Frost 5x5)	Contraste do vetor diferença	Contraste dp vetor diferença (frost 5x5)
Água	97,26	99,94	-	99,82	99,54	99,86	99,61	96,75
Área urbana	0,6	80,21	93,71	78,53	87,52	71,59	87,23	88,92
Cana-de-açúcar1	60,1	63,93	28,5	61,98	58,45	57,76	57,80	40,87
Cana-de-açúcar2	27,96	50,05	18,59	39,86	39,4	47,58	38,19	16,53
Soja	50,54	67,62	66,04	65,44	60,02	64,19	60,11	48,47
Solo exposto1	71,66	74,17	71,35	73,32	73,33	74,47	72,24	70,54
Solo exposto2	0	1,2	0,62	0,14	0,08	1,95	0	0
Solo exposto3	0,15	8,04	0,05	4,75	0,13	18,41	0,37	0
Solo palha	<b>75,89</b>	9,66	14,86	0,18	7,4	16,54	15,66	46,22
<b>Exatidão total (%)</b>	<b>43,55</b>	<b>56,06</b>	<b>42,61</b>	<b>51,79</b>	<b>49,44</b>	<b>54,31</b>	<b>49,46</b>	<b>39,84</b>
<b>kappa</b>	0,2981	0,4344	0,2490	0,3822	0,3553	0,4171	0,3566	0,2619

As células em negrito indicam as classes mais bem classificadas por imagem de textura. A classe água, como era de se esperar, apresentou alta discriminação para todas as imagens de textura, com exceção da imagem *cluster prominence*.

A classe área urbana apresentou boa discriminação para todas as imagens, com exceção da imagem de textura entropia do vetor diferença. A imagem de textura que melhor classificou a classe área urbana foi *cluster prominence*, o que correspondeu à análise feita anteriormente.

A classificação sobre a imagem de textura média do vetor soma (Frost5x5) foi a que melhor discriminou as classes cana-de-açúcar1, cana-de-açúcar2 e soja. A classe soja manteve resultados similares para todas as outras classificações. A classe solo exposto 1 apresentou valores similares para todas as imagens de textura classificadas, sendo a média (Frost5x5) a que melhor classificou essa classe.

As classes solo exposto2 e solo exposto3 apresentaram valores baixos de discriminação para todas as classificações. A classe solo palha apresentou valores baixos de discriminação para todas as classificações com exceção da energia do vetor diferença que apresentou uma boa discriminação.

A classificação que apresentou a melhor exatidão e valor de *kappa* foi a média do vetor soma (Frost5x5), 56,06% e 0,4344, respectivamente, considerada boa no conceito de eficiência *kappa* proposto por Landis e Koch (1977) (seção 4.2.3.4).

A Figura 5.9 ilustra a classificação da imagem média do vetor diferença

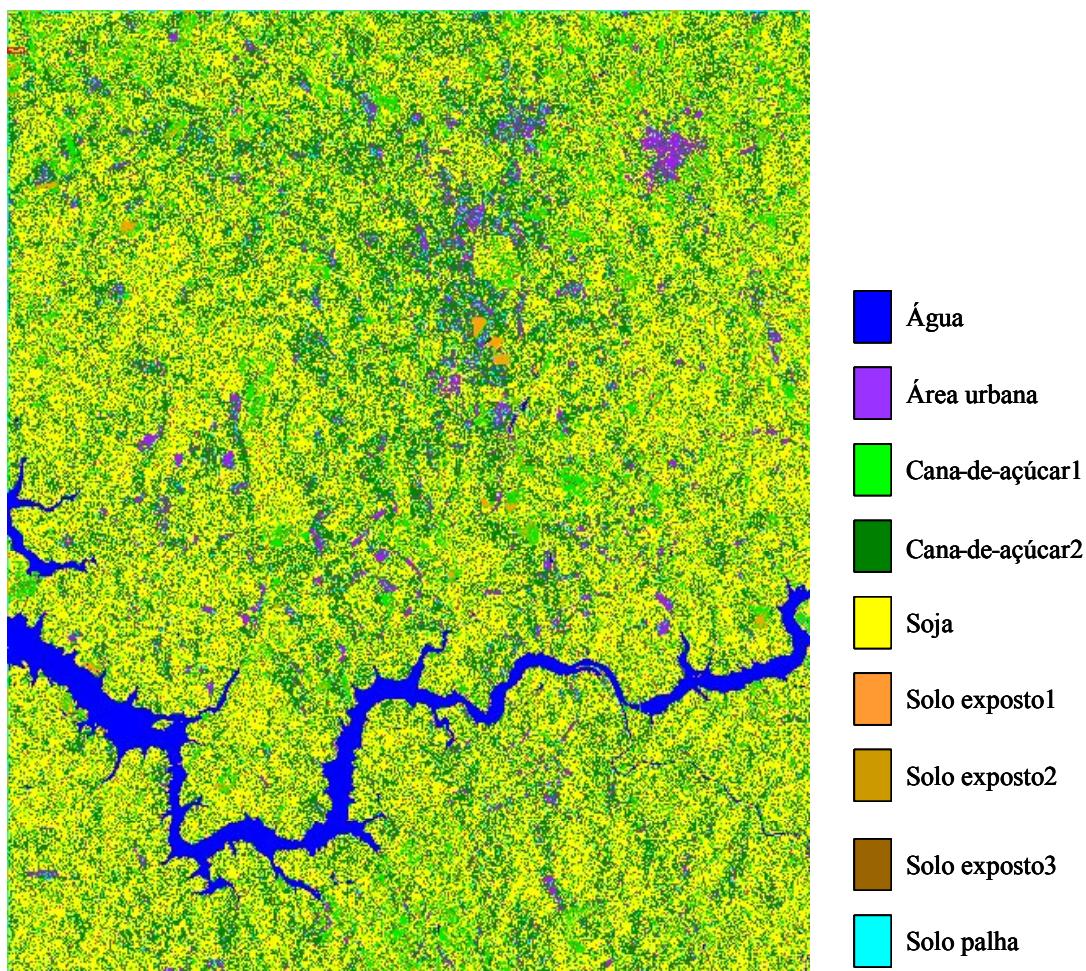


FIGURA 5.9 - Classificação da imagem de textura média do vetor diferença.

A Tabela 5.11 apresenta a matriz de confusão para a classificação da imagem média do vetor diferença.

TABELA 5.11 - Matriz de confusão da imagem de textura média do vetor diferença.

		Referência (%)									
		Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Solo exposto1	Solo exposto2	Solo exposto3	Solo palha	Total
Classificadas	Água	<b>99,94</b>	0	0	0	0	0,08	0	0	0	3,84
	Área urbana	0	<b>80,21</b>	0	9,58	0,45	0	34,56	0,58	58,66	8,56
	Cana-de-açúcar1	0	0,03	<b>63,96</b>	0,35	5,41	24,99	0,71	44,09	0,01	13,98
	Cana-de-açúcar2	0	12,47	0,97	<b>51,05</b>	20,6	0	38,12	9,6	23,71	22,43
	Soja	0	3,63	17,49	30,31	<b>67,62</b>	0,57	15,42	32,17	6,79	38,18
	Solo exposto1	0	0	10,79	0	0	<b>74,17</b>	0	5,1	0	6,48
	Solo exposto2	0	0,37	0	0,9	0,05	0	<b>1,2</b>	0,02	1,05	0,31
	Solo exposto3	0	0,01	6,76	0,43	5,33	0,2	0,36	<b>8,84</b>	0,12	3,55
	Solo Palha	0	3,28	0,03	7,38	0,54	0	9,94	0,41	<b>9,66</b>	2,66
	Total	100	100	100	100	100	100	100	100	100	100
Exatidão total		56,06%		<i>kappa</i> 0,4344							

Apesar de as classificações das imagens de textura não terem melhorado a discriminação da classe soja em relação à imagem original filtrada de Frost5x5, em geral, as classificações das imagens de textura indicam que os atributos texturais foram eficientes na discriminação das classes e apresentaram melhores resultados do que as classificações da imagem isolada. As classes solo exposto2 e solo exposto3 apresentaram valores baixos para todas as classificações.

#### 5.4.2 Classificação da Imagem F5A

A imagem F5A original foi classificada utilizando o algoritmo ICM, onde cada classe foi ajustada às distribuições estatísticas: Raiz Quadrada da Gama, Normal, Log normal ou Weibull.

A Figura 5.10 ilustra a classificação sobre a imagem F5A original.

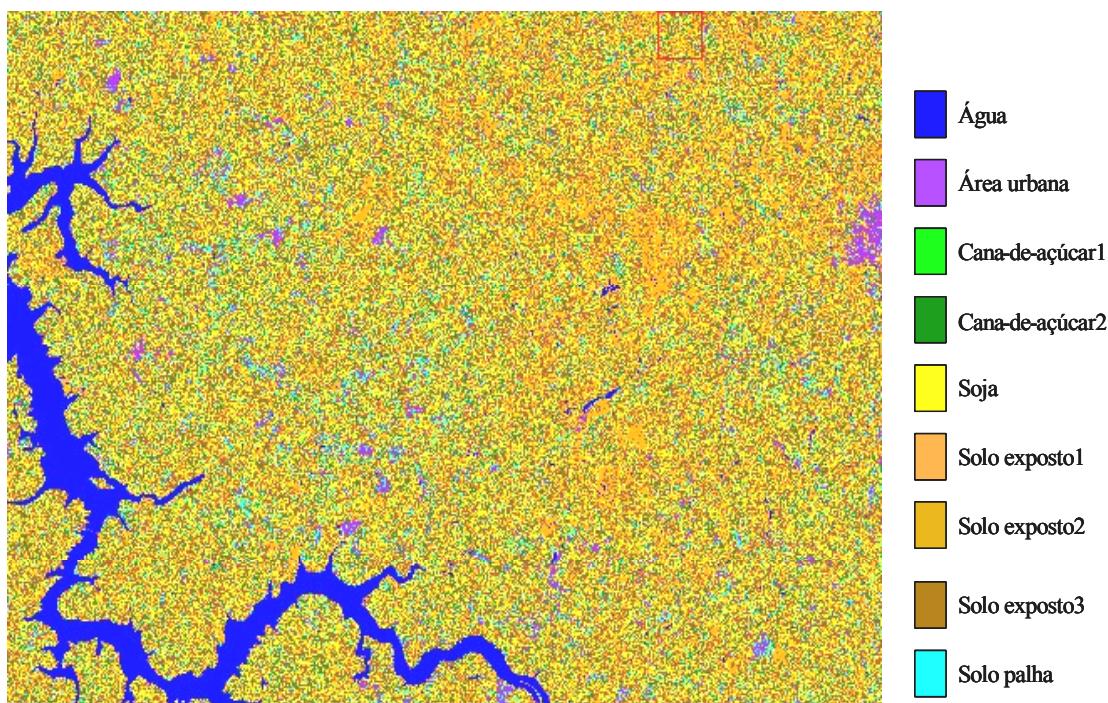


FIGURA 5.10 - Classificação da imagem F5A original.

A Tabela 5.12 apresenta a matriz de confusão e o valor de *kappa* para a classificação da imagem F5A original.

TABELA 5.12 - Matriz de confusão da classificação da imagem F5A original.

classes	Referência (%)									
	Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Solo exposto1	Solo exposto2	Solo exposto3	Solo palha	Total
Água	<b>100</b>	0,02	0,09	0,02	0,05	10,98	0,08	0,11	0,03	2,24
Área urbana	0	<b>67,34</b>	0,42	8,25	0,60	0,02	21,41	0,15	34,11	5,61
Cana-de-açúcar1	0	0	<b>0,22</b>	0,19	0,25	0	0,05	0,17	0,09	0,19
Cana-de-açúcar2	0	2,91	4,72	<b>13,15</b>	7,92	0,02	9,21	3,14	8,57	6,52
Soja	0	7,53	24,13	26,51	<b>32,54</b>	0,42	21,95	15,88	13,44	24,25
Solo exposto1	0	3,83	31,48	5,92	18,33	<b>83,43</b>	4,49	48,52	1,71	25,05
Solo exposto2	0	4	3,18	13,83	5,6	0,03	<b>13,1</b>	1,48	14,72	5,49
Solo exposto3	0	5,95	33,44	15,22	30,3	5,1	10,32	<b>29,69</b>	6,45	25,07
Solo Palha	0	8,43	2,32	16,22	4,42	0	19,38	0,87	<b>20,87</b>	5,57
Total	100	100	100	100	100	100	100	100	100	100
Exatidão total	28,15%		<i>kappa</i> 0,1555							

Observa-se que em termos de exatidão total e valor *kappa* (28,15% e 0,1555), a classificação geral foi ruim e inferior a imagem F5D original. Com exceção das classes água, área urbana e solo exposto1, que foram bem discriminadas, as demais classes apresentaram discriminação ruim, abaixo de 50%.

Os filtros Frost5x5, Gamma5x5 e Lee5x5 de redução do ruído *speckle* foram aplicados na imagem original F5A e geradas as classificações para cada imagem filtrada. Observou-se que a classificação sobre a imagem filtrada de Gamma5x5 apresentou um melhor resultado em relação às classificações realizadas com os outros dois filtros. A classificação sobre a imagem filtrada, assim como na imagem F5D, apresentou resultado consideravelmente melhor que a imagem original.

A Figura 5.11 ilustra a classificação da imagem F5A filtrada de Gamma5x5.

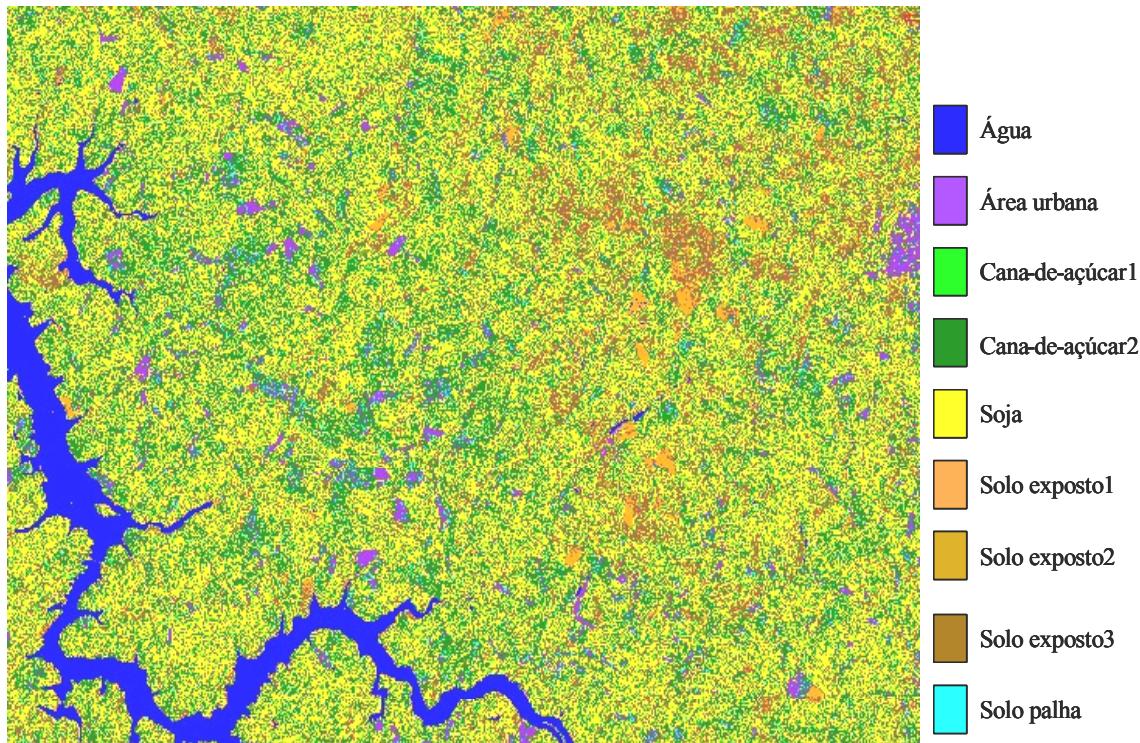


FIGURA 5.11 - Classificação da imagem F5A filtrada de Gamma5x5.

A Tabela 5.13 ilustra a matriz de confusão e o coeficiente *kappa* para a imagem classificada de Gamma5x5.

TABELA 5.13 - Matriz de confusão da imagem F5A filtrada de Gamma5x5.

	classes	Referência (%)									Total
		Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Solo exposto1	Solo exposto2	Solo exposto3	Solo palha	
Classificadas	Água	<b>99,75</b>	0	0	0	0	1,95	0	0	0	1,54
	Área urbana	0	<b>80,02</b>	0,12	10,38	0,23	0	29,21	0,07	52,13	6,93
	Cana-de-açúcar1	0	0,46	<b>9,27</b>	0,58	6,94	0,07	0,38	8,63	0,13	5,76
	Cana-de-açúcar2	0	12,18	9,95	<b>61,32</b>	23,12	0,01	43,11	2,56	32,78	20,61
	Soja	0	3,71	44,07	18,22	<b>56,66</b>	0,23	12,66	28,61	2,86	38,47
	Solo exposto1	0,25	0,05	2,91	0	0,1	<b>85,69</b>	0	13,28	0	7,68
	Solo exposto2	0	0,01	0	0,17	0,02	0	<b>0,16</b>	0	0,19	0,04
	Solo exposto3	0	0,59	33,43	0,21	12,55	12,05	0,18	<b>46,85</b>	0	17,04
	Solo Palha	0	2,96	0,25	9,12	0,38	0	14,30	0	<b>11,91</b>	1,93
	Total	100	100	100	100	100	100	100	100	100	100
Exatidão total		46,14%		<i>kappa</i> 0,3128							

Esta classificação mostra uma performance razoável com exatidão total de 46,14% e valor *kappa* de 0,3128. As classes água, área urbana, cana-de-açúcar2, soja e solo exposto1 apresentaram boa discriminação com porcentagem de acerto de 99,75%, 80,02%, 61,32, 56,66 e 85,69%, respectivamente. As demais classes apresentaram baixa discriminação com porcentagem de acerto abaixo de 50%.

A seguir é apresentado o resultado das classificações sobre as imagens de textura. A Tabela 5.14 mostra o resultado da classificação das classes por imagem de textura, os valores *kappa* e a exatidão total extraídos da matriz de confusão de cada classificação.

TABELA 5.14 - Resultado das classificações de imagens de textura F5A em %.

Classes	Imagens de textura									
	Qui-quadrado	Energia do vetor diferença	Cluster prominence	Contraste do vetor diferença	Entropia do vetor diferença	Variância do vetor diferença	Entropia (Frost5x5)	Média (Lee5x5)	Entropia	Média (Frost5x5)
Água	99,85	99,80	-	99,73	61,58	99,88	95	99,67	95	99,87
Área urbana	0,65	0,68	91,9	89,32	2,27	92,42	9,27	61,13	1,82	67,09
Cana-de-açúcar1	0,35	5,57	0	5,01	3,61	5,86	0,96	7,17	0	9,92
Cana-de-açúcar2	0,07	12,08	18,6	36,86	21,01	28,73	92,64	43,42	86,67	57,38
Soja	3,96	37,1	64,5	48,39	44,1	47,72	3,81	45,35	2,11	49,76
Solo exposto1	79,56	75,3	77,5	78,38	27,35	79,76	57,78	78,90	5,53	81,09
Solo exposto2	0	0	0	0	0	0	0	0,6	0	0,61
Solo exposto3	19,72	45,59	20	49,90	0	48,35	19,46	49,45	16,71	51,63
Solo palha	97,14	89,15	22,9	16,35	80,98	7,54	2,74	25,38	5,42	28,15
<b>Exatidão total (%)</b>	<b>13,87</b>	<b>31,33</b>	<b>41,16</b>	<b>39,58</b>	<b>27,6</b>	<b>38,53</b>	<b>14,60</b>	<b>38,61</b>	<b>15,39</b>	<b>43,07</b>
<b>kappa</b>	0,0838	0,1784	0,2225	0,2495	0,1270	0,2377	0,0587	0,2393	0,0700	0,2874

As células em negrito indicam as classes mais bem classificadas por imagem de textura. Com exceção da classe solo exposto1, as demais classes apresentaram maior discriminação quando comparados à imagem original filtrada de Gamma5x5. Entretanto, a exatidão total e o valor *kappa* das classificações apresentaram valores inferiores à mesma.

As classes solo palha, área urbana, cana-de-açúcar2 apresentaram alta discriminação com valores maximizados para as classificações das imagens de textura qui-quadrado, variância do vetor diferença e entropia (Frost5x5) respectivamente. Para as classes soja, cana-de-açúcar1, solo exposto2 e solo exposto3, os valores indicam ligeira melhora quando comparados à classificação da imagem original filtrada de Gamma5x5. As classes cana-de-açúcar1 e solo exposto2 apresentaram valores de discriminação muito baixo para todas as classificações.

A classificação que apresentou a melhor exatidão total (43,07%) e valor *kappa* (0,2874) foi a média (Frost 5x5), considerada razoável no conceito de eficiência *kappa* proposto por Landis e Koch (1977) (seção 4.2.3.4).

Todas as classificações realizadas para a imagem F5A apresentaram valores de discriminação inferiores às realizadas para a imagem F5D. Isso pode ter ocorrido devido ao menor número de amostras, compostas de polígonos maiores, extraídas sobre a imagem F5A em relação às amostras da imagem F5D (Tabelas 5.1 e 5.2). Polígonos maiores resultaram num aumento do desvio padrão (Tabela 5.4) e, consequentemente, numa maior confusão na classificação digital.

#### 5.4.3 Classificação da Imagem S7D

A imagem S7D original foi classificada utilizando o algoritmo ICM, onde cada classe foi ajustada às distribuições estatísticas Raiz Quadrada da Gama, Normal, Log normal ou Weibull.

A Figura 5.12 ilustra a classificação da imagem S7D original.

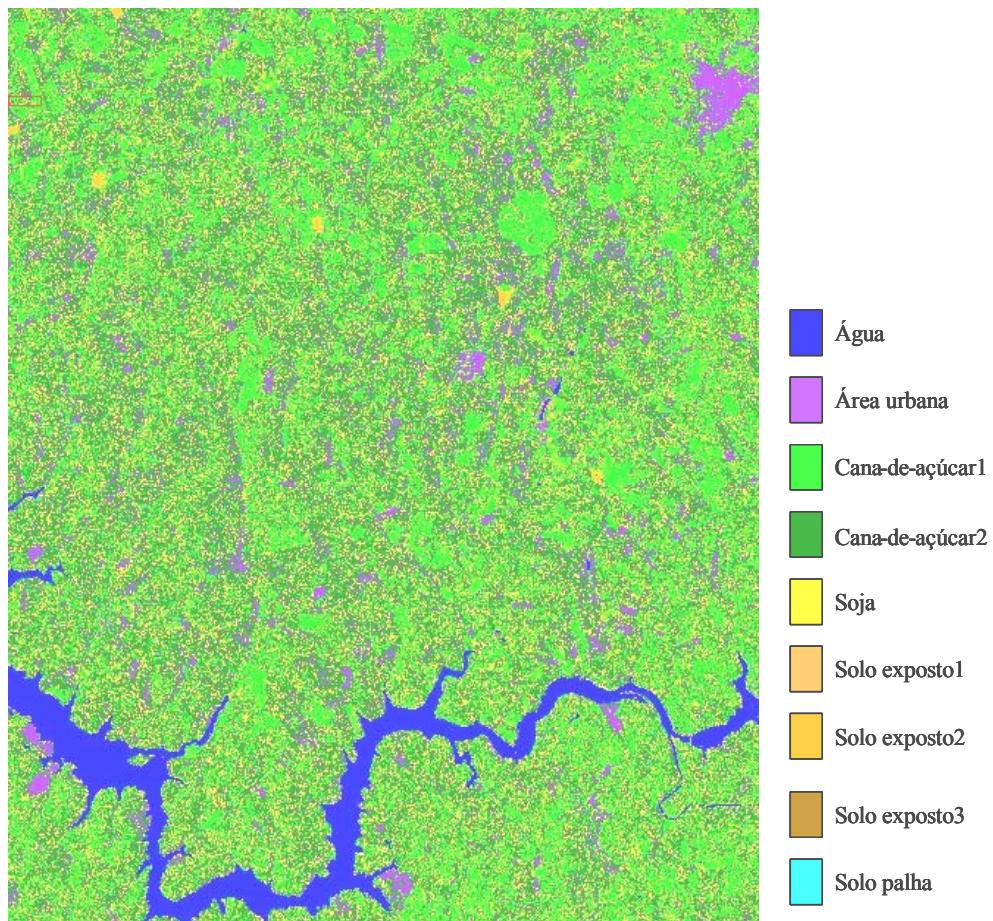


FIGURA 5.12 - Classificação da imagem S7D original.

A Tabela 5.15 apresenta a matriz de confusão e o valor de *kappa* para a classificação da imagem S7D original.

TABELA 5.15 - Matriz de confusão da imagem S7D original.

classes	Referência (%)									Total
	Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Solo exposto1	Solo exposto2	Solo exposto3	Solo palha	
Classificadas	Água	<b>100</b>	0	0	0	0,1	0	0	0	3,76
	Área urbana	0	<b>89,45</b>	0,04	9,83	3,14	0,2	32,39	1,1	9,12
	Cana-de-açúcar1	0	1,38	<b>83,62</b>	13,09	31,69	18,69	9,23	64,45	19,39
	Cana-de-açúcar2	0	7,4	2,9	<b>53,66</b>	33,26	0,9	38,91	13,01	41,51
	Soja	0	1,35	3,32	17,49	<b>22,57</b>	0	14,76	13,09	22,13
	Solo exposto1	0	0,06	8,17	0,12	0,23	<b>80,11</b>	0,37	2,47	0,25
	Solo exposto2	0	0	0	0	0	<b>0</b>	0	0	0
	Solo exposto3	0	0,36	1,95	5,81	9,11	0	4,35	<b>5,89</b>	7,36
	Solo Palha	0	0	0	0	0	0	0	<b>0</b>	0
	Total	100	100	100	100	100	100	100	100	100
Exatidão total		40,76%		<i>kappa</i> 0,2565						

Observa-se que em termos de exatidão total (40,76%) e valor *kappa* (0,2565), a classificação geral foi razoável. As classes soja e solo exposto3 apresentaram discriminação ruim com valores abaixo de 50%. As classes solo exposto2 e solo palha apresentaram 100% de confusão. As demais classes, isto é, água, área urbana, cana-de-açúcar1, cana-de-açúcar2 e solo exposto1, apresentaram boa discriminação.

Os filtros Frost 5x5, Gama 5x5 e Lee 5x5 de redução do ruído *speckle* foram aplicados na imagem S7D original e geradas as classificações para cada imagem filtrada. Observou-se que a classificação sobre a imagem filtrada de Gamma5x5 apresentou o melhor resultado em relação às classificações realizadas com os outros dois filtros. A classificação sobre a imagem filtrada, assim como nas imagens F5D e F5A, apresentaram resultado consideravelmente melhor que a imagem original.

A Figura 5.13 ilustra a classificação da imagem S7D filtrada de Gamma5x5.

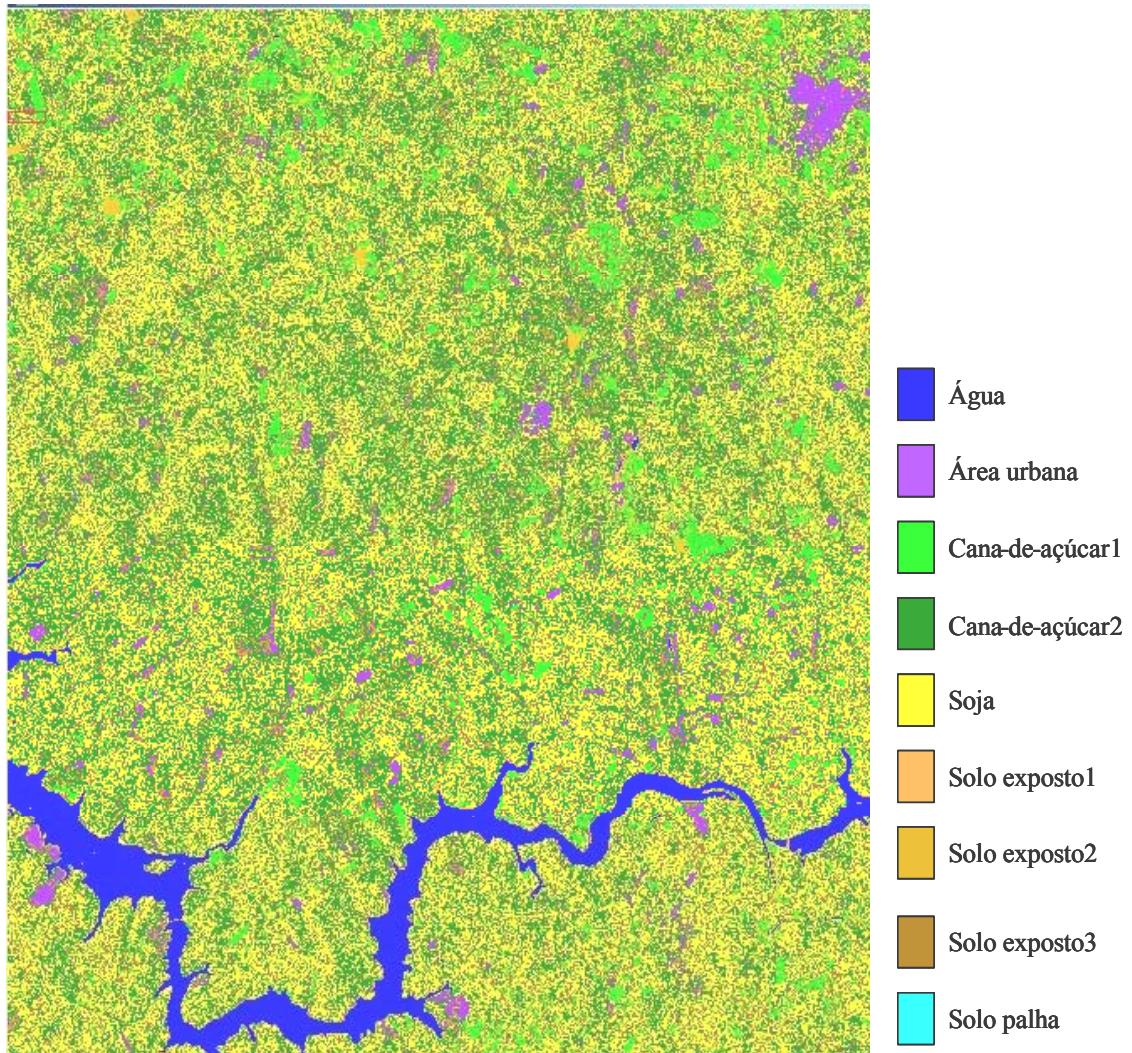


FIGURA 5.13 - Classificação da imagem S7D filtrada de Gamma5x5.

A Tabela 5.16 apresenta a matriz de confusão e o valor de *kappa* para a classificação da imagem S7D original.

TABELA 5.16 - Matriz de confusão da imagem S7D filtrada de Gamma5x5.

	classes	Referência (%)									Total
		Água	Área urbana	Cana-de-açúcar1	Cana-de-açúcar2	Soja	Solo exposto1	Solo exposto2	Solo exposto3	Solo palha	
Classificadas	Água	<b>99,97</b>	0	0	0	0	0	0	0	0	3,75
	Área urbana	0	<b>89,36</b>	0	1,74	0,11	0	23,58	0	0,45	5,11
	Cana-de-açúcar1	0	0	<b>65,86</b>	0,67	3,38	23,03	0,37	31,98	1,8	7,9
	Cana-de-açúcar2	0	6,24	0,14	<b>53,75</b>	27,81	0	41,33	7,68	45,07	30,23
	Soja	0	0,43	9,77	28,14	<b>55,11</b>	0,15	18,16	36,55	42,13	37,89
	Solo exposto1	0,03	0	6,64	0	0	<b>75,77</b>	0	1,36	0	1,51
	Solo exposto2	0	3,96	0,03	12,44	1,22	0	<b>16,07</b>	0,16	5,89	4,49
	Solo exposto3	0	0	17,56	3,24	12,36	1,05	0,49	<b>22,27</b>	4,66	9,09
	Solo Palha	0	0	0	0,02	0,01	0	0	0	<b>0</b>	0,01
	Total	100	100	100	100	100	100	100	100	100	100
Exatidão total		56,48%		<i>kappa</i> 0,3928							

Esta classificação mostra uma performance razoável com exatidão total de 56,48% e valor *kappa* de 0,3928. As classes água, área urbana, cana-de-açúcar1, cana-de-açúcar2, soja e solo exposto1 apresentaram boa discriminação com porcentagem de acerto de 99,97%, 89,36%, 65,86, 53,75 e 55,11%, respectivamente. As classes solo exposto2 e solo exposto3 apresentaram baixa discriminação com porcentagem de acerto bem abaixo de 50%. A classe solo palha apresentou porcentagem de 100% de confusão.

Esta classificação indica valores de exatidão total e *kappa* ligeiramente melhores do que as imagens F5D e F5A. Este resultado pode ser devido ao fato de que a imagem S7D apresenta menos efeito do ruído *speckle*, por conter um maior número de *looks*, o que resulta num melhor desempenho em relação às imagens de apenas 1 *look*.

A seguir é apresentado o resultado das classificações sobre as imagens de textura. A Tabela 5.17 mostra o resultado da classificação das classes por imagem de textura, os valores *kappa* e a exatidão total extraídos da matriz de confusão de cada classificação.

TABELA 5.17 - Resultado das classificações de imagens de textura S7D em %.

Classes	Imagens de textura								
	Qui-quadrado	Média do vetor diferença	Variância do vetor diferença	Energia	Média (Frost5x5)	Média	Desvio médio absoluto	Média (Gamma5x5)	Média do vetor soma
Água	99,74	99,9	99,67		100	99,98	100	99,97	100
Área urbana	0	90,12	91,12	0	91,15	86,51	88,99		77,39
Cana-de-açúcar1	21,22	57,56	57,71	0,18	67,66	72,23	74,04	64,75	60,8
Cana-de-açúcar2	4,1	18,7	14,87	65,08	50,83	43,71	59,18	50,5	54,44
Soja	0	33,95	36,13	0	52,26	35,3	42,15	57,38	52,91
Solo exposto1	75,52	60,27	60,02	90,18	74,38	78,12	77,37	75,82	74,83
Solo exposto2	65,81	23,17	24,97	0	6,6	9,8	0	41,04	0
Solo exposto3	10,08	10,61	9,08	0	16,48	14,92	12,77	23,08	24,88
Solo palha	25,19	0	0	1,6	0,16	8,59	1,64	0,57	0,12
<b>Exatidão total</b>	<b>9,12</b>	<b>35,50</b>	<b>35,58</b>	<b>19,43</b>	<b>54,13</b>	<b>44,06</b>	<b>51,52</b>	<b>55,50</b>	<b>54,47</b>
<i>kappa</i>	0,0595	0,1931	0,1933	0,0421	0,3629	0,2776	0,3438	0,3554	0,3666

No total foram geradas 12 imagens de textura selecionadas a partir das imagens filtradas e da imagem original como vistos da seção 5.3.3. Entretanto, apenas 9 dessas imagens estão representadas na Tabela 5.17, pois estas apresentaram os melhores resultados de classificação. As imagens de textura contraste, energia do vetor diferença e homogeneidade apresentaram desempenho muito baixo com valores de exatidão total abaixo de 10% e valores *kappa* negativos.

As células em negrito na Tabela 5.17 indicam as classes mais bem classificadas por imagem de textura. As classificações sobre as imagens de textura indicaram uma melhora na discriminação de todas as classes em relação à classificação da imagem original filtrada de Gamma5x5. Entretanto, a exatidão total e o valor de *kappa* foram inferiores à imagem original filtrada de Gamma5x5. A classificação que apresentou a melhor exatidão total e valor *kappa* foi a média (Gamma5x5), com valores de 55,5% e 0,3554, respectivamente, considerada boa no conceito de eficiência *kappa* proposto por Landis e Koch (1977) (seção 4.2.3.4).

Em geral, as classificações realizadas sobre as imagens de textura S7D selecionadas a partir da imagem original apresentaram valores de discriminação ligeiramente inferiores em relação às classificações realizadas sobre as imagens de textura F5D. Isso pode ter ocorrido devido à resolução espacial inferior da imagem S7D em relação à imagem F5A, o que acarreta numa perda de informação textural.



## CAPÍTULO 6

### Conclusões e Recomendações

Os resultados obtidos através das análises visuais e das classificações supervisionadas MAXVER/ICM sobre as imagens RADARSAT-1/SAR C-HH *Fine-5*/descendente (F5D), *Fine-5*/ascendente (F5A) e *Standard-7*/descendente (S7D) utilizadas neste trabalho foram, de modo geral, satisfatórios pelo método de eficiência *kappa* propostos por Landis e Koch (1977).

A análise visual das imagens RADARSAT-1 dos principais alvos agrícolas presentes na área de estudo, isto é, soja, cana-de-açúcar e solo exposto mostrou que essas imagens podem ser uma ferramenta útil para a identificação e discriminação das culturas estudadas. As principais conclusões foram:

- A cultura da soja, na fase de máximo desenvolvimento, apresentou padrão de tom de cinza médio nas três imagens RADARSAT-1 analisadas com poucas variações em função da direção de imageamento. Isto pode ser atribuído à estrutura do dossel fechado cobrindo praticamente todo o solo, o que ocasionou atenuação do retroespalhamento pelo dossel, com pouca penetração e, consequentemente, pouca influência do solo. Variações de tons de cinza ocorreram em alguns talhões localizados próximos a área de encosta devido aos efeitos causados pelo relevo e pela declividade.
- Para a cultura da cana-de-açúcar, as imagens RADARSAT-1 foram eficientes em discriminar classes de cana-de-açúcar adulta erectófila (tons de cinza escuros) e erectófila com dobra nas extremidades das folhas (tons de cinza médios) nas três imagens RADARSAT-1 utilizadas, mostrando serem sensíveis às mudanças na estrutura das plantas na fase de máximo desenvolvimento.
- Para áreas de solo exposto, as imagens RADARSAT-1 apresentaram variações de tons de cinza (tons claros, médios e escuros) mostrando serem pouco eficientes para fins de discriminação e classificação digital. Estas variações podem ser devido aos sulcos de

preparo do solo em relação ao sentido de imageamento. O retroespalhamento é menor (tons de cinza escuros) quando a direção de preparo é paralela ao sentido do imageamento e maior (tons de cinza claros) quando está na direção perpendicular ao sentido do imageamento.

A análise dos valores da média e desvio padrão dos níveis de cinza das amostras de treinamento e teste coletadas sobre as imagens F5D e F5A mostram que o efeito da direção de imageamento (imagem ascendente-F5A e descendente-F5D) no retroespalhamento e, consequentemente, nos tons de cinza para fins de classificação digital são mínimos para praticamente todas as classes de estudo. Desse modo, um dado adquirido na órbita descendente pode substituir o dado adquirido na órbita ascendente e vice-versa. Esta flexibilidade aumenta a resolução temporal, o que é uma vantagem para fins de monitoramento de áreas agrícolas.

O método de seleção das medidas e bandas de textura indicou ser adequado, pois permitiu identificar o potencial de discriminação entre classes duas a duas e a geração das bandas de textura correspondentes às medidas de textura que melhor discriminam os alvos de interesse para as três imagens utilizadas. Isto evitou a utilização de todas as medidas de textura e, consequentemente, redundância de informação e demanda computacional elevada.

A utilização de filtros adaptativos de redução do ruído *speckle* mostrou-se eficiente e fundamental para as classes analisadas, pois as classificações das imagens filtradas com o classificador pontual/contextual (MAXVER/ICM) apresentaram resultados bem melhores em relação às imagens originais.

As classificações realizadas sobre as imagens de textura apresentaram, em geral, bom desempenho para as três imagens RADARSAT-1 utilizadas, mostrando que as medidas texturais podem ser ferramentas úteis para maximizar a discriminação de alvos agrícolas.

Como recomendação final, sugere-se a realização de trabalhos contínuos que utilizem outras abordagens de análise como a obtenção de valores do coeficiente de

retroespalhamento, com o intuito de aprimorar a extração de informação de áreas agrícolas e, com isso, implementar um sistema operacional de detecção e monitoramento de culturas agrícolas de interesse.



## REFERÊNCIAS BIBLIOGRÁFICAS

- Ahern, F. **Conceitos fundamentais de radar imageador, nível básico.** Curso ProRADAR. São José dos Campos, 1995. 91p.
- Alvares Filho, A. Botânica e desenvolvimento. In: Santos, O.S. (ed). **A Cultura de soja –1.** Rio de Janeiro: Editora Globo, 1988. p. 25-35.
- Baghdadi, N.; King, C.; Bourguignon, A.; Remond, A. Potential of ERS and RADARSAT data for surface roughness monitoring over bare agricultural fields: application to catchments in Northern France. **International Journal of Remote Sensing**, v. 23, n. 17, p. 3427-3442, 2002.
- Baraldi, A.; Parmiggiani, F. An investigation of textural characteristics associated with gray level cooccurrence matrix statistical parameters. **IEEE Transactions on Geoscience and Remote Sensing**, v. 33, n. 2, p. 293-304, 1995.
- Boin, M. N.; Zavatini, J. A.; Mendes, I. A. Chuvas e erosões no oeste paulista: Uma análise aplicada. **Geografia**, v. 27, n. 1, p.95-118, 2002.
- Brisco, B.; Brown, R. J. Multidate SAR/TM synergism for crop classification in western Canada. **Photogrammetric Engineering and Remote Sensing**. v. 61, n. 8, p. 1009-1014, 1995.
- Brisco, B.; Brown, R. J. Agricultural applications with Radar. In: Henderson, F. M.; Lewis, A. J. **Principles and applications of imaging radar - manual of remote sensing.** (3ed). New York: John Wiley & Sons, 1997. p 381-406.
- Câmara, G. M. S. Ecofisiologia da cultura de cana-de-açúcar. In: Câmara, G. M. S; Oliveira, E. A. M. (ed). **Produção de cana-de-açúcar.** Piracicaba: FEALQ, 1993. p. 31-64.
- Canada Centre for Remote Sensing (CCRS). **GlobeSAR-2 educational/ download and instructions/ English/ data products.** Disponível em: <[http://www.ccrs.nrcan.gc.ca/ccrs/learn/tutorials/gsarcld/intro\\_e.html](http://www.ccrs.nrcan.gc.ca/ccrs/learn/tutorials/gsarcld/intro_e.html)>. Acesso em 10 de Mar, 2003.
- Chen, C. H. Texture unit, texture spectrum, and texture analysis. **IEEE Transactions on Geoscience and Remote Sensing**, v. 28, n. 4, p.509-512, 1990.
- Curlander, J. C.; McDonough, R. N. **Synthetic aperture radar:** systems and signal processing. New York: John Wiley & Sons, 1991.
- Dallemand, J. F.; Lichtenegger, J.; Raney, R. K.; Schumann, R. **Radar imagery:** theory and interpretation: lecture notes. Rome: FAO/ESA, 1993. (RSC Series 67).
- Dobson, M. C.; Ulaby, F. T. Microwave backscatter dependence on surface roughness, soil moisture and soil texture: Part III – Soil Tension. **IEEE Transactions on Geoscience and Remote Sensing**, v. GE-19, p. 51-61, 1981.

- Dobson, M. C.; Ulaby, F. T.; Pierce, L. E. Land cover classification and estimation of terrain using Synthetic Aperture Radar. **Remote Sensing of Environment**, v. 51, n. 1, p. 199-214, 1995.
- Dutra, L. V.; Souza, R. C. M.; Mitsuo, F. A.; Moreira, J. C. **Análise automática de imagens multiespectrais**. São José dos Campos: INPE, 1981. (INPE-2212-MD/009)
- Empresa Brasileira de Pesquisa Agropecuária (EMBRAPA). **Tecnologias de produção de soja - região central do Brasil - 2003**. Londrina: Embrapa, 2002. 199 p.
- Foody, G. M. On the compensation for change agreement in image classification accuracy assessment. **Photogrammetric Engineering and Remote Sensing**, v. 6, n. 10, p. 1459-1460, 1992.
- Formaggio, A. R.; Epiphanio, J. C. N.; Simões, M. S. Radar backscattering from an agricultural scene. **Pesquisa Agropecuária Brasileira**, v. 36, n. 5, p. 823-830, 2001.
- Frery, A. C. **Algumas ferramentas estatísticas na síntese, processamento e análise de imagens de radar de abertura sintética**. São José dos Campos. 228 p. (INPE-5548-TDI/534). Tese (Doutorado em Computação Aplicada) Instituto Nacional de Pesquisas Espaciais, 1993.
- Frost, V. S.; Stiles, J. A.; Shanmugan, K. S.; Holtzman, J. C. A model for radar images and its application to adaptive digital filtering of multiplicative noise. **IEEE Transactions on pattern analysis and machine intelligence**, v. 4, n. 2, p. 157-166, 1982.
- Frost, V. S.; Shanmugam, K. S.; Holtzman, J. C. The influence sensor and flight parameters on texture in radar images. **IEEE Transactions on Geoscience and Remote Sensing**, v. GE-22, n. 5, p. 440-448, 1984.
- Greenspan, H.; Goodman, R.; Chellappa, R.; Anderson, C. H. Learning texture discrimination rules in a multiresolution system. **IEEE Transactions on pattern analysis and machine intelligence**, v. 16, n. 9, p. 894-901, 1994.
- Haralick, R. M.; Shanmugam, K.; Dinstein, I. Textural features for image classification. **IEEE Transactions on Systems, Man and Cybernetics**, v. SMC-3, n. 6, p. 610-621, 1973.
- Haralick, R. M. Statistical and structural approaches to texture. **Proceedings of the IEEE**, v. 67, n. 5, p. 786-804, 1979.
- Hsu, S. Y. Texture-tone analysis for automated land-use mapping. **Photogrammetric Engineering and Remote Sensing**, v. 44, n. 11, p. 1393-1404, 1978.
- Hudson, W. D.; Ramm, C. W. Correct formulation on the Kappa coefficient of agreement. **Photogrammetric Engineering and Remote Sensing**, v. 53, n. 4, p. 421-422, 1987.
- Instituto Agronômico de Campinas. Centro Integrado de Informações Agrometeorológicos (IAC/CIIAGRO). **CIIAGRO ONLINE**: resenha agrometeorológica. Campinas. Disponível em:<[www.iac.sp.gov.br/New/ciiagro/](http://www.iac.sp.gov.br/New/ciiagro/)>. Acesso em: 9 de abr. 2003.

Instituto Brasileiro de Geografia e Estatística (IBGE). **CIDADES**. Disponível em:<<http://www.ibge.gov.br>>. Acesso em: 05 de jan. 2003a.

\_\_\_\_\_. **SIDRA**. Disponível em:  
<[www.sidra.ibge.gov.br/bda/tabela/protabl.asp?z=t&o=11](http://www.sidra.ibge.gov.br/bda/tabela/protabl.asp?z=t&o=11)>. Acesso em: 05 jan. 2003b.

Instituto Nacional de Pesquisas Espaciais (INPE) – Divisão de Sensoriamento Remoto (INPE – DSR). **Cartas topográficas \_ ORB 222/76**. São José dos Campos, 2003. 1 CD ROM.

Ippoliti-Ramilo, G. A.; Epiphanio, J. C. N.; Shimabukuro, Y. E.; Formaggio, A. R. Sensoriamento remoto orbital como meio auxiliar na previsão de safras. **Agricultura em São Paulo**, v.46, n.1, p.89-101, 1999.

Irons, J. R.; Petersen, G. W. Texture transforms of remote sensing data. **Remote Sensing of Environment**, v. 11, n. 5, p. 359-370, 1981.

Landis, J. R.; Koch, G. G. The measurements of observer agreement for categorical data. **Biometrics**, v. 33, p. 159-174, 1977.

Lee, J. S. Digital image enhancement and noise filtering by use of local statistics. **IEEE Transactions on Pattern Analysis Machine Intelligence**, v. 2, n. 2, p. 165-171, 1980.

Lewis, A. J.; Henderson, F. M. Radar fundamentals: the geoscience perspective. In: Henderson, F. M.; Lewis, A. J. **Principles and applications of imaging radar - manual of remote sensing**. (3ed). New York: John Wiley & Sons, 1997. p. 131-181.

Lillesand, T. M.; Kiefer, R. W. **Remote sensing and image interpretation**. New York: John Wiley & Sons, 1987. 721p.

Lopes, A.; Touzi, R.; Nezry, E. Adaptative speckle filters and scene heterogeneity. **IEEE Transations on Geoscience and Remote Sensing**, v. 28, n. 6, p. 992-1000, 1990.

Lopes, A.; Nezry, E.; Touzi, R.; Laur, H. Structure detection and statistical adaptive speckle filtering in SAR images. **International Journal of Remote Sensing**, v. 14, n. 9, p. 1735-1758, 1993.

Macedo, M. A. **Tecnologias geoespaciais no seguro agrícola do milho safrinha**. São José dos Campos, 87 p. Dissertação (Mestrado em Sensoriamento Remoto) Instituto Nacional de Pesquisas Espaciais, 2002.

Mather, P. M. **Computer processing of remotely-sensed images**: an introduction, 2 ed. Chichester: John Wiley & Sons, 1999. 292 p.

McNairn, H.; Brown, R. J.; Wood, D. Incident angle considerations for crop mapping using multitemporal RADARSAT data. In: Canadian Symposium on remote Sensing 20., Calgary, 1988. **Proceedings**. Albany: CCRS. Disponível em: <[www.ccrs.nrcan.gc.ca/ccrs/rd/sci\\_pub/bibpdf/3496.pdf](http://www.ccrs.nrcan.gc.ca/ccrs/rd/sci_pub/bibpdf/3496.pdf)>. Acesso em: 09 de maio 2003.

McNairn, H.; Ellis, J.; Van Der Sanden, J. J.; Hirose, T.; Brown, R. J. Providing crop information using RADARSAT-1 and satellite optical imagery. **International Journal of Remote Sensing**, v. 23, n. 5, 2002, p. 851-870.

Morais, M. C.; Paradella, W. R.; Freitas, C. C. An assessment of the discrimination of Iron-mineralized laterites in the amazon region (Carajás province) based on textural attributes from C-band airborne SAR data. **Asian Journal of Geoinformatics**, v. 2, n. 3, p. 11-19, 2002.

Moran, M. S.; Hymer, D. C.; Qi, J.; Kerr, Y. Comparison of ERS-2 and Landsat TM imagery for monitoring agricultural crop and soil condition. **Remote Sensing of Environment**. v. 79. p. 243-252, 2002.

Moreira, M. A. **Fundamentos do sensoriamento remoto e metodologias de aplicação**. São José dos Campos: Câmara Brasileira do Livro, 2001. 250 p.

Oliveira, J. B.; Camargo, M. N.; Rossi, M.; Calderano Filho, B. **Mapa pedológico do Estado de São Paulo**. Rio de Janeiro: Embrapa Solos, 1999. Escala 1:500.000. A legenda expandida encontra-se em separado na publicação de mesmo nome (ISBN 85-85864-05-2).

Panigrahy, S.; Manjunath, K. R.; Chakraborty, M.; Kundu, N.; Parihar, J. S. Evaluation of RADARSAT standard beam data for identification of potato and rice crops in India. **ISPRS Journal of Photogrammetric and Remote Sensing**, v. 54, p. 254-262, 1999.

Presutti, M. E.; Franklin, S. E.; Moskal, L. M.; Dickson, E.E. Supervised classification of multisource satellite image spectral and textural data for agricultural crop mapping in Buenos Aires Province, Argentina. **Canadian Journal of Remote Sensing**, v. 27, n. 6, p. 679-684, 2001.

RADARSAT International. **RADARSAT Illuminated**: your guide to products and services. Richmond, 1995. Preliminary version 07195.

Raney, K. R. Radar fundamentals: technical perspective. In: Henderson, F. M.; Lewis, A. J. **Principles and applications of imaging radar - manual of remote sensing**. (3ed). New York: John Wiley & Sons, 1997. p. 09-130.

Rennó, C. D. **Avaliação das medidas texturais na discriminação de classes de uso utilizando imagens SIR-C/X-SAR do perímetro irrigado de Bebedouro, Petrolina, PE**. São José dos Campos. 73 p. Dissertação (Mestrado em Sensoriamento remoto) – Instituto Nacional de Pesquisas Espaciais, 1995.

Rennó, C. D.; Freitas, C. C.; Sant'Anna, S. J. S. A system for region image classification based on textural measures. [CD-ROM]. In: Simpósio Brasileiro de Sensoriamento Remoto, 9; 1998. Santos. **Anais**. São Paulo: Imagem multimídia, 1998. II Jornada de Radar.

Rennó, C. D. **Texture 1.0**. classificador por região. São José dos Campos: INPE, 2003. Disponível em: <<http://www.dpi.inpe.br/~camilo>>. Acesso em: 9 de jun. de 2003.

Richards, J. A. **Remote sensing digital image analysis**: an introduction. Berlin: Springer-Verlarg, 1986. 221 p.

Rosenfield, G. H.; Fitzpatrick-Lins, K. A coefficient of agreement as a measure of thematic classification accuracy. **Photogrammetric Engineering and Remote Sensing**. v. 52, n. 2, p. 223-227, 1986.

Showengerdt, R. A. **Remote sensing: models and methods for image processing**. (2ed). New York: Academic Press, 1997. 522 p.

Silva Junior, L. W. P. **Classificação da cobertura da terra na floresta nacional do Tapajós através de medidas de textura utilizando dados do radar ERS**. São José dos Campos. 164 p. Dissertação (Mestrado em Sensoriamento Remoto), Instituto Nacional de Pesquisas Espaciais, 2001.

Simões, M. S. **Análise de dados multitemporais Radarsat-1 para o sensoriamento remoto de culturas agrícolas**. 1999, 147 p. (INPE-7299-TDI/711). Dissertação (Mestrado em Sensoriamento Remoto), Instituto Nacional de Pesquisas Espaciais, São José dos Campos, 1999.

Smith, A. M.; Major, D. J.; Mcneil, R. L.; Willms, W. D.; Brisco, B.; Brown, R. J. Complementarity radar and visible-infrared sensors in assessing rangeland condition. **Remote Sensing of Environment**. v. 52. p. 173-180, 1995.

Soares, J. V.; Rennó, C. D.; Formaggio, A. R.; Yanasse, C. C. F.; Frery, A. C. An investigation of the selection of texture features for crop discrimination using SAR imagery. **Remote Sensing of Environment**, v. 59, n.2, p.234-247, 1997.

Soler, L. S. **Detecção de manchas de óleo na superfície do mar por meio de técnicas de classificação textural de imagens de radar de abertura sintética (RADARSAT-1)**. São José dos Campos. 167 p. (INPE-8605-TDI/790). Dissertação (Mestrado em Sensoriamento Remoto) – Instituto Nacional de Pesquisas Espaciais, 2002.

Toutin, T. Map making with remote sensing data. In: NATO Advanced Research Workshop on Remote Sensing for Environmental Data in Albania: A strategy for integrated Management, Tirana, 1999. **Proceedings**. Albania, p. 65-87.

Troppmair, H. **Geossistemas e geossistemas paulistas**. Rio Claro: Universidade Estadual Paulista – UNESP, 2000, p. 71-74.

Ulaby, F. T.; Moore, R. K.; Fung, A. K. **Microwave remote sensing: active and passive: radar remote sensing and surface scattering and emission theory**. 2 ed. Norwood, MA: Atech House, 1982. 1064 p. v. 2.

Ulaby, F. T.; Jedlicka, R. P. Microwave dielectric properties of plants materials. **IEEE Transaction on Geoscience and Remote Sensing**, v. 22, p. 406-414, 1984.

Ulaby, F. T.; Allen, C. T.; Eger, G.; Kanemasu, E. Relating the microwave backscattering coefficient to leaf area index. **Remote Sensing of Environment**, v. 14, n. 1-3, p. 113-133, 1984.

Ulaby, F. T.; Kouyate, F.; Brisco, B.; Lee Williams, T. H. Textural information in SAR images. **IEEE Transactions on Geoscience and Remote Sensing**, v. 24, n. 2, p. 235-245, 1986a.

Ulaby, F. T.; Moore, R. K.; Fung, A. K. **Microwave remote sensing: active and passive**: from theory to applications. 2 ed. Norwood, MA. Artech House, 1986b. 2162 p. v. 3.

Van der Sanden, J. J. **Radar remote sensing to support tropical forest management**. Georgetown, Guyana, 330p. (Doctoral Dissertation) – Tropenbos-Guyana Programme, 1997.

Venturieri, A.; Santos, J. R. Técnicas de classificação de imagens para análise da cobertura vegetal. In: Assad, E. D.; Sano, E. E. ed. **Sistema de informação geográfica: Aplicações na agricultura**. 2ed. Brasília: Embrapa-CEPAC, 1998, cap.2, p. 13-29.

Vieira, P.R. **Desenvolvimento de classificadores de máxima verossimilhança pontuais e ICM para imagens de abertura sintética**. São José dos Campos. 227p. (INPE-6124-TDI/585). Dissertação (Mestrado em Sensoriamento Remoto) – Instituto Nacional de Pesquisas Espaciais, 1996.

Vieira, P. R.; Yanasse, C. C. F.; Frery, A. C.; Sant'Anna, S. J. S. Um sistema de análise e classificação estatística para imagens SAR. In: Latin American Seminar on Radar Remote Sensing, 1., Buenos Aires, 2-4 Dec. 1997. **Image processing techniques**. Buenos Aires: ESA/INPE, 1997, p.179-185. (ESA SP-407)

Wang, L.; He, D. C. A new statistical approach for texture analysis. **Photogrammetric Engineering and Remote Sensing**, v. 56, n. 1, p. 61-66, 1990.

Wood, D.; McNairn, H.; Brown, R.J.; Dixon, R. The effect of dew on the use of RADARSAT-1 for crop monitoring: choosing between ascending and descending orbits. (Using RADARSAT-1 for crop monitoring: choosing between ascending and descending orbits). **Remote Sensing of Environment**. v. p. 241-247, 2002.

## APÊNDICE A

### Imagens de textura

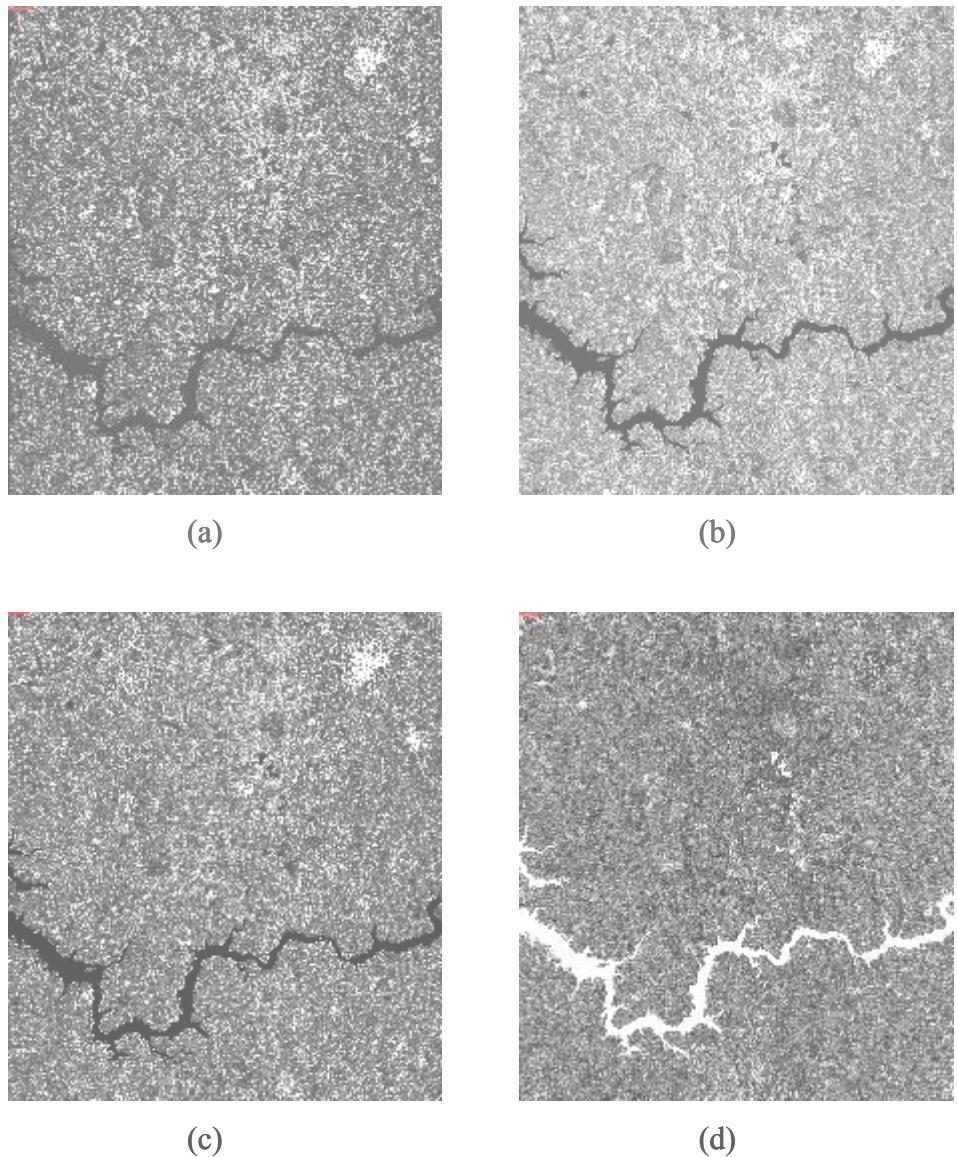
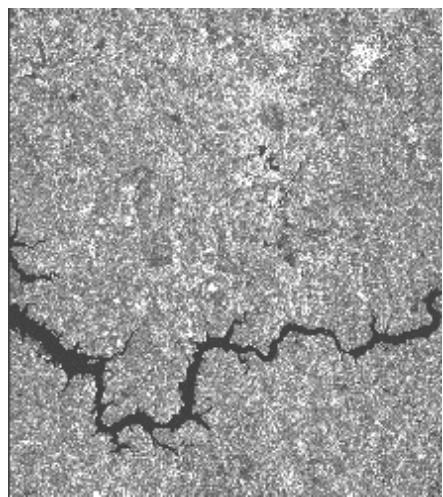
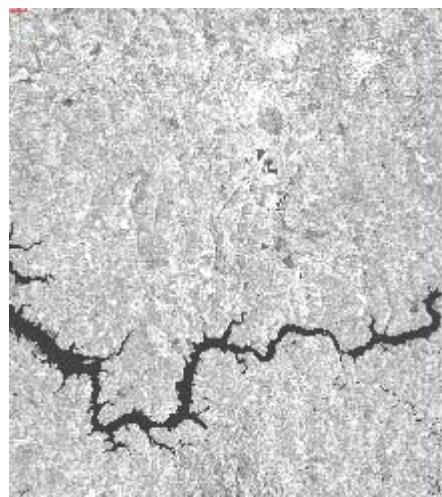


FIGURA A.1 - Imagens de textura da imagem F5D. (a) *Cluster prominence*, (b) Contraste do vetor diferença, (c) Contraste do vetor diferença (Frost 5x5), (d) Energia do vetor diferença.

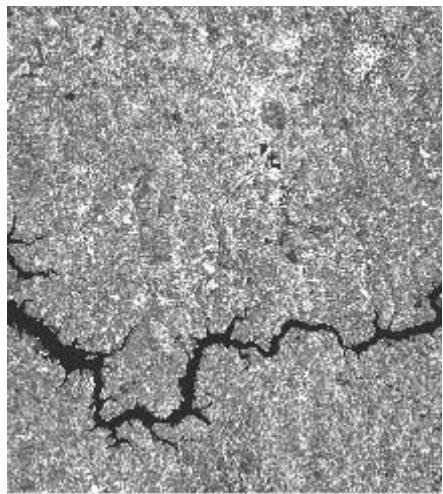
(continua)



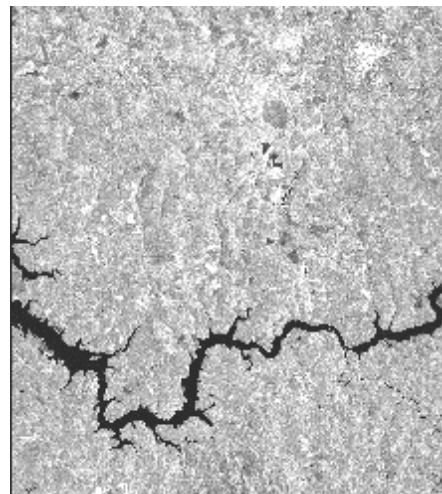
(e)



(f)



(g)



(h)

FIGURA A.1 - Imagens de textura da imagem F5D (conclusão). (e) Variância do vetor diferença, (f) Média (Frost 5x5), (g) Média do vetor soma, (h) Média do vetor soma (Frost 5x5).

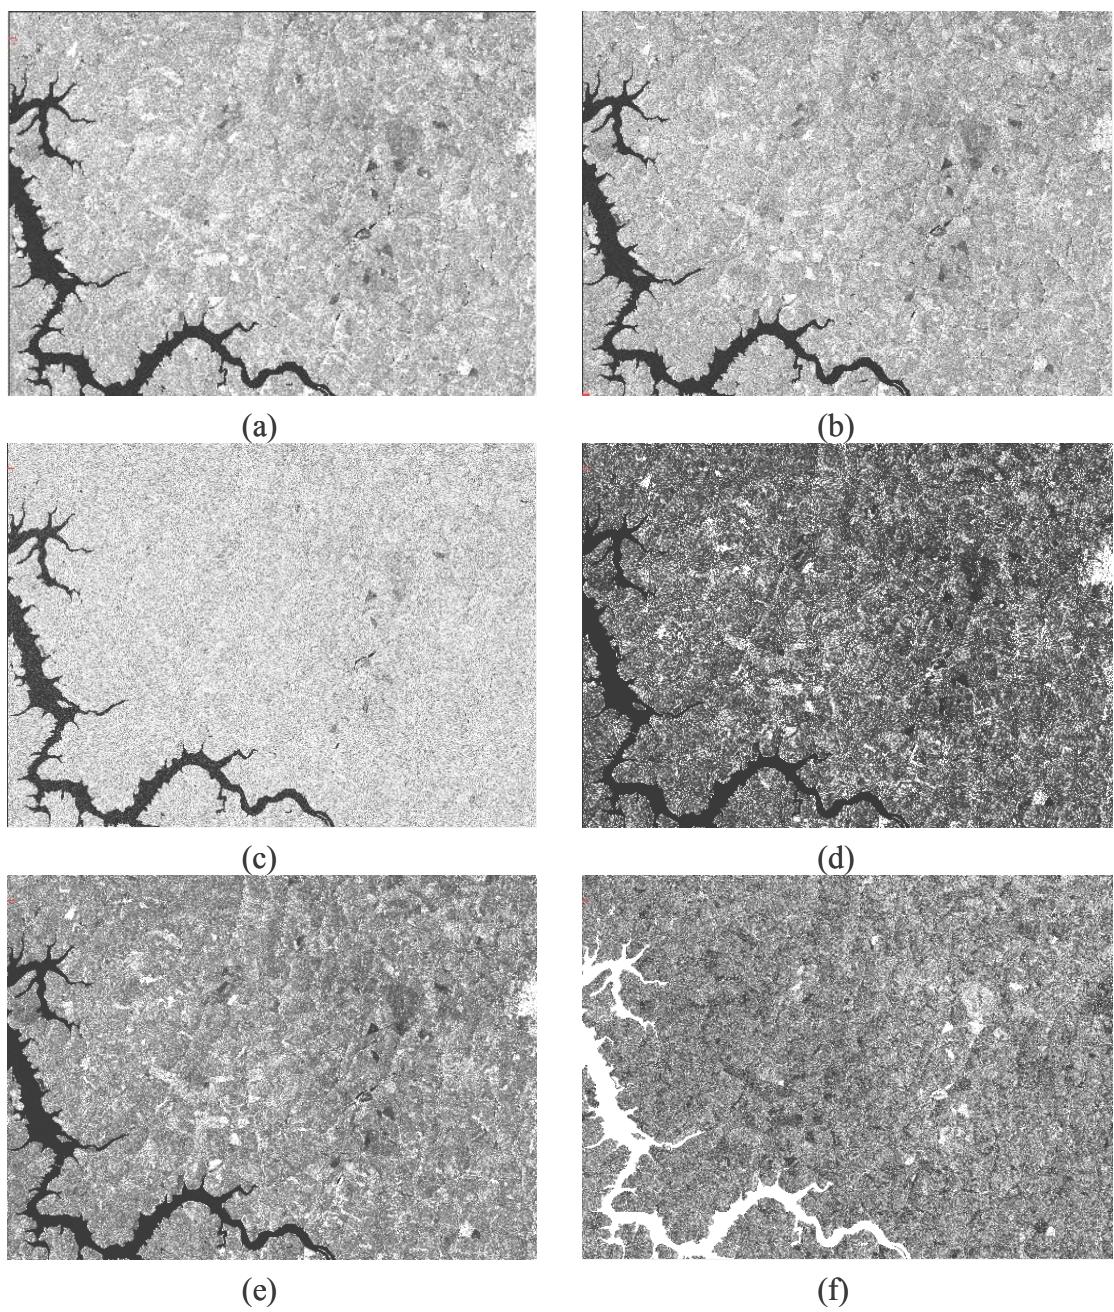


FIGURA A.2 - Imagens de textura F5A. (a) Média (Frost5x5), (b) Média (Lee 5x5), (c) Qui-quadrado, (d) *Cluster prominence*, (e) Contraste do vetor diferença, (f) Energia do vetor diferença.

(continua)

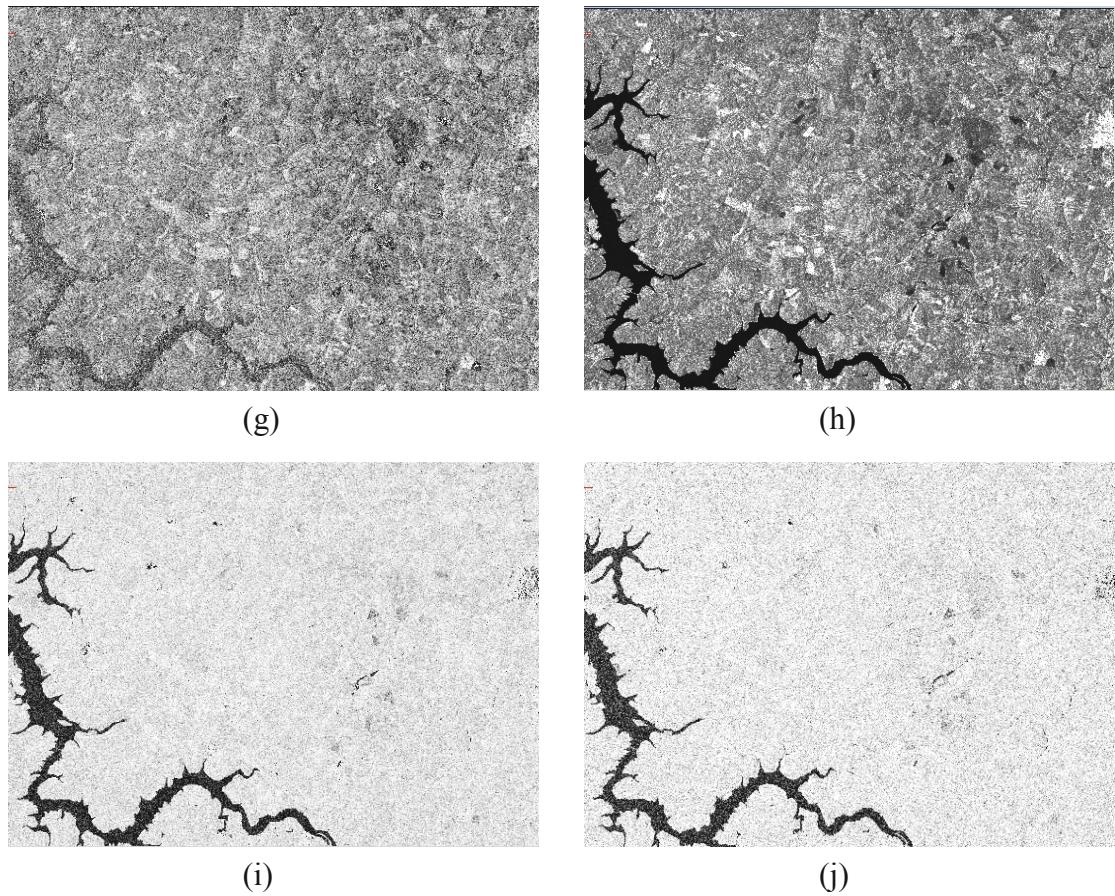


FIGURA A.2 - Imagens de textura F5A (conclusão). (g) Entropia do vetor diferença, (h) Variância do vetor diferença, (i) Entropia, (j) Entropia (Frost5x5).

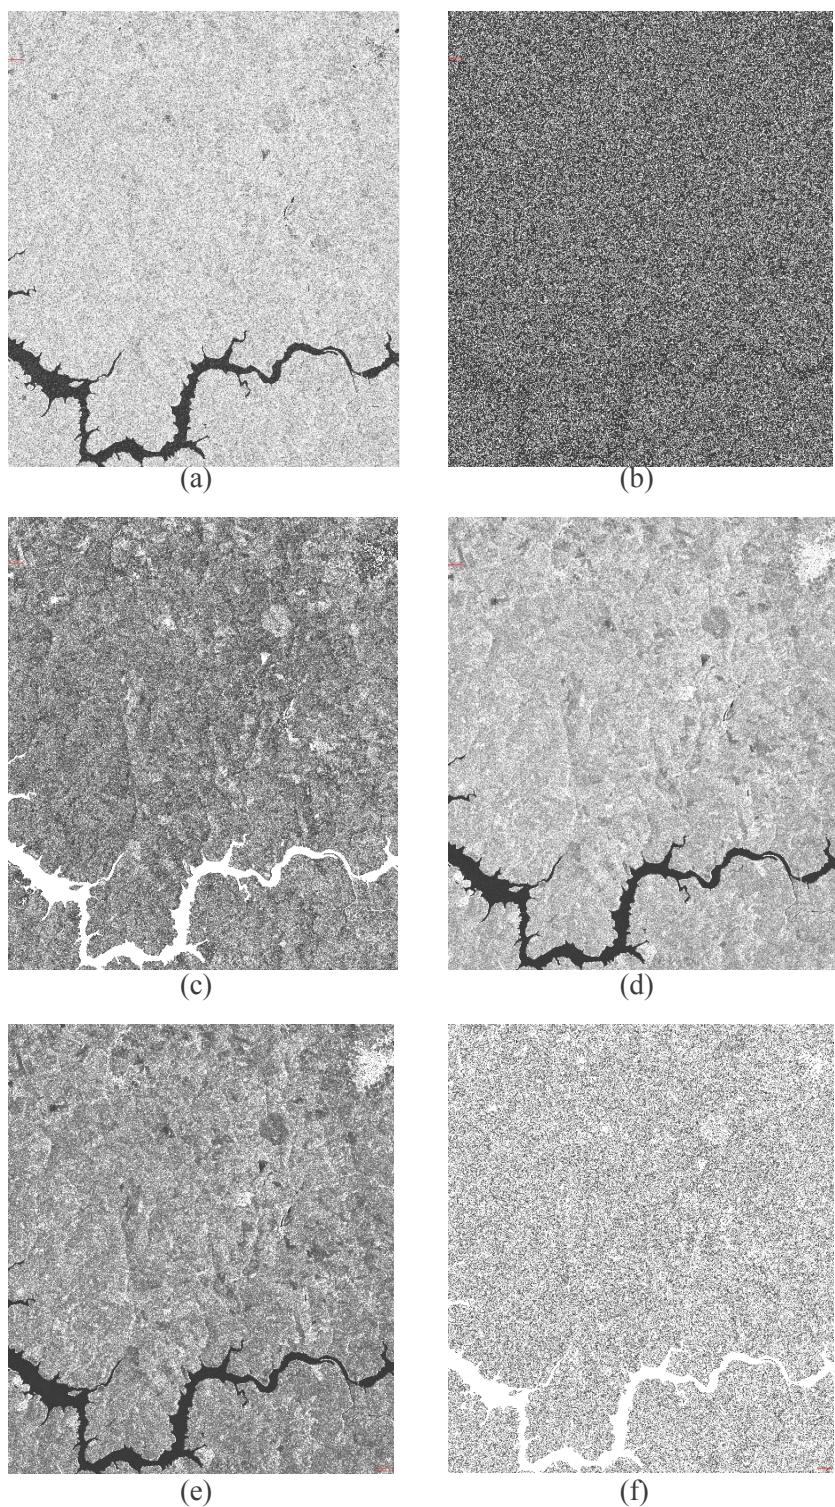


FIGURA A.3 - Imagens de textura S7D. (a) Qui-quadrado, (b) Contraste, (c) Energia do vetor diferença, (d) Média do vetor diferença, (e) Variância do vetor diferença, (f) Energia.

(continua)

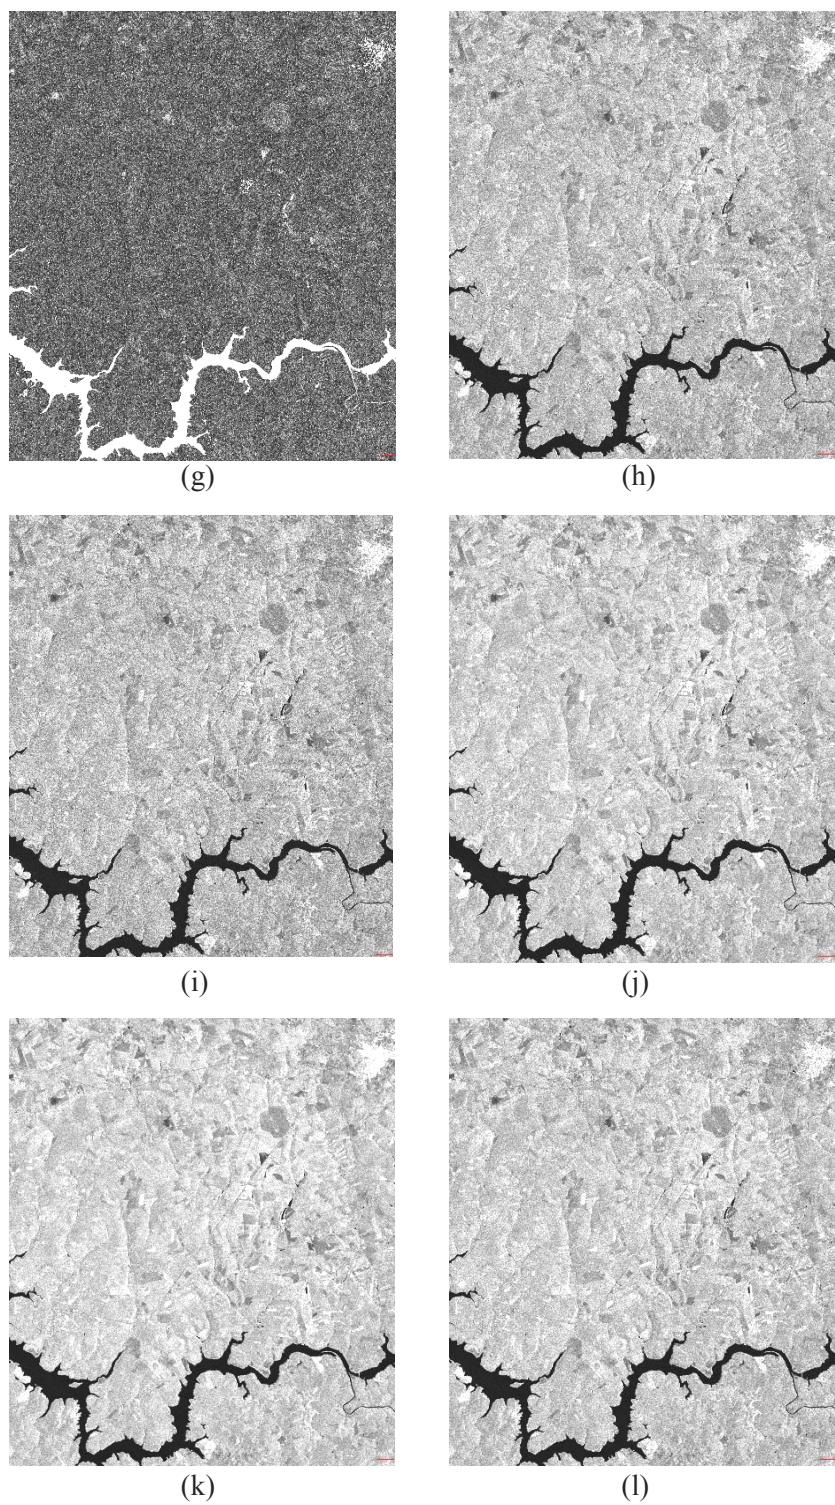


FIGURA A.3 - Imagens de textura S7D (conclusão). (g) homogeneidade, (h) Desvio médio absoluto, (i) Média, (j) Média (Frost5x5), (k) Média (Gamma5x5), (l) Média do vetor soma.